

Investigación en Inteligencia Artificial


Dr. Luis Miguel Garay Gallastegui

Dr. Joaquín Gaspar Medina Arco

Tema 1 – Origen y evolución de la inteligencia artificial

Problema:


¿Cómo podemos explicar las claves del desarrollo actual de la Inteligencia Artificial con base en su evolución histórica?



De qué vamos a hablar hoy...

- ▶ ¿Cómo estudiar este tema?
- ▶ Definición y origen del concepto inteligencia artificial.
- ▶ Evolución de la Inteligencia Artificial
- ▶ Inteligencia artificial y conceptos relacionados.

¿Cómo estudiar este tema?



Introducción a la Inteligencia Artificial

- Contexto y evolución Inteligencia Artificial
- Disciplinas Inteligencia Artificial
- Terminología

Consejo: *Iniciamos un camino...* disfrutadlo con curiosidad porque es la clave del éxito en cualquier viaje

Definición elusiva

- ▶ Cuando la IA consigue sus objetivos, dejamos de percibirla como tal
 - Búsquedas en Google
 - Traducción automática
 - Amazon
 - Netflix
 - GPS
 - Alexa, Cortana, Siri...

Definición y origen del concepto inteligencia artificial

► Definición

inteligencia¹ 

Del lat. *intelligentia*.

1. f. Capacidad de entender o comprender.
2. f. Capacidad de resolver problemas.
3. f. Conocimiento, comprensión, acto de entender.
4. f. Sentido en que se puede tomar una proposición, un dicho o una expresión.
5. f. Habilidad, destreza y experiencia.
6. f. Trato y correspondencia secreta de dos o más personas o naciones entre sí.
7. f. Sustancia puramente espiritual.
8. f. **servicio de inteligencia**.

inteligencia artificial

1. f. *Inform*. Disciplina científica que se ocupa de crear programas informáticos que ejecutan operaciones comparables a las que realiza la mente humana, como el aprendizaje o el razonamiento lógico.

Fuente: RAE

Definición y origen del concepto inteligencia artificial

► Definición

*La **automatización de actividades** que vinculamos con **procesos de pensamiento humano**, actividades como la toma de decisiones, resolución de problemas, aprendizaje...
(Bellman, 1978)*

*El arte de desarrollar máquinas con **capacidad para realizar funciones** que cuando son realizadas por personas **requieren de inteligencia**
(Kurzweil, Richter, Kurzweil y Schneider, 1990)*


Mucho término y pocas nueces

► ¿Es inteligente?

- Un coche autónomo
- El GPS del coche
- Un agente conversacional (Eliza)
- Un resolvedor de captchas
- Deep Blue
- Watson en Jeopardy
- Un mono que imita nuestros gestos
- Nosotros

Ante la duda, preguntemos a Turing

► Test de Turing



Wikimedia Commons, <https://commons.wikimedia.org/w/index.php?curid=3777581>

Objetivo en movimiento

- ▶ Hoy ya no es “interesante” superar el test de Turing
 - Poca aplicación real
 - Agentes contruidos para superar el test, no para ser útiles
- ▶ De hecho, hay una escisión
 - IA débil
 - IA fuerte


Evolución de la IA

De dónde venimos y hacia dónde vamos...

(qué profundo...)

¿Es buen momento para estudiar IA?

- Tecnologías que contribuyen a la competitividad




Fuente: McKinsey (2022)


"Top tech trends that will shape the coming decade"

¿Es buen momento para estudiar IA?

► Innovación, Adopción, Inversión




Fuente: Daniel Zhang et al., *The AI Index 2022 annual report*, Stanford University, Mar 2022; “*The state of AI in 2021*,” McKinsey, Dec 8, 2021



¿Es buen momento para estudiar IA?

- ▶ Nunca antes la investigación académica, los avances corporativos y la inversión ha estado tan alineada




Innovación, Adopción, Inversión



Historia de la inteligencia artificial

► Timeline



Historia de la inteligencia artificial

► Timeline

1950-1970

Exuberancia (sin resultados)

- Nos vamos a comer el mundo
- Pero no hay resultados tangibles
- Mucho foco en la IA fuerte y simbólica

Los 70

Sistemas basados en el Conocimiento

- IA simbólica o formulación del conocimiento
- Cuello de botella del modelado del conocimiento y mantenimiento
- Primeros trabajos con coches autónomos
- Mucho foco en complejidad y calculabilidad

Los 80


Sistemas expertos y redes neuronales

- Sistemas expertos
- Empezamos a mirar las redes neuronales
- Primeros algoritmos genéticos
- Lógica difusa

Los 90

Avances

- Agentes inteligentes
- Explosión ontologías modelizar conocimiento
- Vuelve la exuberancia aunque seguimos sudando con la complejidad y sin conseguir bases de conocimiento
- Deep Blue




Actualidad

Deep Learning

- Edad de oro de la IA subsimbólica
- Redes neuronales de alta potencia
- Sistemas clasificadores
- Sistemas de recomendación...
- Big Data + Cloud + Computación

Los inviernos de la IA



El punto de inflexión

¿Dónde estamos hoy?

► ¿En la cúspide de la curva?

- La edad de oro de la IA subsimbólica/débil
- Redes neuronales de alta potencia
- Sistemas clasificadores que actúan en milisegundos
- Sistemas de recomendación para compras

La transición hacia la IA aplicada

► Investigación antes


- Implementar los sistemas de IA y buscarles aplicación

► Investigación hoy

- IA teórica
 - Nuevos algoritmos
 - Mejoras de rendimiento
 - Despliegue para terceros
- IA aplicada
 - Uso de implementaciones de IA de terceros
 - ¿Qué terceros?

Los “terceros”

Google



IBM **Watson**

aws



Microsoft

Hoy y mañana

La IA y sus campos afines

Inteligencia artificial y conceptos relacionados

► Vehículos autónomos



Inteligencia artificial y conceptos relacionados

► Robótica

Ciencia que estudia el diseño y construcción de máquinas autónomas capaz de realizar tareas de forma inteligente, resolviendo problemas y adaptándose a los cambios que suceden en el entorno




1. South Korea 🇰🇷
2. Singapore 🇸🇬
3. Germany 🇩🇪
4. Japan 🇯🇵
5. Sweden 🇸🇪
6. Denmark 🇩🇰
7. US 🇺🇸
8. Italy 🇮🇹
9. Belgium 🇧🇪
10. Taiwan 🇹🇼

Ranking países penetración Robots en Industria
Fuente: Federación Internacional de Robótica (IFR)

Inteligencia artificial y conceptos relacionados


► Robótica




Inteligencia artificial y conceptos relacionados

► Sistemas expertos

Un sistema experto intenta acumular el conocimiento existente en un ámbito concreto y **aplicarlo a la toma de decisiones** empleando procesos de razonamiento lógico



Arquitectura básica de un sistema experto



Ejemplo de ontología

Inteligencia artificial y conceptos relacionados

► Procesamiento lenguaje natural (PLN)

El procesamiento del lenguaje natural (PLN) estudia las **interacciones entre las computadoras y el lenguaje humano**




VOICE ASSISTANTS


Inteligencia artificial y conceptos relacionados

► Algoritmos genéticos

Algoritmos que enfocan las soluciones a un problema simulando las leyes evolutivas básicas. Realizan pequeños cambios o ‘mutaciones’ en las soluciones posibles y si la nueva solución es mejor que el anterior, ‘sobrevive’ permaneciendo la mutación.



Algoritmos genéticos como posibles técnicas de “soft computing” a utilizar en OCR




Algoritmos genéticos empleados para el procesamiento de logs en procesos de negocio

Inteligencia artificial y conceptos relacionados

► Inteligencia Artificial, Machine Learning y Redes Neuronales


¿Cuál es la relación entre estos conceptos?



Inteligencia artificial y conceptos relacionados


► Machine Learning (Aprendizaje automático)

Generalizar comportamientos y encontrar patrones en los datos. Para ello se entrena el modelo con un conjunto de datos etiquetados. Una vez entrenado nos permitirá aplicarlo a nuevos datos y predecir entradas futuras.



Inteligencia artificial y conceptos relacionados



- ▶ Machine Learning (Aprendizaje automático)



Inteligencia artificial y conceptos relacionados

► Redes Neuronales

Las redes neuronales intentan “emular” la forma en que las personas tomamos decisiones, de modo “similar” a cómo lo hacen las neuronas en nuestro cerebro



Inteligencia artificial y conceptos relacionados

► Computación cognitiva

Sistemas de autoaprendizaje que utilizan la minería de datos, el reconocimiento de patrones y el procesamiento del lenguaje natural para imitar el funcionamiento del cerebro humano y colaborar con personas.



- Análisis comportamiento del consumidor
- Asistente de ventas
- Agente de atención al cliente...

Y lo que viene...

¡Tiempos interesantes!

¿Cuáles serán las 5 áreas de mayor interés?

- ▶ **Avances en el aprendizaje profundo (deep learning):** El aprendizaje profundo ha sido un área de enfoque en los últimos años, pero se espera que siga avanzando. Esto incluye el desarrollo de algoritmos de aprendizaje más eficientes, la creación de redes neuronales más profundas y la capacidad de aprender con menos datos.
- ▶ **Procesamiento del lenguaje natural (NLP):** El NLP ha mejorado enormemente en los últimos años, pero aún hay mucho margen de mejora. Se espera que en el futuro cercano se produzcan avances en la comprensión del lenguaje natural, la generación de lenguaje natural y la traducción automática.
- ▶ **Inteligencia artificial explicada:** Uno de los desafíos actuales de la IA es la capacidad de explicar cómo llega a una determinada conclusión. Se espera que se desarrollen nuevas técnicas para explicar el razonamiento de la IA, lo que permitirá a los usuarios entender mejor sus decisiones y cómo mejorarlas.
- ▶ **Casos de uso sectoriales:**
 - **IA en el ámbito médico:** Se espera que la IA tenga un gran impacto en el ámbito médico, desde la mejora del diagnóstico hasta el desarrollo de nuevos tratamientos. La IA también puede ayudar a los médicos a analizar grandes cantidades de datos para identificar patrones y tendencias.
 - **IA en el transporte:** La IA también se espera que juegue un papel importante en el transporte, desde la mejora de la seguridad en los vehículos autónomos hasta la optimización de las rutas de transporte. La IA también puede ayudar a las empresas de transporte a gestionar mejor sus flotas y a reducir los costes operativos.

¿Dudas?





www.unir.net

Investigación y Gestión de Proyectos en Inteligencia
Artificial

Tema 1. Origen y evolución de la inteligencia artificial

Índice

Esquema


Ideas clave

- 1.1. Introducción y objetivos
- 1.2. Definición y origen del concepto inteligencia artificial
- 1.3. Fundamentos de la inteligencia artificial
- 1.4. Historia de la inteligencia artificial
- 1.5. Inteligencia artificial y conceptos relacionados
- 1.6. Referencias bibliográficas

A fondo

- La mente nueva del emperador
- Artificial intelligence is permeating business at last

Test



1.1. Introducción y objetivos

Este tema supone la primera introducción del alumno al concepto de inteligencia artificial, se trata, por tanto, de un tema introductorio con el objetivo genérico de adentrarse en la disciplina. Objetivos más concretos son:

- ▶ Ser capaz de enmarcar la evolución de la inteligencia artificial en su contexto histórico.
- ▶ Conocer las principales disciplinas o escuelas de la inteligencia artificial.
- ▶ Conocer algunos de los términos principales en el ámbito.

1.2. Definición y origen del concepto inteligencia artificial

La inteligencia artificial está presente en todos los ámbitos de nuestra vida. La presencia de este término en los medios de comunicación es frecuente.

La herramienta Google Trends (<https://trends.google.es/trends/>) permite analizar el interés a lo largo del tiempo de un término concreto a partir de las búsquedas realizadas en Google.

Con el término en castellano «inteligencia artificial» se aprecia un interés creciente en el último año (Figura 1).




Figura 1. Interés a lo largo del tiempo del término «inteligencia artificial».Fuente:

<https://trends.google.es/trends/explore?date=2010-01-01%202023-03-31&geo=ES&q=Inteligencia%20Artificial>

Este interés es mucho más evidente si analizamos el término en su versión anglosajona (*artificial intelligence*). Como se ha explicado anteriormente, el inglés es la lengua franca de la ciencia y la técnica, por lo que todos los análisis de este tipo adquieren mayor relevancia si se hacen en este idioma.

La Figura 2 evidencia de forma muy clara la tendencia creciente desde hace una década y el punto de inflexión producido por la aparición de ChatGPT.




Figura 2. Interés a lo largo del tiempo del término *artificial intelligence*. Fuente:

<https://trends.google.es/trends/explore?date=2010-01-01%202023-03-31&geo=ES&q=Artificial%20Intelligence>

Pero ¿qué es la inteligencia artificial?, ¿para qué sirve? Se intentará dar respuesta a estas preguntas en los siguientes apartados.

¿Qué es la inteligencia artificial?

Intuitivamente, el término «inteligencia artificial» hace referencia a **la capacidad que tienen ciertas máquinas de comportarse como humanos**. Sin embargo, esta descripción no puede considerarse una definición, ya que es sumamente ambigua y difusa.

Para llegar a una buena comprensión del término deberíamos primero entender el **significado de inteligencia**. Según la Real Academia Española, este término hace referencia a:

- ▶ Capacidad de entender o comprender.
- ▶ Capacidad de resolver problemas.
- ▶ Conocimiento, comprensión, acto de entender.

Aunque las definiciones parecen claras y evidentes, el espectro se complica según

nos adentramos en la interpretación del término. ¿Cuántos tipos de inteligencia hay?, ¿uno, varios?

Howard Gardner (1983) en su famosa obra *Frames of Mind: The Theory of Multiple Intelligences* se atrevió a formular diez tipos de inteligencia:

- ▶ Musical.
- ▶ Espacial o visual.
- ▶ Lingüística-verbal.
- ▶ Lógico-matemática.
- ▶ Corporal-cinestésica.
- ▶ Interpersonal.
- ▶ Intrapersonal.
- ▶ Naturalista.
- ▶ Existencial.
- ▶ Otras: categoría en la que entra incluso una inteligencia sexual.

La visión de Gardner no es plenamente aceptada, ya que algunos autores critican que este autor contempla como inteligencias lo que comúnmente se han denominado habilidades o competencias (Geake, 2008). Aun así, **esta teoría ha tenido gran impacto en ámbitos como el educativo**, donde tradicionalmente las pruebas de evaluación se enfocaban a un enfoque puramente lógico matemático y lingüístico.

Son numerosas las instituciones educativas que tratan hoy en día de ampliar la

evaluación del estudiante incorporando factores asociados a sus capacidades para la expresión artística o corporal, por poner algunos ejemplos.

Otra discusión asociada al concepto de inteligencia es la exclusividad o no de la **inteligencia como atributo humano**. Sin embargo, los resultados de la experimentación científica han conseguido apartar esta discusión al poner en evidencia que son numerosas las especies animales que consiguen generar nuevas estrategias para adaptarse mejor a las necesidades del entorno y resolver los problemas asociados (Rayner, 1887), y todo ello a pesar de que la experimentación con otras especies animales en este ámbito no es trivial (MacLean, 2014).

Comentado el concepto de inteligencia, queda profundizar en el término que nos ocupaba al inicio. Según la RAE (Real Academia Española), la **inteligencia artificial** es:

«La disciplina científica que se ocupa de crear programas informáticos que ejecutan operaciones comparables a las que realiza la mente humana, como el aprendizaje o el razonamiento lógico».

Otras definiciones del término muy extendidas son las siguientes:

«La automatización de actividades que vinculamos con procesos de pensamiento humano, actividades como la toma de decisiones, resolución de problemas, aprendizaje...» (Bellman, 1978).

«El arte de desarrollar máquinas con capacidad para realizar funciones que cuando son realizadas por personas requieren de inteligencia» (Kurzweil, Richter, Kurzweil y Schneider, 1990).

Como se puede apreciar, la automatización o realización de estas actividades por máquinas (artificial) es una característica común a estas definiciones.

1.3. Fundamentos de la inteligencia artificial

El objetivo de este apartado es identificar algunas disciplinas y conceptos que han contribuido al desarrollo de la inteligencia artificial.

Sin duda alguna, la **filosofía** es una de las disciplinas que más ha contribuido al desarrollo de la inteligencia artificial y lo ha hecho desde diversos enfoques. Las ideas filosóficas han sido básicas para definir los conceptos de «inteligencia», «racional», etc.

Aristóteles (384-322 a. C.) fue el primer autor que intentó definir el conjunto de leyes que rigen el razonamiento. El mallorquín Ramón Llull (1232-1315), patrón de los ingenieros informáticos, dedicó parte de su vida a diseñar una máquina lógica capaz de demostrar una verdad o refutar una mentira. Thomas Hobbes (1588-1679) contemplaba amplias analogías entre el proceso de razonamiento y el proceso de computación numérica.

A partir del siglo XVI aparecen corrientes filosóficas que marcan el debate de la época. Por un lado, **nos encontramos el dualismo frente al materialismo**. El dualismo hace referencia a la existencia de dos componentes independientes entre sí y que marcan nuestras elecciones. Uno de esos componentes de la mente sería el asociado al alma y funciona al margen de las leyes físicas, mientras que el otro se basa exclusivamente en la aplicación de los principios físicos universales. René Descartes (1596-1650) era uno de los firmes defensores de esta corriente.

El materialismo surge como contraposición al dualismo al considerar que todas las operaciones del cerebro se realizan de acuerdo con las leyes de la física que constituyen la mente. Según los materialistas, la conciencia es fruto de la materia. Francis Bacon (1561-1626) y Thomas Hobbes (1588-1679) fueron dos de los máximos exponentes de esta corriente.

Respecto a la procedencia del conocimiento, el **movimiento empírico** iniciado por Bacon establece que todo conocimiento tiene que pasar por la percepción de los sentidos. Como decía John Locke (1632-1704) «nada existe en la mente que no haya pasado antes por los sentidos».

La relación entre conocimiento y acción busca explicar los desencadenantes de las acciones y constituye una cuestión de especial relevancia en la inteligencia artificial. Los **postulados de Aristóteles** son, todavía hoy, una fuente imprescindible a la hora de entender esta relación. Según el filósofo griego las acciones pueden justificarse en base a la conexión lógica entre los objetivos planteados y el conocimiento de la operativa y consecuencia de las acciones aprendidas.

Obviamente, la filosofía no es la única disciplina que ha aportado valor a la evolución de la inteligencia artificial. Las matemáticas, economía, neurociencia, psicología e ingeniería computacional también han realizado indispensables contribuciones a este campo.

Otras contribuciones de la inteligencia artificial

La **matemática** es una de las ciencias que más ha contribuido al desarrollo de la inteligencia artificial. Hoy en día es complicado considerarse experto en inteligencia artificial sin poseer una elevada competencia en el manejo y comprensión de los fundamentos matemáticos relacionados con la lógica, álgebra, cálculo, etc.

Además del concepto de algoritmo trabajado desde la Antigüedad por un amplio abanico de matemáticos, la **lógica matemática** es esencial para permitir el modelado de ciertas conductas. Dos contribuciones fundamentales son el trabajo de **George Boole** (1815-1864) definiendo la lógica proposicional o booleana (se mencionará con más detalle más adelante), y las contribuciones de **Gottlob Frege** (1848-1925), extendiendo la lógica de Boole para incluir objetos y relaciones y dando lugar a la lógica de primer orden que permite la representación del conocimiento.

Para muchos autores, el principio de incompletitud pone límite al conocimiento humano al evidenciar la existencia de postulados no demostrables mediante la argumentación matemática.

<https://www.jflap.org/tutorial/turing/one/index.html>

Por último, los trabajos matemáticos relacionados con el estudio de la complejidad algorítmica y el desarrollo de los algoritmos probabilistas también merecen ser mencionados en este resumen.

Respecto a la **economía** pura y las matemáticas aplicadas a la economía, las investigaciones centradas en teoría de la decisión, teoría de juegos e investigación operativa permitieron entender y modelar mejor el concepto de agente inteligente.

La **neurociencia**, en todo lo referente a la estructura neuronal, y la **psicología**, en todo lo referente al análisis del comportamiento, realizan aportaciones destacadas a la evolución de los métodos empleados en la disciplina.

Finalizaremos este apartado hablando de las contribuciones de la **ingeniería informática**, y lo haremos centrándonos exclusivamente en las aportaciones más recientes. En un contexto de gran disposición de datos para entrenar los sistemas inteligentes y mejorar su desempeño, las aportaciones de la ingeniería informática al sector han sido esenciales permitiendo el diseño e implementación de sistemas escalables que permiten realizar en paralelo miles de millones de operaciones posibilitando la creación de aplicaciones que, en muchas ocasiones, compiten de tú a tú con las capacidades humanas (cuando no las superan).

1.4. Historia de la inteligencia artificial

Se resumirá de forma básica en este apartado la evolución de la inteligencia artificial. Se resaltarán algunos hitos destacados en la disciplina.

Aunque el trabajo puro relacionado con la inteligencia artificial comenzó poco después de la Segunda Guerra Mundial, y el término fue formalmente fijado en 1956, existen algunos antecedentes que merece la pena recordar.

En 1912, el genio español **Leonardo Torres Quevedo** (llegó a diseñar el funicular del Niágara) creó una máquina autónoma capaz de jugar al ajedrez.



Figura 4. Autómata para jugar al ajedrez diseñado por Torres Quevedo. Fuente:

<https://divulgadores.com/el-primer-juego-de-ordenador-de-la-historia/>

Constituyó este un hito importante en la época, dando una idea del potencial que podía llegar a adquirir una máquina.

En 1943, **McCulloch y Pitts** proponen una unidad de cálculo que intenta modelar el comportamiento de una neurona «natural», similar a las que constituyen el cerebro humano.




Figura 5. Unidad de cálculo propuesta por McCulloch y Pitts.

En 1949, **Donald Hebb** formula la regla de Hebb.

En 1950, el gran científico **Alan Turing** publica su obra *Computing Machinery and Intelligence* donde expone su famosa prueba de Turing. Esta prueba se diseñó para proporcionar un mecanismo que permitiese decidir si una máquina tenía un comportamiento «inteligente» o no. La prueba consiste en un humano que contempla dos terminales. En estos terminales hay un humano y un programa que contestan y dialogan con el humano o humanos entrevistadores. Si el humano no es capaz de distinguir entre el humano real y el *software*, entonces podemos decir que este software ha superado la prueba y le podemos considerar inteligente.

En **1950** también aparecen programas informáticos que aplican técnicas de inteligencia artificial como el programa de ajedrez de Arthur Samuel, el solucionador de problemas lógicos de Newell y Simon y la máquina de Gelernter, capaz de deducir problemas de geometría euclídea.

De 1952 a 1969 se da el período conocido como «Look, Ma, ¡no hands!». Esta época se caracteriza por un gran entusiasmo y expectativa en las aplicaciones de la inteligencia artificial.

En **1956** tiene lugar la Conferencia de Dartmouth (en el Dartmouth College, Estados Unidos). En este encuentro de muchos de los investigadores más influyentes del momento en el área se adoptó oficialmente el término «inteligencia artificial».

En **1965** **Robinson** propone un algoritmo capaz de aplicar criterios de razonamiento

lógico. Al mismo tiempo, aparece en el MIT el primer *chatbot* denominado Eliza.

En el período comprendido entre **1966 y 1974** se profundiza en el concepto de la complejidad computacional, algo esencial para las futuras evoluciones de la disciplina.

Entre 1969 y 1979 se desarrollan los primeros sistemas basados en el conocimiento.

En **1974** aparecen los primeros trabajos con coches autónomos, aunque todavía muy primitivos y no muy alejados de coches a control remoto.

Entre 1980 y 1988 aparecen en el mercado diversos sistemas expertos.

Entre los años **1985 y 1995** se retoma el interés por las redes neuronales.

A partir de 1988 nuevas soluciones como algoritmos genéticos o *soft computing* contribuyen al enriquecimiento de la disciplina.

A partir de 1995 se produce la gran explosión de los agentes inteligentes.

En **1997** el ordenador de IBM (*Deep Blue*) derrota a Gary Kasparov en uno de los duelos de ajedrez que más expectación han generado.

En el año **2011**, el programa de IBM Watson derrota al campeón (humano) del conocido juego *Jeopardy*.

En el año **2015**, el *software* desarrollado por Google, DeepMind AlphaGo, derrota al campeón mundial de *Go*.

En el año **2019**, DeepMind AlphaStar consigue ser gran maestro en la liga mundial de jugadores de *Starcraft II*, ganando el 98 % de las partidas.

No todo han sido éxitos en la historia de la inteligencia artificial, **los períodos que abarcan los años 1974-1980 y 1987-1993 son conocidos como los inviernos de la inteligencia artificial**. Estas franjas de tiempo se caracterizan por una gran

desilusión en las posibilidades de esta disciplina y descenso del número de aportaciones.

Aunque no constituye un hito puramente científico, merece la pena mencionar la **aparición de las tres leyes de la robótica de Asimov** (aunque también hay quien asocia la coautoría de estas leyes con John W. Campbell). La aparición de estas leyes propició interesantes debates sobre la evolución de la inteligencia artificial. Las tres leyes de la robótica de Asimov establecen los ejes fundamentales que deberían guiar la conducta de un robot. Son las siguientes:

1.ª Ley	2.ª Ley	3.ª Ley
Un robot no hará daño a un ser humano o, por inacción, permitir que un ser humano sufra daño	Un robot debe hacer o realizar las órdenes dadas por los seres humanos, excepto si estas órdenes entrasen en conflicto con la primera ley	Un robot debe proteger su propia existencia en la medida en que esta protección no entre en conflicto con la primera o la segunda ley

Figura 6. Leyes de la robótica de Asimov.

Las **leyes de Asimov** guardan relación con los retos éticos que afronta la inteligencia artificial y que serán tratados en próximos temas.

1.5. Inteligencia artificial y conceptos relacionados

Inteligencia artificial es un concepto muy amplio y genérico. Por ello es útil y necesario precisar con mayor exactitud algunas de las aplicaciones o campos de actuación de la inteligencia artificial más referenciados.

Robótica

Comencemos con el concepto de robótica. Según la RAE, un robot es una «máquina o ingenio electrónico programable, capaz de manipular objetos y realizar operaciones antes reservadas solo a las personas». El término robot proviene de su correspondiente anglosajón (con la misma grafía), que proviene a su vez de la voz checa *robota*, que significa 'trabajo, prestación personal'.

El significado original del término tiene sentido porque los robots se concibieron como máquinas destinadas a ayudar al ser humano a realizar las tareas más pesadas, estando ahora totalmente introducidos en casi la totalidad de las cadenas de producción.

Robótica, por tanto, es la ciencia que estudia el diseño y construcción de máquinas autónomas capaz de realizar tareas de forma inteligente, resolviendo problemas y adaptándose a los cambios que suceden en el entorno.

A la hora de hablar de robótica, haremos referencia con relativa frecuencia a Sophia por el nivel de interlocución con los humanos que demuestra. Sophia es producto de Hanson Robotics.



Figura 7. Sophia, robot creado por Hanson Robotics. Fuente: https://www.hansonrobotics.com/wp-content/uploads/2018/09/gds_Sophia_D058.jpg

Sin embargo, no es Sophia el tipo de robot susceptible de estar más presente en nuestras casas, los robots aspiradoras o robots juguetes son ejemplos más cercanos a nuestros hogares.

Sistemas expertos

Una de las ramas más conocidas de la inteligencia artificial es la de los sistemas expertos. Un sistema experto **intenta acumular el conocimiento existente en un ámbito concreto (por ejemplo, el área de atención primaria de medicina) y aplicarlo a la toma de decisiones empleando procesos de razonamiento lógico**. El desarrollo de sistemas expertos se potenció especialmente a partir de los años 70. Hoy en día disponemos de sistemas expertos que ayudan a tomar mejores decisiones en el ámbito clínico, transporte aéreo, seguridad, gestión de empresas, etc.

El desarrollo de un sistema experto suele exigir el modelado del conocimiento asociado para que la máquina pueda tenerlo en consideración. Para esta tarea son especialmente indicadas las **ontologías**. Una ontología pretende representar el

conocimiento existente, así como las propiedades y relaciones entre los distintos conceptos de forma consistente. La Figura 8 muestra un sencillo ejemplo de una ontología.




Figura 8. Ejemplo de una ontología para modelar la disponibilidad de pizzas existentes. Fuente:

https://www.researchgate.net/figure/236842047_fig1_Figure-1-Example-pizza-ontology-represented-as-a-graph-G-a-and-a-changed-version-of

Procesamiento del lenguaje natural

El procesamiento del lenguaje natural (PLN) estudia las **interacciones entre las computadoras y el lenguaje humano**. Es este uno de los ámbitos de trabajo más fructíferos de los últimos años y ha dado lugar a conocidos productos como Siri de Apple o Alexa de Amazon.




Figura 9. Echo y Alexa. Fuente: https://images-na.ssl-images-amazon.com/images/I/51TFnR7AtGL._AC_US218_.jpg

Estos productos permiten al usuario comunicarse con un dispositivo concreto, como puede ser el teléfono móvil, a través del lenguaje natural.

Las técnicas de procesamiento del lenguaje natural se aplican también al diseño de *chatbots*. Los *chatbot* son piezas de *software* diseñada para aplicaciones de mensajería que interactúan con el usuario intentando comprender y satisfacer sus necesidades proveyendo acceso al servicio más adecuado en cada momento.

Productos como Siri o Alexa se enfrentan a multitud de retos a la hora de interpretar el lenguaje hablado. La gran diversidad de idiomas y acentos, así como la necesidad de proporcionar una respuesta coherente en tiempo y forma adecuado hace que este tipo de soluciones no sean triviales.

Algoritmos genéticos

Una parte de la inteligencia artificial se ocupa de lo que algunos autores vienen a denominar **pautas para la vida artificial**. Este tipo de técnicas simulan realidades virtuales que evolucionan en función de un conjunto de reglas previamente definidas. Uno de los ejemplos más conocidos de este paradigma son los algoritmos genéticos.

Los algoritmos genéticos **suelen emplearse para encontrar la solución a un**

problema concreto simulando las leyes evolutivas básicas. En primer lugar, se parte de una inicialización, frecuentemente aleatoria, de la población. Cada elemento de la población está compuesto de una serie de genes que se interpretan según una función de *fitness* previamente definida por el usuario. Esta función de *fitness* permite comparar los distintos individuos entre sí y saber cuáles están más cerca del objetivo buscado.

Por ejemplo, supongamos que buscamos maximizar la **función** $f(x, y) = x^2 + 5y^3$. Cada individuo podría estar compuesto de dos genes representando a x e y . Según esto, los mejores individuos considerando el objetivo inicialmente planteados serían los que tuviesen un valor más alto a la hora de calcular $f(x, y)$.

Ciertos elementos de la población (por ejemplo, los más aptos al entorno según el criterio elitista) se cruzan entre sí (*crossover*) generando una descendencia y compartiendo genes. Algunos estos genes podrían sufrir una mutación. A continuación, se evalúa cada individuo de la población según la función de *fitness* determinando, según el criterio seguido, quiénes sobreviven y pasan a la siguiente iteración y quiénes fallecen. La Figura 10 muestra el esquema general de un algoritmo genético.




Figura 10. Esquema general de un algoritmo genético. Fuente:

https://www.researchgate.net/publication/312520808_A_method_for_the_generation_of_rankings_in_the_teamwork_selection_in_competitive_environment_based_on_genetic_algorithms/figures?lo=1

Machine learning (aprendizaje automático)

Las técnicas de *machine learning* o aprendizaje automático pretenden **generalizar comportamientos y encontrar patrones** en función de los ejemplos proporcionados de antemano. Existen dos grandes tipologías a la hora de afrontar un problema de aprendizaje automático: aprendizaje supervisado y aprendizaje no supervisado.

Con las técnicas de **aprendizaje supervisado** se entrena al algoritmo con un conjunto de datos previamente etiquetado (conjunto de entrenamiento). En función de ese entrenamiento previo el algoritmo generará un modelo. La aplicación de dicho modelo a nuevos datos permitirá predecir entradas futuras.

Por ejemplo, supongamos que queremos generar un modelo capaz de discernir si una imagen representa una cara humana o no. Para ello alimentaremos al algoritmo con imágenes de caras humanas variadas (y las catalogaremos como «caras») e imágenes de otros objetos (y las catalogaremos como «no caras»). El algoritmo tratará de encontrar patrones comunes de las «caras» frente a las «no caras» para

generar un modelo. Posteriormente, probaremos dicho modelo con un conjunto nuevo de imágenes (conjunto de prueba). En este caso, no se proporciona información al modelo sobre si está leyendo una cara o no. Será el modelo el que haga la predicción oportuna. Comparando los resultados del modelo en este conjunto de prueba con la realidad podremos obtener una idea de su fiabilidad. La Figura 10 muestra el esquema asociado a la fase de entrenamiento.



Figura 11. Ejemplo de aprendizaje supervisado. Fuente: <https://uploads.toptal.io/blog/image/443/toptal-blog-image-1407508081138.png>

En el caso del **aprendizaje no supervisado**, no se proporciona al algoritmo información previa de etiquetado. Por ejemplo, supongamos que queremos clasificar a los clientes de una empresa en determinados grupos en función de su actividad (*clustering*). En este caso no sabemos de forma previa el grupo al que pertenece el cliente, por tanto, no se puede proporcionar un etiquetado previo. En función de los parámetros de cada cliente, propiedades y relaciones numéricas entre los distintos individuos el algoritmo propondrá distintas tipologías o grupos de clientes.




Figura 12. Ejemplo de aprendizaje no supervisado. Fuente: <https://insidebigdata.com/>

Redes neuronales y *deep learning*

Las redes neuronales representan un modelo computacional de las conexiones entre neuronas que se dan en el cerebro. Cada neurona recibe información de entrada procedente de varias fuentes y emite una salida concreta en función de su configuración.

Asociado al concepto de redes neuronales, un término en auge es el concepto de *deep learning*. Las técnicas de *deep learning* constituyen una familia específica de **algoritmos de aprendizaje automático centrados en aprender representaciones de datos**, por ejemplo, la estructura de una imagen que represente una cara humana. El ejemplo más común de *deep learning* es una red neuronal de varias capas ocultas. La Figura 13 muestra un conjunto de neuronas interconectadas entre sí. Las capas del medio (marcadas en el gráfico como *hidden layer 1, 2 y 3*) reciben datos de las capas previas, procesan el resultado según un procedimiento previamente estipulado antes de compartir la salida con otras neuronas.




Figura 13. Red neuronal de varias capas ocultas. Fuente: https://cdn-images-1.medium.com/max/1600/1*Pn42wNB6_HBKgpvxRzGBWw.png

Las aplicaciones de las técnicas de *deep learning* son varias y diversas, desde visión por computador hasta reconocimiento automático del habla pasando por sistemas de recomendación. En este punto, el alumno no debe preocuparse por que le resulten vagos y poco concretos los contenidos sobre redes neuronales y *deep learning* expuestos en este tema. Pretendemos aquí simplemente introducir estos términos de forma muy básica.

Computación cognitiva

El último de los conceptos que vamos a estudiar en este tema es el concepto de «computación cognitiva», concepto sumamente amplio que está centrado en **intentar que las máquinas piensen de la forma más parecida posible a como lo haría un ser humano**. La computación cognitiva exige aprovechar todos los datos que tenemos a nuestra disposición tanto estructurados (bases de datos) como no estructurados (imágenes, vídeos, sonidos...). La computación cognitiva obliga a usar estos datos en contexto. Pongamos un ejemplo de esto: supongamos que están hablando dos personas y una de ellas dice a la otra: «¡Claro!, me parece perfecto».

¿Qué ha querido decir? ¿Está de acuerdo? La respuesta es: depende. El tono del

mensaje, la expresión facial a la hora de transmitir el mensaje, todo es relevante. Si un programa simple de procesamiento del lenguaje natural analizase la frase, lo normal es que interpretase que sí, que efectivamente está de acuerdo. Una aplicación cognitiva, sin embargo, sería capaz de contextualizar el mensaje en línea con el tono de voz y la expresión facial a la hora de tomar una decisión.

Las aplicaciones cognitivas están en auge en la industria, pero debemos ser especialmente cuidadosos porque, en ocasiones, el término se emplea con demasiada libertad.

1.6. Referencias bibliográficas

Bellman, R. (1978). *An introduction to artificial intelligence: Can computers think?* Thomson Course Technology.

Gardner, H. (1983). *Frames of mind: The theory of multiple intelligences*. NY: Basics.

Geake, J. (2008). Neuromythologies in education. *Educational Research*, 50(2), 123-133.

Kurzweil, R., Richter, R., Kurzweil, R. y Schneider, M. L. (1990). *The age of intelligent machines* (Vol. 579). Cambridge: MIT press.

MacLean, E. L. et al. (2014). *The evolution of self-control*. *Proceedings of the National Academy of Sciences*, 111(20), E2140-E2148.

Rayner, H. (1887). Breeding for Intelligence in Animals. *Nature*, 36, 246-246.

Russell, S. y Norving, P. (2004). *Inteligencia Artificial: un enfoque moderno* (pp. 1-35). Madrid: Pearson Educación.

La mente nueva del emperador

Penrose, R. y García Sanz, J. J. (2002). *La mente nueva del emperador*. México: Fondo de Cultura Económica (FCE).

Gran introducción a la inteligencia artificial de la mano del gran físico Roger Penrose, Premio Nobel de Física 2020. Un apasionante paseo por la matemática y la física, y por los hallazgos del pensamiento humano.

Artificial intelligence is permeating business at last

The Economist. (6 de diciembre de 2022). *Artificial intelligence is permeating business at last*. Recuperado de <https://www.economist.com/business/2022/12/06/artificial-intelligence-is-permeating-business-at-last>

La inteligencia artificial se está trasladando rápidamente del laboratorio al mundo real. Chatgpt, una nueva herramienta de inteligencia artificial que se lanzó recientemente para pruebas públicas, está causando sensación por su capacidad para elaborar y argumentar todo tipo de contenidos. Y es solo un pequeño ejemplo de las posibilidades de la IA que está seduciendo a las empresas y al gran público.

1. ¿Cuáles se pueden considerar definiciones de la «inteligencia artificial»?
 - A. Una rama de la ingeniería informática centrada en el desarrollo de máquinas capaces de realizar cuantos más cálculos mejor.
 - B. La ciencia encargada de la automatización de procesos de fabricación.
 - C. El arte de desarrollar máquinas con capacidad para realizar funciones que cuando son realizadas por personas requieren de inteligencia.
 - D. La inteligencia asociada a los animales.

2. Han contribuido a los fundamentos de la inteligencia artificial:
 - A. La filosofía.
 - B. La economía.
 - C. Las matemáticas.
 - D. Todas las anteriores.

3. Los teoremas de incompletitud de Gödel:
 - A. Establecen que el poder de las matemáticas es infinito y pueden demostrar cualquier cosa.
 - B. Demuestran que existen afirmaciones que no se pueden demostrar verdaderas ni falsas.
 - C. Gödel no llegó a finalizar la formulación de ahí el nombre de incompletitud.
 - D. Demuestran que la inteligencia artificial será capaz de crear máquinas autónomas.

4. La economía:
- A. Ha realizado diversas contribuciones al campo de la inteligencia artificial.
 - B. Es una ciencia totalmente ajena a la inteligencia artificial.
 - C. La teoría de la oferta y demanda ha sido muy valiosa para la inteligencia artificial.
 - D. La econometría ha aportado mucho conocimiento a ciertas técnicas de inteligencia artificial.
5. Algunos hitos de la inteligencia artificial fueron:
- A. El desarrollo del primer ordenador cuántico.
 - B. La ley de la relatividad.
 - C. El test de Turing.
 - D. Ninguna de las anteriores.
6. Los sistemas expertos:
- A. No son lo suficientemente fiables para emplearlos en medicina.
 - B. A veces exigen el empleo de ontologías para representar y modelar el conocimiento disponible.
 - C. Salvo en casos sencillos como un sistema de gestión de pedidos de pizzas, no son fiables.
 - D. Se emplean exclusivamente para la gestión de empresas.
7. Las técnicas de procesamiento del lenguaje natural:
- A. A veces requieren gran capacidad de cómputo para responder de forma muy breve al usuario.
 - B. Afrontan el reto de lidiar con varios idiomas y multitud de acentos.
 - C. pueden aplicarse al diseño de chatbot.
 - D. Todas las anteriores.

8. Los algoritmos genéticos:
 - A. Simulan las leyes de la evolución para intentar encontrar la mejor solución a problemas reales.
 - B. Se emplean en medicina para analizar la composición genética.
 - C. Se abandonaron rápidamente debido a su alto coste computacional.
 - D. No son considerados una técnica de inteligencia artificial.

9. El aprendizaje automático:
 - A. Consiste en compartir con la máquina una serie de reglas para que tome las decisiones más oportunas.
 - B. Tiene dos vertientes: aprendizaje supervisado y aprendizaje bajo-supervisado.
 - C. Pretende generalizar comportamientos y encontrar patrones con base en ejemplos proporcionados de antemano.
 - D. No incluye a las redes neuronales como una de sus técnicas.

10. La computación cognitiva:
 - A. Está presente en todas las aplicaciones de inteligencia artificial.
 - B. Implica el uso de grandes volúmenes de datos proveyendo el adecuado contexto.
 - C. Todas las compañías usan el término correctamente y se vende como cognitivo lo que realmente es.
 - D. Es un término cuyo origen se remonta a los años 40.

Investigación y Gestión de Proyectos en Inteligencia
Artificial

Tema 2. Ciencia y método científico

Índice

Esquema


Ideas clave

- 2.1. Introducción y objetivos
- 2.2. La ciencia y su método
- 2.3. Metodologías de investigación en inteligencia artificial
- 2.4. Metodología empírica cuantitativa
- 2.5. Metodología empírica cualitativa
- 2.6. Referencias bibliográficas

A fondo

- Scientific Papers
- Uso ético de la información y sus citas bibliográficas
- Scientific Studies: Last Week Tonight with John Oliver (HBO)

Test



2.1. Introducción y objetivos

En este tema se explica de forma resumida el **proceso de investigación científica**. Desde la explicación del propio método científico, de qué metodologías disponemos y cómo diseñamos experimentos. De esta forma, el alumno se puede basar en los conceptos aquí expuestos para el desarrollo de los trabajos a los que dé lugar este programa de estudio, sentando las bases de cuáles son los pasos que se debe seguir para investigar en inteligencia artificial.

2.2. La ciencia y su método

Un alumno que inicia un máster universitario puede tener varios objetivos, por ejemplo, aprender sobre un tema que le resulta de especial interés. Pero si el objetivo se queda en el mero interés, no estaremos aprovechando la formación que estamos recibiendo. Un objetivo más ambicioso sería capacitarle para aplicar estos conocimientos en la práctica. Cuando utilizamos las destrezas adquiridas es cuando realmente comprobamos si los conceptos y técnicas impartidas se han aprendido correctamente.

Esta asignatura versa sobre inteligencia artificial; en los próximos temas se entrará más en detalle en la explicación de ese concepto. Dado que la inteligencia artificial es un ámbito científico más, aquí nos centraremos en el concepto de ciencia y su método de trabajo.

La Real Academia Española (RAE) define ciencia como el «conjunto de conocimientos obtenidos mediante la observación y el razonamiento, sistemáticamente estructurados y de los que se deducen principios y leyes generales con capacidad predictiva y comprobables experimentalmente».

El estudio detenido de la propia definición proporcionada por la RAE nos permite extraer los puntos fundamentales a la hora de «hacer ciencia».

En primer lugar, **la ciencia tiene que ver con la obtención de conocimiento**. Los científicos buscan evolucionar el conocimiento humano. *Conocimiento* es radicalmente opuesto a *creencia*. El conocimiento implica constatación de verdad basándonos en la experimentación de determinadas hipótesis. Por el contrario, las creencias no implican demostración de ningún tipo.

Los métodos esenciales para la obtención de conocimiento son la **observación** y el **razonamiento**. Obtenemos conocimiento a través de una observación sistemática de

la naturaleza y el posterior razonamiento sobre ellos. En ocasiones, la capacidad de razonamiento humana es capaz de trabajar en escenarios donde no es posible en un momento concreto la observación del hecho. Por ejemplo, uno de los puntos fundamentales de la teoría de la relatividad de Einstein fue el de la existencia de las ondas gravitacionales. La predicción de Einstein tuvo que esperar hasta el año 2015 para que los modernos aparatos de los astrofísicos confirmaran mediante la observación el postulado del genio alemán.

Por último, la **repetitividad** permite verificar el resultado de los experimentos realizados. Ante una experimentación en la otra punta de mundo, si repetimos el experimento en nuestro laboratorio u ordenador, partiendo de exactamente las mismas condiciones iniciales deberíamos obtener el mismo resultado. Este proceso de revisión por pares es lo que asegura la calidad de la experimentación científica.

Método científico

El método científico establece los **pasos generales que nos permiten obtener conocimiento científico**. Aristóteles fue uno de los grandes impulsores del método científico. Grandes filósofos griegos, como Sócrates o Platón, también insistieron en la necesidad de disponer de métodos de razonamiento. Ibn al-Haytham, Johannes Kepler y el propio Galileo Galilei fueron otros actores fundamentales en el desarrollo de la metodología científica.

De forma muy básica, el método científico general podría resumirse en los siguientes pasos:




Figura 1. Pasos generales del método científico.

Si entramos en detalle, se contemplan diversas tipologías del método científico:

- ▶ Método lógico-deductivo.
- ▶ Método empírico-analítico.
- ▶ Método histórico.
- ▶ Etc.

El detalle de todas y cada una de ellas se explicará más adelante.

Algo absolutamente esencial en el método científico es la **pregunta**. Y aquí podemos enlazar fácilmente con el tema objeto de estudio en este máster. Dentro de la inteligencia artificial, lo esencial no es la tecnología ni la técnica, lo absolutamente esencial es la pregunta que nos planteamos como marco de trabajo. Algunos

ejemplos de preguntas potenciales pueden ser:

- ▶ ¿Puedo crear un sistema de reconocimiento de imágenes de radiodiagnóstico de un fémur que ayude a los médicos a determinar si el crecimiento de un niño es correcto para su edad?
- ▶ ¿Puedo crear un sistema que me indique si un cliente es candidato para solicitar una refinanciación de su deuda?
- ▶ ¿Puedo crear un sistema de inteligencia artificial que permita conducir un vehículo de forma autónoma?
- ▶ ¿Puedo crear un sistema que aprenda de forma autónoma a jugar a un juego?

Es la pregunta la que guía la investigación. Además, esta pregunta debe tener sentido. Es decir, debe haber un motivo por el cual nos la estamos haciendo. Si no lo hay o si ya está resuelto el problema, la investigación no tiene sentido realizarla. Por eso, **todos los trabajos deben estar motivados**. La motivación de un trabajo científico es la explicación de por qué creemos que es interesante dicho trabajo para que el conocimiento avance. Para ello debemos asegurarnos de que el problema que pretendemos resolver o el método que queremos describir tiene relevancia. Es decir, aporta algo a la ciencia en algún campo. Por ejemplo, mejora los resultados obtenidos hasta ese momento, es una nueva técnica que permite obtener mejores resultados o que enfoca el problema desde un punto de vista diferente, o hay un interés real por el problema en la sociedad o en la academia y otros autores han trabajado en temas relacionados.

2.3. Metodologías de investigación en inteligencia artificial

Los métodos de investigación son unas magníficas herramientas para la recolección de datos de investigación, así como para formular las preguntas de investigación que son claves para el proceso de investigación, como ya hemos comentado en el apartado anterior. Además, con estas metodologías también podemos extraer conclusiones en base a un análisis sistemático del tema a estudiar, así como de los resultados experimentales obtenidos.

El acceso a la información necesaria para llevar a cabo esta tarea requiere de una **búsqueda exhaustiva** en diferentes fuentes de documentación y de conocimiento de otros expertos humanos que la comparten.

Los diferentes métodos de investigación nos ayudan a delimitar el tipo de problema que pretendemos tratar y a elegir cuál es el mejor camino para resolverlo, en función del tipo de problema. Esto nos ayuda a la toma de decisiones en el proceso de investigación, minimizando los errores y acelerando este.

Podemos establecer **dos grandes tipos de métodos de investigación**: los métodos lógicos y los métodos empíricos.

Los métodos lógicos son aquellos que se basan en la utilización del pensamiento y su deducción para obtener resultados científicos, mientras que los empíricos buscan aproximar el conocimiento en base a la experiencia y las observaciones.

Métodos lógicos

Los métodos lógicos de la investigación científica **se centran en el método deductivo y el método inductivo**.

El **método deductivo** es un razonamiento que parte de axiomas o ideas preconcebidas o aceptadas como ciertas para llegar a unas conclusiones no conocidas. A este proceso se le llama inferencia. Es un **conocimiento inferido** a partir de otro conocimiento ya probado. Si la inferencia se produce en un único paso se la llama inferencia directa, si requiere de varios pasos se le llama inferencia indirecta.

- ▶ Ejemplo de inferencia directa: «Si te acostaste tarde anoche, hoy puedes tener sueño».
- ▶ Ejemplo de inferencia indirecta: «Los ingleses son puntuales. Churchill es inglés, por tanto, Churchill es puntual».

Sin embargo, el **método inductivo** intenta inferir de casos particulares para extraer leyes generales. Se dice que es una **inducción completa** si se puede enumerar todos los casos de estudio. En caso contrario, es una **inducción incompleta** si necesitamos recurrir a la toma de una muestra representativa que permita hacer la generalización. En estos casos basta con que un solo caso contradiga la afirmación, para que no sea válida.

El método inductivo es muy bueno para **generar hipótesis**. Una hipótesis se debe basar en la observación. Si se observa una característica que es común a varios individuos, podemos formular la hipótesis que esta característica se repite en todos los individuos del mismo tipo. Después esa hipótesis hay que validarla, bien con el método deductivo (construyendo una demostración lógica y formal que lo valide) o con la experimentación.

Métodos empíricos

Dentro de los métodos empíricos, el más usado es el **método experimental**. Para llevarlo a cabo se debe buscar una forma en la que demostrar una hipótesis previamente planteada, aunque a veces surge de forma espontánea buscando otra cosa. Pero lo normal es que **un experimento intente validar una hipótesis previa que se establece con base en la observación realizada**, y este experimento procure demostrar que dicha afirmación es correcta. Para ello, el experimento debe estar bien diseñado siguiendo los siguientes principios:

- ▶ Debe estar **controlado** para evitar injerencias externas al objeto de estudio.
- ▶ Debe **aislarse el estudio de factores que puedan añadir ruido** al objeto a investigar.
- ▶ Debe ser **reproducible** para que otros investigadores puedan comprobar que los resultados son correctos y no se ha llegado a una conclusión errónea.

En el método experimental **deben existir dos tipos de variables**, las variables dependientes que son consecuencia de las independientes. Y debemos asignar a cada tipo de variable las que vamos a tener en cuenta en el estudio. Lo importante para el método experimental es llegar a establecer relaciones causales que permitan la explicación de las variables. Para ello debemos tener en cuenta una serie de condiciones:

- ▶ Existe una correlación entre la variable independiente (causa) y la variable dependiente (efecto).
- ▶ La causa precede al efecto en el tiempo.

- ▶ No existen variables que incidan en el efecto observado que hagan que los resultados no sean concluyentes. Este último punto es el más difícil de conseguir.
- ▶ Debe haber una asignación de los individuos en los grupos de estudio de forma aleatoria.

Si no se consigue tener todas las variables controladas, estamos en un método **cuasiexperimental**.

El **diseño cuasiexperimental** también busca establecer una relación de causalidad entre la variable independiente y la dependiente, pero se aplica cuando no es posible la asignación aleatoria de los sujetos en el experimento. Se produce manipulación de la variable independiente y se da también algún control de la situación experimental y de las variables secundarias; pero no hay aleatorización en la asignación de los sujetos a los grupos experimental o de control. El método cuasiexperimental es de una mayor aplicabilidad en la investigación en el campo. Bajo esta condición podemos describir **tres tipos de métodos cuasiexperimentales**:

- ▶ **Métodos descriptivos:** su propósito es **describir la estructura y características de un objeto, situación, hecho o fenómeno a partir de algún modo de observación sistemática de este**, en algún momento de su existencia. La descripción se realiza en el ambiente natural, o lo más parecido posible a este, en el que se da o produce el fenómeno u objeto de estudio.
- ▶ **Métodos correlacionales:** **esos métodos estudian y analizan las relaciones existentes entre fenómenos tal y como se producen en la realidad**, no manipulando ningún tipo de variable. Aunque resulta evidente que la correlación no implica una causa, sí es cierto que la presencia de una relación entre variables puede, de alguna manera, sugerir relaciones causales entre ellas. Sobre todo, si

estas variables están relacionadas de forma lógica.

- **El metaanálisis:** es un **método para realizar síntesis cuantitativas de lo ya investigado**, establecer el estado de la cuestión y llegar, o intentar llegar, a una generalización sobre una hipótesis determinada. Podríamos decir que el metaanálisis es una investigación sobre investigaciones, que intenta integrar en un resultado único, los resultados de todas las investigaciones previas relacionadas con una determinada hipótesis.

En la inteligencia artificial se pueden dar **ambos modelos de estudios** de forma indistinta. Por ejemplo, si proponemos un nuevo algoritmo de aprendizaje, o una modificación de uno ya existente, este modelo puede probar su eficacia con base en experimentos de laboratorio en un *data set* ya testeado con otros modelos y comparando los resultados obtenidos. Sin embargo, si queremos evaluar un sistema de recomendación, necesitaremos un estudio de campo, ya que el sistema de recomendación debe ser evaluado por los usuarios para comprobar su inteligencia y la calidad de sus recomendaciones. Esta calidad es algo subjetivo y, por tanto, difícilmente medible sin un trabajo de campo. Aquí, además, es mucho más difícil aislar las variables y los posibles valores que puedan generar ruido en el experimento.

2.4. Metodología empírica cuantitativa

La metodología cuantitativa **parte normalmente de un cuerpo de conocimientos teóricos ya aceptados** como base para formular hipótesis sobre relaciones especiales entre variables que forman parte del problema que se está estudiando.

La aceptación de la hipótesis se realiza recolectando información cuantitativa de conceptos medibles que se derivan de los conceptos teóricos previamente dados como ciertos. A ese cuerpo de partida se le suele denominar **axiomas** y es muy importante que sean ciertos, ya que de su veracidad parte toda la investigación. El análisis de la información que se va adquiriendo debe ser lo suficientemente significativo como para aceptar la hipótesis o negarla.

El proceso que se sigue pues es, normalmente, el **hipotético-deductivo**.

Desde esta tradición empírico-analítica se considera que **el proceso de investigación sigue una serie de etapas** a través de las cuales el investigador realiza el proceso de investigación. Las **etapas** son las siguientes:




Figura 2. Etapas del proceso empírico-analítico.

Planteamiento del problema

La necesidad de resolver un problema se toma como punto de partida de la investigación, iniciándose con el planteamiento de este. Sin embargo, previamente, el problema objeto de estudio **tiene que reunir unas condiciones básicas** para que pueda considerarse científico, de tal forma que:

- ▶ Ha de explorar una relación entre dos o más variables.
- ▶ El problema debe formularse sin ambigüedad.
- ▶ Debe ser verificable empíricamente.

Formulación de las hipótesis

Una hipótesis se considera como una **respuesta conjetural al problema**, es decir, una solución tentativa al problema de investigación.

La **formulación de hipótesis** debe realizarse de un modo claro y preciso, de manera preferentemente enunciativa y teniendo en cuenta que implique no solo la existencia de relación entre dos o más variables medibles, sino el tipo de relación que pensamos que existe. Esa suposición es la que queremos aceptar.

Al conjunto de procedimientos que seguirá el investigador para contrastar las hipótesis se le denomina la **metodología**. El investigador debe elaborar un diseño o esquema de acción en el que se describa con detalle qué se debe hacer y cómo realizarlo. El investigador si no tiene la posibilidad de estudiar todos los casos, cosa muy habitual, debe realizar un muestreo e identificar cómo se han elegido los individuos que pertenecen a esa muestra, para hacerla representativa.

Para ello debemos seleccionar primero qué grupos van a participar en la muestra, y cómo vamos a asignar (bajo qué criterios) a un individuo en uno de esos grupos, siempre que no sea algo trivial (género, especie, etc.). También se debe elegir cómo vamos a tomar los datos de recogida (herramientas de medida, test, cuestionarios, escalas, etc.) y deben de ser lo más fiables posibles. Para ser cuantitativos los fenómenos a evaluar **deben poder ser representados con valores números**.

Análisis de datos

Es la organización de los datos de tal forma que permita al investigador dar respuesta al problema planteado y decidir si las hipótesis han sido confirmadas o rechazada. Se suele requerir algún tipo de análisis estadístico en el caso de que los datos se hayan obtenido a partir de una muestra.

Conclusiones

Las **conclusiones** son respuestas a los problemas planteados o decisiones acerca de mantener o no las hipótesis formuladas.

No solo han de aportarse las conclusiones, sino que además el investigador debe contextualizarlas en el marco de estudios previos, resaltando en qué medida son coincidentes o discrepan, cómo se integran en sistemas teóricos más amplios que permitan explicar los resultados obtenidos, o cómo contribuyen al cuerpo de conocimientos que ya existe sobre ese mismo problema. En definitiva, el investigador debe presentar su propia interpretación de los resultados.

Diseño de un experimento cuantitativo

La elaboración de un experimento **cuantitativo exige un cuidadoso trabajo de definición sobre las variables a contemplar que sea claro y preciso**. Por ejemplo, se han de tener en cuenta las siguientes recomendaciones:

- ▶ Establecer, de forma clara y precisa, las variables contempladas en el problema de investigación, es decir definir cuáles son las variables a estudiar.
- ▶ Examinar cuidadosamente la relación o relaciones de variables utilizadas en el estudio.
- ▶ Definir las variables, de forma detallada, tanto en lo conceptual, como en términos operacionales e instrumentales. Esto nos lleva a las siguientes interrogantes:
 - ¿Cómo se sustentan teórica y conceptualmente las variables del estudio?
 - ¿Cómo se realizarán las mediciones? ¿Cuáles serán los indicadores y qué instrumentos se emplearán?
- ▶ Garantizar la repetibilidad de los experimentos.
- ▶ Usar grupos de control que nos permita contrastar los resultados donde no se modifique la variable independiente.

Para finalizar, queremos enfatizar que el control y validez interna de los estudios con enfoque cuantitativo de investigación y, particularmente, los diseños experimentales, demandan un escrupuloso y aséptico manejo de los procedimientos de manipulación de variables como garantía de la pureza de la experimentación.

Ventajas y desventajas de la investigación cuantitativa

La investigación cuantitativa tiene una serie de ventajas sobre la cualitativa y viceversa. Vamos a resumir estas **ventajas y desventajas** en el siguiente cuadro resumen:

Ventajas y desventajas de la investigación cuantitativa			
Ventajas		Desventajas	
1	Permite medir datos concretos	1	El contexto del experimento es ignorado
2	El investigador es más objetivo	2	No estudia los fenómenos en su ambiente natural
3	Se pueden probar hipótesis en experimentos	3	Si se basa en estadística; la población seleccionada debe ser muy grande

Tabla 1. Ventajas y desventajas de la investigación cuantitativa. Fuente: elaboración propia.

Ejemplos de experimentos cuantitativos

Aquí tienes una serie de ejemplos de experimentos cuantitativos:

- ▶ Descubrir el porcentaje de almidón que posee cada alimento que consumimos, para determinar su índice glucémico (IG).
- ▶ Conocer el índice de inflación en una economía determinada, tomando como base porcentajes históricos de meses previos, los precios de los alimentos en las grandes cadenas de supermercados, etc.
- ▶ Conocer el porcentaje de obesos que vive en la región, teniendo en cuenta variables como la condición de salud, el sexo y la edad.
- ▶ Cuántos niños en una comunidad aún no tienen las vacunas indicadas para su edad.
- ▶ Se necesita saber la precisión que tiene nuestro nuevo algoritmo de *deep learning* para clasificar los tipos de clientes de una organización.

2.5. Metodología empírica cualitativa

La **investigación cualitativa** se interesa **por captar la realidad a través de los ojos de los sujetos de estudio**. Es decir, a partir de la percepción que dicho sujeto tiene en su propio contexto. El investigador induce las propiedades del problema que se va a estudiar en base a la forma en la que los individuos se desenvuelven en el mundo donde se plantea el problema a resolver (Bonilla y Rodríguez, 1997).

La investigación cualitativa se plantea, por un lado, qué observadores competentes y cualificados pueden informar con objetividad, claridad y precisión acerca de sus propias observaciones del mundo social, así como de las experiencias de los demás. Por otro, los investigadores se aproximan a un sujeto real, un individuo real que está presente en el mundo y que puede, en cierta medida, ofrecernos información sobre sus propias experiencias, opiniones, valores, etc. Por medio de un conjunto de técnicas o métodos como las entrevistas, las historias de vida, el estudio de caso o el análisis documental; el investigador puede añadir sus observaciones con las observaciones aportadas por los entrevistados.

Estas dos ideas han incitado a los investigadores cualitativos a buscar un método que les permitiera registrar sus propias observaciones de una forma adecuada, y que permitiera dejar al descubierto los significados que los sujetos ofrecen de sus propias experiencias. Este método confía en las expresiones subjetivas (escrita y verbal) de los significados dados por los propios sujetos estudiados. Así, el investigador cualitativo dispone de una ventana a través de la cual puede adentrarse en el interior de cada situación o sujeto.

En la Figura 3 podemos observar el proceso de investigación que planteamos (Rodríguez, Gil y García, 1999). A través de esta representación se intenta expresar el carácter continuo del mismo, con una serie de fases que no tienen un principio y final claramente delimitados, sino que se superponen y mezclan unas con otras, pero

siempre en un camino hacia delante en el intento de responder a las cuestiones planteadas en la investigación. Así, en este proceso se dan cuatro fases fundamentales:

- ▶ Preparatoria.
- ▶ Ejecutiva.
- ▶ Analítica.
- ▶ Conclusiva.



Figura 3. Fases de la investigación cualitativa. Fuente: Rodríguez, Gil y García, 1999.

Continuamente, a lo largo de todo el proceso de investigación, el investigador tendrá que ir tomando opciones entre las diferentes alternativas que se van presentando. Si hay algo común a los diferentes enfoques cualitativos, esto es el **continuo proceso de toma de decisiones** a las que se ve sometido el investigador.

Fase preparatoria

En esta fase inicial de la investigación **cualitativa podemos diferenciar dos grandes etapas: reflexiva y diseño**. En la primera etapa el investigador, tomando como base su propia formación investigadora, sus conocimientos y experiencias

sobre los fenómenos en estudio y, claro está, su propia ideología, intentará establecer el marco teórico-conceptual desde el que parte la investigación. La etapa de diseño se dedicará a la planificación de las actividades que se ejecutarán en las fases posteriores.

Fase de trabajo de campo

Hasta este momento del estudio, el investigador ha permanecido fuera del campo, o a lo sumo ha tenido algún contacto esporádico para recabar algún tipo de información que le era necesaria para iniciar una primera toma de contacto.

Si en la fase de preparación había que tener en cuenta la formación y experiencia del investigador, en este momento del estudio resulta de una importancia crucial algunas características de este, que permitirán el avance de la investigación.

A través de su habilidad, paciencia y visión, el investigador obtiene la información necesaria para producir un buen estudio cualitativo. Debe estar preparado para confiar en el escenario; ser paciente y esperar hasta que sea aceptado por los informantes, en definitiva, ser flexible y tener capacidad de adaptación.

Hay que ser conscientes de que existen muchas **maneras diferentes de obtener la información necesaria**.

- ▶ Es preciso **ser persistente**, ya que la investigación se hace paso a paso, los datos se contrastan una y otra vez, se verifican se comprueban, etc.; las dudas surgen y la confusión es preciso superarla.
- ▶ **Meticuloso**, cuidando cualquier detalle, sobre todo en lo que se refiere a la recogida de información y su archivo y organización.
- ▶ Debe tener una **buena preparación teórica** sobre el tópico objeto de estudio y sobre las bases teóricas y metodológicas de la ciencia que esté estudiando. En

nuestro caso, la inteligencia artificial.

Así pues, el investigador debe ser consciente de las metodologías y procesos que se llevan a cabo en el desarrollo de *software* basado en inteligencia artificial, sus peculiaridades y qué implicaciones tiene dentro de la investigación llevada a cabo.

Fase analítica

Aunque situamos esta fase tras la ejecutiva, en modo alguno queremos significar que **el proceso de análisis de la información recogida se inicia tras el abandono del escenario de estudio**. Al contrario, la necesidad de contar con una investigación con datos suficientes y adecuados exige que las tareas de análisis se inicien durante la etapa de recogida de datos. No obstante, por motivos didácticos la situamos como una fase posterior.

El análisis de datos cualitativos va a ser considerado aquí como un proceso realizado con un cierto grado de sistematización que, a veces, permanece implícita en las actuaciones emprendidas por el investigador.

En este sentido, resulta difícil hablar de una estrategia o procedimiento general de análisis de datos cualitativos, con la salvedad de lo que pueda inferirse a partir de las acciones identificadas en un análisis ya realizado. No obstante, tomando como base estas inferencias, **es posible establecer una serie de tareas u operaciones que constituyen el proceso analítico básico**, común a la mayoría de los estudios en que se trabaja con datos cualitativos. Estas **tareas** serían:

- ▶ Reducción de datos.
- ▶ Disposición y transformación de datos.

- Obtención de resultados y verificación de conclusiones.

Fase informativa

La culminación del proceso de investigación lo constituye la **presentación de los resultados**, a través del cual el investigador no solo llega a alcanzar una mayor comprensión del fenómeno objeto de estudio, sino que comparte esa comprensión con los demás. El informe cualitativo debe ser un argumento convincente presentando los datos sistemáticamente que apoyen el caso del investigador y acepte las explicaciones alternativas. Existen dos **formas fundamentales de escribir un informe**:

- Como si el lector estuviera resolviendo el puzle con el investigador.
- Ofrecer un resumen de los principales hallazgos y entonces presentar los resultados que apoyan las conclusiones.

Diseño de un experimento cualitativo

Al no estar sujeto a unas variables específicas como en el caso de la cuantitativa, el problema se va reformulando a la hora de realizar la investigación.

En el diseño experimental de este tipo de investigación, lo primero que debemos es **identificar a los sujetos de estudio**, ya que generalmente no se podrán conseguir muestras aleatorias y será el investigador el que los seleccione acorde con el propósito de la investigación.

Por otro lado, la **hipótesis** no va a surgir al inicio de la investigación, sino que irá cambiando. Así que es fundamental la capacidad de síntesis del investigador para

procesar toda esta información que se va a ir adquiriendo y darle una interpretación adecuada.

En cuanto a la **validación de los resultados**, al igual que pasa con la formulación del problema, es dinámica y continua. También estas conclusiones se deben ir reformulando a lo largo del proceso de investigación. Por ello, a veces es importante contrastar la opinión con otros grupos en foros de debate para tratar de contrastar la opinión con otros investigadores.

Los **procesos de recolección de datos** empleados en los estudios cualitativos normalmente no se basan en métodos estandarizados y es muy probable que el análisis no pueda ser estadístico o que este tenga poco peso, debido a que se centra en los puntos de vista de los diferentes individuos que forman parte del estudio. De hecho, para centrarse más en las experiencias de los sujetos, las muestras suelen ser pequeñas. Por lo tanto, usan principalmente el **método inductivo**, como explicamos al principio de tema.

Las **principales técnicas** que se utilizan en la investigación cualitativa son:

- ▶ Entrevistas abiertas.
- ▶ Observación no estructurada.
- ▶ Revisión de documentos.
- ▶ Discusiones en grupo.
- ▶ Evaluación de experiencias.

Ventajas y desventajas de la investigación cualitativa

La investigación cualitativa tiene una serie de ventajas sobre la cuantitativa y viceversa. Vamos a resumir estas ventajas y desventajas en el siguiente cuadro resumen:

Ventajas y desventajas de la investigación cualitativa			
Ventajas		Desventajas	
1	Útil en etapas tempranas de un estudio	1	Investigador muy involucrado, con lo cual pierde objetividad
2	No necesita un plan estrictamente diseñado, lo que da libertad al investigador	2	El investigador es clave en la interpretación
3	Información más detallada	3	Consume mucho tiempo
4	Observa el contexto de los sujetos de estudio		

Tabla 2. Ventajas y desventajas de la investigación cualitativa. Fuente: elaboración propia.

Ejemplos de investigación cualitativa

A continuación, describimos algunos ejemplos de investigaciones cualitativas:

- ▶ En antropología, este método permite analizar qué dice, cómo se comporta o cómo piensa un grupo étnico.
- ▶ En el mundo del trabajo se puede medir y valorar al personal y los colaboradores de una empresa, así como valorar nuevos candidatos.
- ▶ En psicología se utilizan valoraciones cualitativas para medir distintos fenómenos como la empatía, el desempeño en sociedad o el bienestar.
- ▶ En el ámbito de la educación, se puede estudiar la composición de una clase y así

permitir que los docentes adapten su didáctica a las características específicas del grupo.

- ▶ Podemos evaluar un sistema recomendador en función de las opiniones de los usuarios.

2.6. Referencias bibliográficas

Bernal, I. (2012). *El repositorio institucional*. UNED: e-Spacio.

Klingner, J. K., Scanlon, D. y Pressley, M. (2005). How to publish in scholarly journals. *Educational researcher*, 34(8), 14-20.

Scientific Papers

Ramesh, V., Glass, R. L., y Vessey, I. (2004). *Research in computer science: an empirical study*. *Journal of systems and software*, 70(1-2), 165-176. Recuperado de <https://www.sciencedirect.com/science/article/abs/pii/S0164121203000153>

Este artículo se examina el estado de la investigación en ciencias de la computación, abordando cuestiones como qué temas abordan los investigadores, qué enfoques y métodos de investigación utilizan y de qué disciplinas de referencia depende la investigación.

Uso ético de la información y sus citas bibliográficas

UNED. (23 de marzo de 2017). *Uso ético de la información y sus citas bibliográficas*.
2.uned.es. Recuperado de:
http://www2.uned.es/biblioteca/tutorial_uso_etico/citas_bibliograficas.htm

En el siguiente enlace a la página de UNED se muestra una introducción al sistema de citas bibliográficas incluyendo ejemplos variados.

Scientific Studies: Last Week Tonight with John Oliver (HBO)

LastWeekTonight. (9 de mayo de 2016). *Scientific Studies: Last Week Tonight with John Oliver* [Video]. Recuperado de: <https://www.youtube.com/watch?v=0Rnq1NpHdmw>

El presentador y cómico John Oliver presenta su punto de vista en clave de humor sobre ciertos estudios científicos que considera falsos o incompletos.

1. Es un elemento esencial de la ciencia:
 - A. El empleo de la tecnología, porque asegura que la investigación se hace según los últimos medios.
 - B. La repetitividad, porque permite comprobar los resultados obtenidos.
 - C. La geografía, porque la forma de hacer ciencia está condicionada por el ámbito geográfico.
 - D. El coste de la experimentación, porque en un entorno de crisis es algo para tener en cuenta.

2. El método científico tiene las siguientes fases:
 - A. Observación, documentación, experimentación y conclusiones.
 - B. Observación, hipótesis, experimentación y conclusiones.
 - C. Hipótesis, documentación, experimentación y análisis.
 - D. Ninguna de las anteriores.

3. La metodología cuantitativa es:
 - A. Mide la precisión de las magnitudes que se pueden representar numéricamente.
 - B. Se interesa por captar la realidad a través de los ojos de los sujetos de estudio. Es decir, a partir de la percepción que dicho sujeto tiene en su propio contexto.
 - C. Su propósito de describir la estructura y características de un objeto, situación, hecho o fenómeno a partir de algún modo de observación sistemática de este.
 - D. Parte de un cuerpo de conocimientos teóricos ya aceptados para formular hipótesis sobre relaciones especiales entre variables que forman parte del problema que se está estudiando.

4. Los métodos lógicos:
 - A. Se centran en el método cuantitativo y cualitativo.
 - B. Se centran en el método deductivo y el método inductivo.
 - C. Los más usados son el método experimental y el cuasiexperimental.
 - D. Ninguno de los anteriores.

5. La metodología cualitativa tiene las siguientes partes:
 - A. Preparatoria, hipótesis, experimentación y analítica.
 - B. Preparatoria, ejecutiva, analítica, conclusiva.
 - C. Observación, hipótesis, experimentación y conclusiones.
 - D. Análisis, diseño, implementación y pruebas.

6. La hipótesis:
 - A. Se extrae a base de las conclusiones del experimento.
 - B. Se considera como una respuesta conjetural al problema, es decir, una solución tentativa al problema de investigación.
 - C. No es necesario que sea aceptada experimentalmente.
 - D. Es clave en la metodología cualitativa.

7. Las conclusiones en la metodología cuantitativa:
 - A. Permiten definir si una investigación tiene aplicabilidad o no.
 - B. No dicen nada sobre la veracidad o falsedad de la hipótesis inicial.
 - C. Pretenden analizar los resultados experimentales.
 - D. Son respuestas a los problemas planteados o decisiones acerca de mantener o no las hipótesis formuladas.

8. Las principales técnicas que se utilizan en la investigación cualitativa son:
- A. Entrevistas abiertas, observación no estructurada, revisión de documentos, discusiones en grupo, evaluación de experiencias.
 - B. Entrevistas abiertas, medición de resultados, revisión de documentos, evaluación de expertos.
 - C. Entrevistas cerradas, test, medición de resultados, discusiones en grupo, evaluación de experiencias.
 - D. Ninguna de las anteriores.
9. Diseño de un experimento cuantitativo se debe:
- A. Diseñar las entrevistas previamente.
 - B. Establecer, de forma clara y precisa, las variables contempladas en el problema de investigación, es decir definir cuáles son las variables para estudiar.
 - C. Que el investigador se involucre dentro del ambiente a investigar.
 - D. Ninguna de las anteriores.
10. La validación de los experimentos cualitativos:
- A. Es dinámica y continua.
 - B. Debe realizarse desde un punto de vista objetivo al final del proceso de investigación.
 - C. Debe decidir si la hipótesis es correcta o no.
 - D. Es resultado de la evaluación empírica de los experimentos.

Tema 4 – Publicación de resultados y redacción científica

En la sesión anterior...


► Semana 4

- Métodos de financiación.
- Elaboración de una propuesta.
- Gestión económica del proyecto.



Problema:

¿Cómo construir un artículo científico?



De qué vamos a hablar hoy...

► Tema 4

- Publicación científica
 - **Revistas:** Índice de impacto (JCR), tipos de revisiones...
 - **Congresos**
 - **Proceso:** desde selección de revista hasta publicación
 - **Redacción científica**

 **frontiers**
in Neuroscience

 **PLOS** | ONE

J C R
Journal of Consumer Research

JMR JOURNAL OF MARKETING RESEARCH

IJIMAI
journal

JAIR *Journal of
Artificial Intelligence
Research*

Volume 10, Number 1, May 2002
ISSN 1089-7763
APPLIED INTELLIGENCE
The International Journal of
Research on Intelligent Systems
for Real-World Complex Problems
Editor-in-Chief
Maurice H.
Emergent

¿Cómo estudiar este tema?



- Proceso publicación científica
- Revistas y congresos
- Redacción científica

Ciclo de las publicaciones científicas

¿Por qué publicar?



- Aportación al **avance del conocimiento**
- **Validación ante comunidad científica**
- Principal **medida del trabajo de investigación**
- Evolución **carrera profesional**


¿Qué es un artículo científico?

- ▶ Es una publicación especializada en la que:
 - **Se plantean y justifican** los objetivos
 - Se describe el **estado del arte** que ya existe sobre el tema
 - Se comparten:
 - Los datos que se emplean.
 - Los experimentos
 - Se discuten los resultados.
 - Se plantean conclusiones.
 - Formas de mejorar (trabajos futuros)
 - Describe la **metodología** que se siguió para hacer la investigación.

¿Qué es un artículo científico?

► Ejemplo de artículo de revista



- <http://jmlr.org/papers/volume15/srivastava14a/srivastava14a.pdf>



¿Qué es un artículo científico?

► Ejemplo de artículo de revista

— <https://link.springer.com/article/10.1007/s10489-021-02613-x>



Ciclo de las publicaciones científicas

- ▶ Los artículos se publican en revistas científicas
- ▶ Por lo tanto, **la actividad científica se mide**
 - Algunos criterios: número trabajos publicados significativos, número de citas recibidas...
- ▶ En consecuencia, es relevante escoger las revistas científicas donde publicar

Impacto bibliográfico

Relevancia de una revista

Impacto bibliográfico

- ▶ ¿Qué son las publicaciones con impacto?
- ▶ Relevancia de la revista: índice o factor de impacto JCR (Journal Citation Report)
 - Medida de la calidad científica para evaluar las revistas académicas
 - No mide la calidad de los artículos sino la revista en la que se publica
- ▶ ¿Cómo se calcula?
 - Mide el impacto de una revista en función de las citas recibidas por los artículos publicados y recogidos en la Web of Science (WOS)
 - Web of Science: plataforma que recoge las principales publicaciones científicas de cualquier disciplina del conocimiento
 - Índice de calidad relativo (rankings) actualizable anualmente

Impacto bibliográfico

- ▶ JCR
- ▶ SCImago Journal & Country Rank (SJR)
- ▶ LATINDEX
- ▶ IN-RECS
- ▶ IN-RECJ
- ▶ ...

Citas e impacto


¿Qué hace que un artículo sea bueno?

La cita como métrica del impacto

- ▶ ¿Cómo medir la calidad de un trabajo?
 - Habitualmente, por el prestigio del sitio donde se publica.
 - Idealmente, por número de citas que recibe, pero es un reto medirlo.
- ▶ ¿Y de un investigador?
 - Habitualmente, por el número de JCRs.
 - Idealmente, por el agregado de citas de sus artículos.

La cita como métrica del impacto

► El número h (h -index)



El proceso de publicación científica

Tipos de artículos académicos

► En revistas científicas

- Se publican periódicamente
- Normalmente para público especializado
 - Excepciones: Science y Nature
- No se suele adquirir individualmente, sino a nivel institucional

► ¿Y cuánto cuesta?

- Modelo tradicional: gratis para el autor, se paga por leer.
- Modelo open-access: paga el autor, lectura gratuita.
- Modelo doble open-access: no paga “nadie”

► ¿Y el autor nunca cobra? 😞

Tipos de artículos académicos

► En congresos científicos

- Se celebran en un momento dado (anualmente es lo normal)
- Suelen ser más específicos que las conferencias
- Los artículos seleccionados se presentan públicamente y se discuten
- El congreso puede publicar sus actas o depender de una editorial para hacerlo

► ¿Y cuánto cuesta?

- Casi siempre, se cubren los costes de publicación con las inscripciones al congreso

► ¿Y el autor nunca cobra? 😞

Tipos de artículos académicos

- ▶ **Números especiales en revistas**
 - Revistas que dedican un número a una temática concreta
- ▶ **Libros académicos**
 - Puede ser un libro completo o un único capítulo
 - Los libros “editados” son en realidad un conjunto de capítulos hechos por distintos autores, con un editor que coordina
- ▶ ¿Y el autor nunca cobra? 😞

Workflow publicación científica

Workflow completo

► Pasos a seguir



1. Identificación del sitio donde vamos a publicar
2. Redacción del artículo siguiendo las orientaciones y formatos de la revista / congreso / editorial
3. Envío para consideración
4. Revisión por pares
5. Modificaciones al artículo
6. Revisión por pares
7. Aceptación
8. Proceso editorial
9. Publicación

Workflow de una publicación

► Revisión por pares (peer review):

- Proceso de revisión y validación del trabajo científico.
- Se denomina así porque la revisión es realizada por investigadores expertos en el tema al igual que el creador.

► Distintos tipos

- Revisión doble ciego:
 - Revisores y autores son anónimos.
 - Difícil autor se mantenga anónimo en áreas pequeñas
- Revisión simple ciego:
 - Sólo los revisores son anónimos.
- Abierto:
 - Tanto revisores como autores son públicos

Búsqueda de información

- ▶ Tema
- ▶ Tiempo o espacio geográfico específico
- ▶ Propósito investigación
- ▶ Tipo información
- ▶ Disponibilidad y costes fuentes de información

Búsqueda de información

► Tesis Doctorales:

– <https://www.educacion.gob.es/teseo/irGestionarConsulta.do>

► Google Scholar

– <https://scholar.google.es/>

Google Académico

● Cualquier idioma ○ Buscar sólo páginas en español

Artículos sobre COVID-19

CDC NEJM JAMA Lancet Cell BMJ
Nature Science Elsevier Oxford Wiley medRxiv

A hombros de gigantes

► OpenDOAR

– <http://www.opendoar.org/>

► Web of Science, Scopus...

The screenshot shows the Microsoft Academic homepage. At the top, it says "Microsoft Academic" and "Research more, search less". Below this is a search bar with the placeholder text "Search any topic, author, journal, etc. or any combination of these". To the right of the search bar, there is a sidebar titled "Explore Entity Analytics" which displays several statistics: 247,389,875 Publications, 261,445,825 Authors, 743,427 Topics, 4,523 Conferences, 48,974 Journals, and 25,811 Institutes. At the bottom of the page, there is a section titled "Unleash the Power of Semantic Search" and a small disclaimer about data usage.

Estilo

La forma ayuda a entender el fondo

Estilo redacción científica

Principios redacción científica

Comparison of Clustering Algorithms for Learning Analytics with Educational Datasets

Alvaro Martínez Navarro¹, Pablo Moreno-Ger² *

¹ Departamento de Ingeniería de Sistemas, Universidad Mariana, Pasto (Colombia)

² Escuela Superior de Ingeniería y Tecnología, Universidad Internacional de La Rioja, Logroño (España)

Received 3 November 2017 | Accepted 22 January 2018 | Published 9 February 2018



ABSTRACT

Learning Analytics is becoming a key tool for the analysis and improvement of digital education processes, and its potential benefit grows with the size of the student cohorts generating data. In the context of Open Education, the potentially massive student cohorts and the global audience represent a great opportunity for significant analyses and breakthroughs in the field of learning analytics. However, these potentially huge datasets require proper analysis techniques, and different algorithms, tools and approaches may perform better in this specific context. In this work, we compare different clustering algorithms using an educational dataset. We start by identifying the most relevant algorithms in Learning Analytics and benchmark them to determine, according to internal validation and stability measurements, which algorithms perform better. We analyzed seven algorithms, and determined that K-means and PAM were the best performers among partition algorithms, and DIANA was the best performer among hierarchical algorithms.

KEYWORDS

Clustering Methods,
Computer Languages,
Data Analysis,
Engineering Students,
Performance Evaluation,
Unsupervised Learning.

DOI: 10.9781/ijimai.2018.02.003

1. INTRODUCTION

SINCE the turn of the Century, researchers have been studying clustering methods and comparing them from different perspectives. These algorithms were the core of an emerging data mining discipline, which would soon explode along with the popularity of big data approaches in all fields. And when these ideas were applied to digital education, the field of Learning Analytics was born.

But the core of these approaches is still the use of adequate clustering algorithms for each scenario, and this problem has received a fair share of attention. Berkhin contrasted theoretically different algorithms [1], and indicated how to perform the most typical evaluations, data preparation and measurements. In [2], the authors studied 216 articles written between 2000 and 2011, classifying the literature in three

author proposed specific analysis methods, and also studied the performance impact of different perturbations. In [6] the authors compared five grouping algorithms and used four different supervised automatic learning algorithms to analyze their performance. In [7] three algorithms were measured with four cluster validation indexes, using synthetic and real datasets. Other relevant works have conducted formal tests to determine the most appropriate data mining algorithms for specific fields such as classification [8] or text mining from RSS sources [9]. However, few experimental studies focused on analyzing performance using specifically educational datasets.

In turn, Learning Analytics (LA) research ranges from theoretical essays on the potential impact of LA in education [10] to very focused studies on how it is useful for establishing personalized feedback to improve academic performance [11]. There are also works proposing

1. Precisión
2. Claridad
3. Brevedad
4. Formalidad

<https://www.ijimai.org/journal/node/2111>

Estilo redacción científica

► Precisión

“El método 1 distribuye mejor los resultados que el método 2” ❌

- ¿Qué significar distribuir? Obtener, ordenar...
- ¿Qué significa mejor? Más rápidamente, uniformemente, menor error...

► Claridad

- El texto se lee y se entiende rápidamente. Oraciones bien construidas y cada párrafo desarrolla su tema siguiendo un orden lógico

Estilo redacción científica

► Brevedad

“Los resultados relacionados con la dispersión y la personalización en cada campaña de marketing estudiada nos permiten afirmar, de una manera general, que éstos no han presentado diferencias significativas...”



“La dispersión y la personalización no variaron en las campañas de marketing estudiadas”



► Formalidad

- “Tomamos un montón de muestras”
- “El método 1 converge a toda prisa”



Estilo redacción científica

► Otros aspectos a considerar




- Sintaxis
- Puntuación deficiente
- Faltas ortográficas
- Redundancia
- Vocabulario rebuscado
- Longitud de oraciones y párrafos
- Lenguaje informal...

Estructura

Todo en su sitio

Estructura artículo científico

- ▶ Introducción
- ▶ Motivación
- ▶ Estado del arte
- ▶ Marco Teórico
- ▶ Metodología experimental empleada
- ▶ Resultado de los experimentos
- ▶ Conclusiones
- ▶ Trabajos futuros
- ▶ Referencias



Estructura artículo científico

- ▶ Los descubrimientos científicos se comparten con la comunidad mediante artículos.
 - Se realizan artículos científicos donde:
 - **Se justifican** los objetivos
 - Se describe el **estado del arte** que ya existe sobre el tema
 - Se describe la **metodología** que se siguió para hacer la investigación.
 - Los datos que se emplean.
 - Los experimentos
 - Se discuten los resultados.
 - Se plantean conclusiones.
 - Formas de mejorar (trabajos futuros)

Estructura artículo científico

Comparison of Clustering Algorithms for Learning Analytics with Educational Datasets

Alvaro Martínez Navarro¹, Pablo Moreno-Ger² *

¹ Departamento de Ingeniería de Sistemas, Universidad Mariana, Pasto (Colombia)

² Escuela Superior de Ingeniería y Tecnología, Universidad Internacional de La Rioja, Logroño (España)

Received 3 November 2017 | Accepted 22 January 2018 | Published 9 February 2018

unir
LA UNIVERSIDAD
EN INTERNET

ABSTRACT

Learning Analytics is becoming a key tool for the analysis and improvement of digital education processes, and its potential benefit grows with the size of the student cohorts generating data. In the context of Open Education, the potentially massive student cohorts and the global audience represent a great opportunity for significant analyses and breakthroughs in the field of learning analytics. However, these potentially huge datasets require proper analysis techniques, and different algorithms, tools and approaches may perform better in this specific context. In this work, we compare different clustering algorithms using an educational dataset. We start by identifying the most relevant algorithms in Learning Analytics and benchmark them to determine, according to internal validation and stability measurements, which algorithms perform better. We analyzed seven algorithms, and determined that K-means and PAM were the best performers among partition algorithms, and DIANA was the best performer among hierarchical algorithms.

KEYWORDS

Clustering Methods,
Computer Languages,
Data Analysis,
Engineering Students,
Performance Evaluation,
Unsupervised Learning.

DOI: 10.9781/ijimai.2018.02.003

1. INTRODUCTION

SINCE the turn of the Century, researchers have been studying clustering methods and comparing them from different perspectives. These algorithms were the core of an emerging data mining discipline, which would soon explode along with the popularity of big data approaches in all fields. And when these ideas were applied to digital education, the field of Learning Analytics was born.

But the core of these approaches is still the use of adequate clustering algorithms for each scenario, and this problem has received a fair share of attention. Berkhin contrasted theoretically different algorithms [1], and indicated how to perform the most typical evaluations, data preparation and measurements. In [2], the authors studied 216 articles written between 2000 and 2011, classifying the literature in three

author proposed specific analysis methods, and also studied the performance impact of different perturbations. In [6] the authors compared five grouping algorithms and used four different supervised automatic learning algorithms to analyze their performance. In [7] three algorithms were measured with four cluster validation indexes, using synthetic and real datasets. Other relevant works have conducted formal tests to determine the most appropriate data mining algorithms for specific fields such as classification [8] or text mining from RSS sources [9]. However, few experimental studies focused on analyzing performance using specifically educational datasets.

In turn, Learning Analytics (LA) research ranges from theoretical essays on the potential impact of LA in education [10] to very focused studies on how it is useful for establishing personalized feedback to improve academic performance [11]. There are also works proposing

Título

Autores

Institución donde se
realizó la investigación

Resumen

Introducción

Estructura artículo científico

trivial burdens on the data mining algorithms applied to make sense of how students are interacting with these open materials.

At the crossroads of these lines of research, our goal is to contribute experimental validation of the performance of different clustering techniques when specifically applied to educational datasets, thus providing a more solid foundation for further works focusing on practical aspects rather than back-office performance.

To achieve this goal, we have conducted a practical experiment using a real-world dataset provided by Universidad Mariana in Colombia, benchmarking different algorithms and configurations in terms of internal validations and stability measurements.

II. MATERIALS AND METHODS

The experimental design is quite straightforward. We started with a literature review to select a representative set of clustering algorithms. Then, we organized a workflow for testing each algorithm and selected specific measurements for comparison, and finally we applied this workflow to all algorithms targeting an educational dataset provided by Universidad Mariana. This section details each of these steps.

A. Selecting the Algorithms to Be Benchmarked

The specific selection of algorithms was conducted after performing a literature review, with a heavy influence of related works from other fields ([1], [4], [16]) and trying to provide a wide perspective of the potential approaches.

The final selection of algorithms is summarized in Table I.

B. Experimental Platform

We employed different platforms and tools to create our experimental pipeline. We started with raw and cross-referenced data available on an Oracle 10g database server. We extracted different listings and used Microsoft Excel to review, perform basic cleaning (including anonymization) and saving as CSV (comma-separated values) files.

All statistical analyses and clustering algorithms were applied using the opensource platform R, for which we created our test scripts using the R Studio graphical interface. The platform was also used to create the different visualizations that helped in this study and that

TABLE I. ALGORITHM SELECTION

NAME	Description
------	-------------

are included in this article. In Table II we provide a summary of the different libraries that we used for the experiment.

C. Benchmarking Performance

In order to benchmark the performance of each algorithm, we focused on the facilities provided by the *clValid* library presented in [19] to measure internal and stability validations.

Internal validations are computed using intrinsic information from the datasets to assess the quality of the resulting clusters. We used the three main internal validation measurements offered by the validation library: *connectivity* (which provides a value in the $[0, \infty)$ range where lower is better), *silhouette width* (which proves values in the $(-1, 1)$ range where higher is better), and *Dunn index* (which provides a value in the $[0, \infty)$ range where higher is better).

In terms of stability measurement, we again selected the main measures from [19], all of them focused on inspecting each cluster and sequentially removing internal columns and checking whether the cluster remains valid. We employed APN (average proportion of non-overlap), AD (average distance between measurements), ADM (average distance between means) and FOM (figure of merit, focused on the average intra-cluster variance of the observations). All of them take values in the $[0, \infty)$ range where higher is better except APN, with values in the $[0, 1]$ range with preferred results close to zero.

TABLE II. R LIBRARIES

Library	Description
cluster	It allows clustering analysis by implementing hierarchical and partition algorithms. Details in: https://cran.r-project.org/web/packages/cluster/index.html
ggplot2	It builds visualizations using the information of the data meaning. Details in: https://cran.r-project.org/web/packages/ggplot2/index.html
factoextra	It offers different easy-to-use functions to extract and visualize the results of multivariate analyzes, it simplifies clustering analysis and its graphical representations. Details in: https://cran.r-project.org/web/packages/factoextra/index.html
readr	It provides fast and friendly mechanisms to read files in csv, tsv and fwf formats. Details in: https://cran.r-project.org/web/packages/readr/index.html
	It provides color schemes to be used with various types of

Material y métodos

Responde a la pregunta “cómo se ha hecho el estudio”

Descripción del diseño de la investigación

Explicación de cómo se llevó a la práctica, justificando la elección de métodos y técnicas de forma tal que el lector pueda repetir el estudio

Estructura artículo científico

III. RESULTS

A. Pre-processing

The first step in our test pipeline was the conduction of relatively simple cleanup tasks, mostly focused on removing instances where some grades were missing (this may happen either due to an administrative issue or an error in the grade reporting system).

After this step, we analyzed for each variable different comparison statistics, averaging their maximum, minimum, average and mean values. We determined that their standard deviation and variances were minimal, therefore making it possible to work directly with the original data without requiring a previous normalization.

We also analyzed the dataset to validate its clusterability, using two approaches: first, we used the *Hopkins statistic* method from [20], with a resulting value of 0.2036606 (<0.5) which shows that the values are potentially groupable. We also validated this notion visually, by representing the tendency of the data to be grouped. This is achieved by (1) calculating the dissimilarities between all datapoints and storing them in a dissimilarity matrix according to their Euclidean distances, (2) sorting the matrix so that similar objects are closer together and (3) displaying the matrix to check the presence of high values along the diagonal of the matrix (Fig. 1).




Fig. 1. Data clustering trend where we can observe dark blue rectangles aligned with the diagonal line, which can be interpreted as a potential clustering amenability of the data.

Number of clusters k

Fig. 2. Optimal K presented by the gap statistic.

Given this partially unsatisfactory result, we also looked at the nbClust R package, which analyses 30 separate indexes to determine the optimal K. We ran this analysis for values of K in the [2,10] range, with full clustering and all indexes included. As observed in Fig. 3, this yielded an optimal number of clusters of K=3.




Fig. 3. Optimal K reported by nbClust.

C. Algorithm Execution with Optimal K Value

All seven algorithms were run on the data using K=3 in order to study their behavior and performance.

Regarding the set of partition algorithms, Fig. 4a shows the dispersion and cluster charts produce by the K-means, CLARA and PAM algorithms (all three produced the same output), while Fig. 4b shows the results for the FANNY algorithm, which displayed a significantly worse performance.

These results were validated through a silhouette inspection, which measures the adequacy of each observation for each cluster representing the average distance between groups. Fig. 5 shows the results of these inspections. The K-means, CLARA and PAM algorithms yielded an average silhouette width of 0.55 while the FANNY algorithm yielded 0.29. This indicates a good result for the first three algorithms, while the FANNY algorithm even had a cluster with negative average width, representing a large number of incorrectly assigned instances.

Resultados

Presentar resultados del estudio mencionando los hallazgos relevantes (incluso los contrarios a la hipótesis), incluyendo detalles suficientes para justificar las conclusiones

Estructura artículo científico

	Method	APN	ADM	FOM	AD
pam	Silhouette	0.5549	0.2151	0.2301	0.2435
	Connectivity	5.7167	58.4603	75.7325	76.1421
	Dunn	0.3721	0.0485	0.0485	0.0781
	Silhouette	0.5549	0.2168	0.2262	0.2345
fanny	Connectivity	NA	NA	NA	NA
	Dunn	NA	NA	NA	NA
	Silhouette	NA	NA	NA	NA
	Connectivity	NA	NA	NA	NA
hierarchical	Silhouette	8.6151	11.9484	13.7079	16.6579
	Connectivity	0.3883	0.3883	0.4338	0.4338
	Dunn	0.5450	0.5377	0.5513	0.5524
	Silhouette	8.6151	11.9484	13.7079	16.6579
agnes	Connectivity	0.3883	0.3883	0.4338	0.4338
	Dunn	0.5450	0.5377	0.5513	0.5524
	Silhouette	8.6151	10.3746	28.6325	31.9659
	Connectivity	0.3883	0.4338	0.1209	0.1466
diana	Dunn	0.5450	0.5586	0.4156	0.4083
	Silhouette	0.5450	0.5586	0.4156	0.4083
	Silhouette	0.5450	0.5586	0.4156	0.4083
	Silhouette	0.5450	0.5586	0.4156	0.4083

optimal scores:

Score	Method	Clusters
5.7167	kmeans	3
0.4338	hierarchical	5
0.5586	diana	4

Fig. 10. Internal validation scores for all algorithms.

Clustering Methods:
kmeans clara pam fanny hierarchical agnes diana

Cluster sizes:
3 4 5 6

validation Measures:

	3	4	5	6
--	---	---	---	---

kmeans	APN	0.0350	0.1462	0.0524	0.0345
	AD	2.4473	2.4391	2.2072	2.0718
	ADM	0.2036	0.5720	0.4537	0.3029
	FOM	0.6958	0.6866	0.6907	0.6690
clara	APN	0.0758	0.1308	0.1661	0.1674
	AD	2.4425	2.1941	2.0620	1.9967
	ADM	0.2482	0.3520	0.4425	0.5323
	FOM	0.6917	0.6630	0.6674	0.6680
pam	APN	0.0476	0.1499	0.1706	0.2969
	AD	2.4014	2.2172	2.0254	1.9934
	ADM	0.1323	0.4477	0.3421	0.5667
	FOM	0.6957	0.6676	0.6585	0.6578
fanny	APN	NA	NA	NA	NA
	AD	NA	NA	NA	NA
	ADM	NA	NA	NA	NA
	FOM	NA	NA	NA	NA
hierarchical	APN	0.0187	0.0525	0.0049	0.0071
	AD	2.7104	2.6614	2.2709	2.2316
	ADM	0.1080	0.2569	0.1111	0.1171
	FOM	0.7016	0.6912	0.6787	0.6715
agnes	APN	0.0187	0.0525	0.0049	0.0071
	AD	2.7104	2.6614	2.2709	2.2316
	ADM	0.1080	0.2569	0.1111	0.1171
	FOM	0.7016	0.6912	0.6787	0.6715
diana	APN	0.0350	0.0265	0.0176	0.0161
	AD	2.7106	2.3175	2.2031	2.0415
	ADM	0.1729	0.1330	0.4379	0.1834
	FOM	0.7015	0.6873	0.6765	0.6598

optimal scores:

Score	Method	Clusters
0.0049	hierarchical	5
1.9934	pam	6
0.1080	hierarchical	3
0.6578	pam	6

Fig. 11. Stability scores for all algorithms.

IV. DISCUSSION

One of the most relevant (although reasonably expected) observations is that no algorithm is a clear and obvious winner across all measurements and potential K values.

In terms of internal validation, K-means, CLARA and PAM achieved the best overall scores with K=3, although CLARA and PAM experienced a worst degradation as the K value increased. However, the hierarchical and AGENS algorithms also achieve very significant Dunn scores when K=4.

If we focus on K=3 (our selected optimal value), the worst performers in connectivity were the three hierarchical algorithms, although they achieved better Dunn index scores. However, they also presented more incorrect assignments, and therefore can be considered worst performers overall.

However, as we increased the K value, partition algorithms degraded their performance quickly, while hierarchical algorithms remained more stable and actually improved some scores.

In terms of stability, again there is no single algorithm that achieves the best score in all four measurements. PAM exhibited good AP and FOM behavior at K=6, hierarchical achieved very good APN with K=5 and very good ADM with K=3.

Again, if we focus on K=3, the worst performer in terms of APN and ADM was CLARA, while DIANA and AGNES performed poorly in AD and FOM respectively.

The pattern of degradation as we increased the K value exhibited by partition algorithms was also apparent when looking at stability measurements, yielding a consistent conclusion of the better behavior of hierarchical algorithms for higher number of clusters.

The FANNY algorithm failed to produce significant clusters and was therefore deemed as poorly fit for our specific dataset.

V. CONCLUSION AND FUTURE WORKS

Open education is bound to push the boundaries of how we analyze our educational datasets. And as the scope of our research actions Learning Analytics becomes more and more specialized, the specific underlying techniques, including the selection of a particular clustering algorithm, are bound to receive less attention than appropriate.

This study aims to provide researchers with insights into how the different algorithms exhibit different performance patterns depending on specific measurements and variation in K values, especially when the dataset is highly driven by a set of grades in different courses.

This is achieved through a detailed and highly practical experiment,

Discusión

Se discuten los resultados logrados mediante los experimentos y las observaciones realizadas. Comparar o contrastar resultados obtenidos con otros estudios para extraer similitudes, mejoras o diferencias

Conclusiones y trabajo futuro

Establecer conclusiones infiriendo o deduciendo una verdad, respondiendo a la pregunta de investigación planteada en la introducción

Recomendaciones evolución trabajo investigación

Estructura artículo científico

REFERENCES

- [1] P. Berkhin, "A Survey of Clustering Data Mining Techniques", *Grouping Multidimensional Data*. Springer, no. c, pp. 25–71, 2006.
- [2] S. H. Liao, P. H. Chu, and P. Y. Hsiao, "Data mining techniques and applications - A decade review from 2000 to 2011", *Expert Systems with Applications*, vol. 39, no. 12, pp. 11303–11311, 2012.
- [3] Q. Hen, "A Review of Clustering Algorithms as Applied in IR", *Technical Report IUI/CLIS--1999/6+IRG*, pp. 1–33, 1999.
- [4] G. Sreenivasulu, S. V. Raju, and N. S. Rao, "Review of Clustering Techniques", *Proceedings of the International Conference on Data Engineering and Communication Technology Advances in Intelligent Systems and Computing* 468, pp. 523–535, 2017.
- [5] G. W. Milligan and M. C. Cooper, "Methodology Review: Clustering Methods", *Applied Psychological Measurement*, vol. 11, no. 4, pp. 329–354, 1987.
- [6] L. Candillier, I. Tellier, F. Torre, and O. Bousquet, "Cascade evaluation of clustering algorithm", *Springer Verlag. 17th European conference on machine learning*, pp. 574–581, 2010.
- [7] U. Maulik and S. Bandyopadhyay, "Performance evaluation of some clustering algorithms and validity indices", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 24, no. 12, pp. 1650–1654, 2002.
- [8] N. Settouti, M. Bechar, and M. Chikh, "Statistical Comparisons of the Top 10 Algorithms in Data Mining for Classification Task", *International Journal Of Interactive Multimedia And Artificial Intelligence*, vol. 4, no. 1, pp. 46–51, 2016.
- [9] A. M. Jalil, I. Hafidi and L. Alami, "Comparative Study of Clustering Algorithms in Text Mining Context", *International Journal Of Interactive Multimedia And Artificial Intelligence*, vol. 3, no. 7, pp. 42–45, 2016.
- [10] K. Swan, "Learning Analytics and the Shape of Things To Come", *The Quarterly Review of Distance Education*, vol. 17, no. 3, pp. 5–12, 2016.
- [11] Q. Nguyen, D. T. Tempelaar, B. Rienties, and G. Bas, "What learning analytics-based prediction models tell us about feedback preferences of students", *The Quarterly Review of Distance Education*, vol. 17, no. 3, pp. 13–33, 2016.
- [12] S. De Freitas *et al.*, "Foundations of dynamic learning analytics: Using university student data to increase retention", *British Journal of Educational Technology*, vol. 46, no. 6, pp. 1175–1188, 2015.
- [13] O. J. Oyelade, O. O. Oladipupo, and I. C. Obagbuwa, "Application of k Means Clustering algorithm for prediction of Students' Academic Performance", *International Journal of Computer Science and Information Security*, vol. 7, no. 1, pp. 292–295, 2010.
- [14] J. A. Reyes, "The Skinny on Big Data in Education: Learning analytics simplified", *TechTrends*, vol. 59, no. 2, pp. 75–80, 2015.
- [15] R. Klamma, "Community Learning Analytics – Challenges and Opportunities", *Advances in Web-Based Learning – ICWL 2013. Lecture Notes in Computer Science*, vol. 8117, pp. 204–208, 2013.

Bibliografía

El nivel de actualización del artículo científico se determina atendiendo a la bibliografía consultada y que se encuentra en los últimos 3-5 años de publicación

Citas y bibliografía

Citar mucho y bien

Citas académicas

► Referencias específicas a trabajos concretos

- No es una “bibliografía orientativa”
- Todo lo citado en el texto sale en las referencias, y todas las referencias se citan en el texto.

► Referencias académicas

- Solamente fuentes relevantes: revistas, congresos, libros técnicos, informes oficiales, normativas.
- Evitar: blogs, comentarios, artículos periodísticos, etc.

¿Y eso no es un lío...?

Pues sí...


Gestores bibliográficos

► ¿Qué son?

- Permiten gestionar las referencias de vuestro trabajo.


► Mendeley

- <https://www.mendeley.com/>



► RefWorks

- <https://www.refworks.com/es>



Mendeley

Mendeley Desktop

File Edit View Tools Help

Add Folders Related Sync Help

Search...

Ismael 15

Mendeley Literature Search

My Library

- All Documents
- Recently Added
- Recently Read
- Favorites
- My Publications
- Unsorted
- Create Folder...

Groups

- Create Group...

Trash

- All Deleted Documents

Filter by Authors

- All
- Aamodt, Agnar
- Aaron Canary, Jeet Shroff
- Abbas-Yadkori, Yasin
- Alha, David W
- Almeida, Marcos Silvano Orita
- Angali, Brenna D
- Asada, Minoru
- Avery, Benjamin
- Avery, Phillip
- B. W. Silverman, M C Jones
- Baskerville, Richard
- Baumgarten, Robin
- Beatty, Joy
- Beattie, Mike
- Bentley, Jon Louis
- Blum, Avrim L
- Bonet, J S De
- Botea, Adi
- Bourg, David M
- Braun, Heinrich
- Brennan, Karen
- Browning, Brett
- Buchanan, John
- Butz, Martin V
- Calvert, Tom
- Cardamone, Luigi
- Caroline, Chopinaud

All Documents

★	●	Authors	Title	Year	Published In	Added
☆	●	Floyd, Michael W; Efsandiari, Babak; Lam, Kevin	A Case-Based Reasoning Approach to Imitating RoboCup Players	2008	Proceedings of the Twenty-First International Florida Artificial Inte...	8:23
☆	●	Hu, Danying; Gong, Yuansheng; Hannaford, Blake; Seibel, Eric J	Semi-autonomous simulated brain tumor ablation with ravenii surgical robot using behavior tree	2015	Robotics and Automation (ICRA), 2015 IEEE International Conferen...	8:23
☆	●	van Otterlo, Martijn; Wiering, Marco	Reinforcement learning and markov decision processes	2012	Reinforcement Learning	8:23
☆	●	Mitchell, Melanie	An introduction to genetic algorithms	1998		8:23
☆	●	Gonzalez-Perez, Cesar; Henderson-Sellers, Brian; Dromey, Geoff	A metamodel for the behavior trees modelling technique	2005	Information Technology and Applications, ICITA 2005.	8:23
☆	●	Colledanchise, Michele; Ögren, Petter	How Behavior Trees Modularize Hybrid Control Systems and Generalize Sequential Behavior Compositions, the Subsumption Architecture, and Decision Trees	2016	IEEE Transactions on Robotics	8:23
☆	●	Blum, Avrim L; Langley, Pat	Selection of relevant features and examples in machine learning	1997	Artificial Intelligence	8:23
☆	●	Quinlan, J Ross	Simplifying decision trees	1987	International journal of man-machine studies	8:23
☆	●	Match, Damián Jorge	Redes Neuronales: Conceptos básicos y aplicaciones	2001	Cátedra de Informática Aplicada a la Ingeniería(\)ja de Procesos-O...	8:23
☆	●	Hall, Mark A; Holmes, Geoffrey	Benchmarking attribute selection techniques for discrete class data mining	2003	IEEE Transactions on Knowledge and Data engineering	8:23
☆	●	Powers, David Martin	Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation	2011	Journal of Machine Learning Technologies	8:23
☆	●	Koutonen, Jussi; Leppänen, Mauri	How Are Agile Methods and Practices Deployed in Video Game Development? (A) Survey into Finnish Game Studios	2013	International Conference on Agile Software Development	8:23
☆	●	Cordone, Rachel	Unreal Development Kit Game Programming with UnrealScript: Beginner's Guide	2011		8:23
☆	●	Wiegens, Karl; Beatty, Joy	Software requirements	2013		8:23
☆	●	Kelly Jr, James D; Davis, Lawrence	Hybridizing the Genetic Algorithm and the (K-Nearest Neighbors) Classification Algorithm.	1991	ICGA	8:23
☆	●	Wirfs-Brock, Rebecca; Wilkerson, Brian	Object-oriented design: A responsibility-driven approach	1989	ACM SIGPLAN Notices	8:23
☆	●	Yannakakis, Georgios N	Game (AI) revisited	2012	Proceedings of the 9th conference on Computing Frontiers	8:23
☆	●	Yao, Xin	Evolving artificial neural networks	1999	Proceedings of the IEEE	8:23
☆	●	Mizuguchi, Mark; Buchanan, John; Calvert, Tom	Data driven motion transitions for interactive games	2001	Eurographics 2001 - Short Presentations	8:23
☆	●	Pomerleau, Dean A	ALVINN, an autonomous land vehicle in a neural network	1989		8:23
☆	●	Bourg, David M; Seemann, Glenn	AI for game developers	2004		8:23
☆	●	Klodner, Janet	Case-based reasoning	2014		8:23
☆	●	Ontañón, Santiago; Montaña, José L; Gonzalez, Avelino J	A Dynamic-Bayesian Network framework for modeling and evaluating learning from observation	2014	Expert Systems with Applications	8:23
☆	●	Wilson, David; Lane, H Chad	Proceedings of the Twenty-First International Florida Artificial Intelligence Research Society Conference, May 15-17, 2008, Coconut Grove, Florida, (USA)	2008		8:23
☆	●	Ontanon, Santiago	Case acquisition strategies for case-based reasoning in real-time strategy games	2012	Twenty-Fifth International FLAIRS Conference	8:23
☆	●	Ontañón, Santi; Mishra, Kinshuk; Sugandh, Nehar Ram, Ashvin	On-Line Case-Based Planning	2010	Computational Intelligence	8:23

Details Notes Contents

Type: Journal Article

Redes Neuronales: Conceptos básicos y aplicaciones

Authors: D. Match

 View research catalog entry for this paper

Journal: Cátedra de Informática Aplicada a la Ingeniería(\)ja de Procesos-Orientaci...

Year: 2001

Volume:

Issue:

Pages:

Abstract:

Tags:

Author Keywords:

Citation Key: match2001redes

Type of Work: article

URL: Add URL...

Catalog IDs

ArXiv ID:

DOI:

PMID:

Files: Add File...

Other Settings

☐ Unpublished work - exclude from Mendeley Web catalog

Citas

► Cómo obtener citas en Google Scholar:

A fast and elitist multiobjective **genetic algorithm**: NSGA-II

[K Deb](#), [A Pratap](#), [S Agarwal](#)... - [IEEE transactions on ...](#), 2002 - [ieeexplore.ieee.org](#)

Multi-objective evolutionary algorithms (MOEAs) that use non-dominated sorting and sharing have been criticized mainly for: (1) their $O(MN/\sup 3/l)$ computational complexity (where M is the number of objectives and N is the population size); (2) their non-elitism ...

☆  Citado por 26301 Artículos relacionados Las 20 versiones

 Citar

APA Deb, K., Pratap, A., Agarwal, S., & Meyerivan, T. A. M. T. (2002). A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE transactions on evolutionary computation*, 6(2), 182-197.

ISO 690 DEB, Kalyanmoy, et al. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE transactions on evolutionary computation*, 2002, vol. 6, no 2, p. 182-197.

MLA Deb, Kalyanmoy, et al. "A fast and elitist multiobjective genetic algorithm: NSGA-II." *IEEE transactions on evolutionary computation* 6.2 (2002): 182-197.

[BibTeX](#) [EndNote](#) [RefMan](#) [RefWorks](#)

Editores de textos científicos

Bienvenidos a LaTeX

¿Por qué LaTeX?

- ▶ Simplifica la gestión de referencias
 - BibTeX para formatear la bibliografía.
- ▶ Potente lenguaje de expresiones matemáticas
- ▶ Plantillas disponibles en la inmensa mayoría de revistas y congresos.

Instalando LaTeX

► Descargar LaTeX

- <https://www.latex-project.org/get/>
 - Windows MikTeX
 - Mac MacTeX
 - Linux Ubuntu/debian apt.


► Recomendable editor

- TexStudio: <https://www.texstudio.org/>

► Edición online y colaborativa:

- <https://www.overleaf.com/>

Ejemplo de artículo en LaTeX (sin compilar):



Ejemplo de artículo en Latex (Compilado):

The screenshot displays the TeXstudio interface with the file `C:\Users\ismael\Documents\unir\Investigacion_IA_nueva\Tema3\elsarticle-template\elsarticle-template.tex` open. The left sidebar shows the document structure, including sections like `BIBLIOGRAFIA`, `The Elsevier article class`, `Front matter`, `Bibliography styles`, and `References`. The main editor shows the LaTeX source code, which includes author information, affiliations, and the start of the abstract and keyword sections. The right pane shows the compiled PDF output, which features the Elsevier logo, the title "Elsevier LATEX template*", and the abstract text. The status bar at the bottom indicates the current page is 1 of 3, with a zoom level of 92%.

```
% Group authors per affiliation:
\author{Elsevier\fnref{myfootnote}}
\address{Radarweg 29, Amsterdam}
\fnref{myfootnote}{Since 1880.}

% or include affiliations in footnotes:
\author[mymainaddress,mysecondaryaddress]{Elsevier, Inc}
\ead[url]{www.elsevier.com}

\author[mysecondaryaddress]{Global Customer
Service\corref{mycorrespondingauthor}}
\cortext{mycorrespondingauthor}{Corresponding author}
\ead{support@elsevier.com}

\address[mymainaddress]{1600 John F Kennedy Boulevard,
Philadelphia}
\address[mysecondaryaddress]{360 Park Avenue South, New York}

\begin{abstract}
This template helps you to create a properly formatted \LaTeX\
manuscript.
\end{abstract}

\begin{keyword}
\texttt{elsarticle.cls}\sep \LaTeX\sep Elsevier \sep template
MSC[2010] 00-01\sep 99-00
\end{keyword}

\end{frontmatter}
```

Elsevier LATEX template*

Elsevier¹
Radarweg 29, Amsterdam
Elsevier Inc^{a,b}, Global Customer Service^{a,*}
^a1600 John F Kennedy Boulevard, Philadelphia
^b360 Park Avenue South, New York

Abstract

This template helps you to create a properly formatted LATEX manuscript.

Keywords: elsarticle.cls, LATEX, Elsevier, template
2010 MSC: 00-01, 99-00

1. The Elsevier article class

Installation. If the document class `elsarticle` is not available on your computer, you can download and install the system package `texlive-publishers` (Linux) or install the LATEX package `elsarticle` using the package manager of your T_EX installation, which is typically T_EX Live or MikT_EX.

Usage. Once the package is properly installed, you can use the document class `elsarticle` to create a manuscript. Please make sure that your manuscript follows the guidelines in the Guide for Authors of the relevant journal. It is not necessary to typeset your manuscript in exactly the same way as an article, unless you are submitting to a camera-ready copy (CRC) journal.

Página 1 de 3 92%
es_ES UTF-8 Listo Automático


Redes sociales científicas

Mantener contacto con comunidad investigadora

Redes sociales científicas

► ResearchGate

— <https://www.researchgate.net/>



► Academia

— <https://www.academia.edu>

ACADEMIA

LOG IN

Join 147,314,144 Academics and Researchers

Academia is the easiest way to share papers with millions of people across the world for free. A [study](#) published in *PLOS ONE* found that papers uploaded to Academia receive a 69% boost in citations over 5 years.



GOOGLE SIGN UP



FACEBOOK SIGN UP

Don't have Google or Facebook? Sign Up with Email



[About](#) [Press](#) [Blog](#) [People](#) [Papers](#) [Job Board](#) [Advertise](#) [We're Hiring!](#) [Help Center](#)

Find new research papers in: [Physics](#) [Chemistry](#) [Biology](#) [Health Sciences](#) [Ecology](#) [Earth Sciences](#) [Cognitive Science](#) [Mathematics](#) [Computer Science](#)

[Terms](#) [Privacy](#) [Copyright](#) Academia ©2021

Otros sitios relevantes

► ORCID

— <https://orcid.org/>

The screenshot shows the ORCID iD profile for Pablo Moreno-Ger. The profile includes the ORCID iD (0000-0003-4817-8150), a list of email addresses (pablo.moreno@unir.net, pablom@fdi.ucm.es), and a list of affiliations (Universidad Internacional de La Rioja (UNIR), Logroño, ES). The profile also shows a list of activities (Empleo (2)) and a list of publications (2017-03-13 hasta la fecha | Vicedean for Academic Affairs (Escuela Superior de Ingeniería y Tecnología)).

► Publons (Web of Science)

— <https://publons.com/>

The screenshot shows the Private dashboard - Summary for Pablo Moreno-Ger on Publons (Web of Science). The dashboard includes a sidebar with navigation links (Me, Dashboard summary, My records, Activity, Community, Settings) and a main content area with four tiles: Track my citations, Manage my reviews, See my profile, and Export my Publons CV. Below the tiles, there are sections for Recent notifications (Your review contributions in Web of Science) and Web of Science Author Impact Beamplot (Full Career).

Cerrando

Resumen

- ▶ Hoy nos hemos centrado en los resultados de la producción científica...
- ▶ ... la publicación de artículos científicos...
- ▶ ... y qué sucede antes de ver un artículo publicado
- ▶ ... y en el estilo y la estructura de un artículo científico

Para la próxima semana

► Bloque 2. Gestión de Proyectos

- Gestión de proyectos de inteligencia artificial: enfoque metodológico

¿Dudas?





www.unir.net

Investigación y Gestión de Proyectos en Inteligencia
Artificial

Tema 8. Investigación en agentes inteligentes y sistemas expertos

Índice

Esquema

Ideas clave

- 8.1. Introducción y objetivos
- 8.2. Introducción a los agentes inteligentes
- 8.3. Comportamiento y entorno de los agentes inteligentes
- 8.4. Estructura de los agentes inteligentes
- 8.5. Proyectos de investigación en agentes inteligentes
- 8.6. ¿Qué son los sistemas expertos?
- 8.7. Proyectos de investigación en sistemas expertos
- 8.8. Referencias bibliográficas

A fondo

- Mastering the game of Go with deep neural networks and tree search
- Expert Systems

Test



8.1. Introducción y objetivos

En este tema se explica a alto nivel el **concepto y la estructura general de los agentes inteligentes y los sistemas expertos**. Estos conceptos forman parte de los fundamentos básicos de la inteligencia artificial y, de una forma u otra, deben considerarse a la hora de diseñar una solución basada en esta disciplina.

De forma detallada, los **objetivos** que persigue esta unidad son:

- ▶ Ser capaz de definir las **peculiaridades** de un agente inteligente.
- ▶ Identificar las **aplicaciones** de los agentes inteligentes.
- ▶ Conocer los fundamentos de diseño y estructura de los agentes inteligentes.
- ▶ Conocer los **conceptos clave** de los sistemas expertos.
- ▶ Identificar qué **proyectos son más adecuados** para los sistemas expertos.

8.2. Introducción a los agentes inteligentes

En temas anteriores se ha discutido el significado de inteligencia y comportamiento racional. Todos estos contenidos previos deben tenerse en mente a la hora abordar el presente tema.

Un agente es un ente que recibe información del entorno y actúa en consecuencia. Se espera de él que actúe de forma inteligente.

Un ejemplo de actuación inteligente es la que está orientada a la **maximización de un objetivo** previamente establecido usando toda la información disponible en ese momento. Por ejemplo, si el objetivo es la supervivencia, una acción inteligente sería escapar u ocultarnos de un depredador.

De forma abstracta, un agente es una función que convierte las percepciones en acciones.

$f: P^* \rightarrow A$

P^* : indica un conjunto de percepciones finito.

A : indica la acción que llevamos a cabo en función de dichas percepciones.

Los agentes son muy útiles para modelar entornos complejos donde las acciones que lleven a cabo unos agentes puedan afectar a movimientos posteriores de otros entes. Se recibe información de un entorno y las propias acciones que los agentes llevan a cabo insertan nueva información en dicho entorno.




Figura 1. Un agente y su entorno. Fuente: Russell, 2004.

Ilustraremos estos conceptos mediante un sencillo ejemplo práctico. Supongamos que hemos creado un robot aspirador. Hemos hecho un gran trabajo y, por tanto, nuestro robot puede considerarse un buen ejemplo de agente inteligente. ¿Cómo actuaría este robot aspirador? Resumiendo, la función asociada al agente (que estaría ejecutándose de forma continua mientras el robot estuviese encendido) podría ser como la que sigue (Russell, 2004):

```
function Reflex-Vacuum-Agent([location,status]) returns an action
```

```
if status = Dirty then return Suck
```

```
else if location = Right then return Right
```

```
else if location = Left then return Left
```

Explicado de forma sencilla, el robot dispone de un sensor que, dentro de un radio de acción, le indica que hay algún tipo de residuo o suciedad por recoger. Si así fuese, el mismo sensor le proporciona la localización

concreta donde actuar. Si está a su derecha, el robot toma la decisión de moverse a la derecha. Una vez posicionado en el punto concreto, activa el aspirador. Tras ejecutar estas acciones, el entorno de partida ha cambiado, el residuo o resto de basura ha desaparecido y, por tanto, la información asociada a dicho entorno no es la misma que al inicio.

Como podemos esperar, sacar al mercado un robot aspirador implica crear un producto más completo del aquí reflejado. No obstante, la dinámica del procedimiento es común a todos los agentes inteligentes, todos tienen en cuenta la información que proporciona el entorno para, en función de una configuración previa, llevar a cabo una serie de acciones que permite maximizar el objetivo inicial planteado.

8.3. Comportamiento y entorno de los agentes inteligentes

Para diseñar un agente inteligente **debemos especificar de antemano el entorno en el que se va a ejecutar la tarea**. Esto implica definir **cómo se va a evaluar si la tarea se está realizando correctamente**, qué información se recoge del entorno, cuáles son las posibles acciones y qué tipo de sensores vamos a emplear. Todo ello constituye lo que se llama el **entorno de trabajo**, para cuya denominación se utiliza el acrónimo **REAS** (rendimiento, entorno, actuadores/acciones, sensores).

Por ejemplo, supongamos que queremos diseñar ahora un coche autónomo. Podríamos trabajar con la siguiente descripción de elementos:

- ▶ **Indicadores de rendimiento:** número de kilómetros recorridos, número de infracciones de tráfico cometidas, número de accidentes, valoración media (o mediana) de la comodidad del viaje por parte de los ocupantes del vehículo, número de situaciones de riesgo detectadas, coste del sistema, etc.
- ▶ **Entorno:** calles de la ciudad, señales, otros vehículos, peatones, etc.
- ▶ **Acciones posibles:** arrancar, parar, frenar, acelerar, girar, cambiar marcha, etc.
- ▶ **Sensores:** velocímetros, frenos, GPS, cámaras de vídeo, etc.

A la hora de diseñar el agente se debe tener en especial **consideración las características del entorno**. Por ejemplo, **no es lo mismo un entorno totalmente observable y una lógica de secuencias simple como puede ser la planteada para aspirar una habitación**, que un entorno más estocástico e incluso con fenómenos no

directamente observables **como pueden ser los mercados financieros**. En este último caso y en el ejemplo concreto del diseño de un agente inteligente para llevar a cabo operaciones bursátiles automatizadas, es probable que no se disponga del detalle de todas las acciones llevadas a cabo por todos los agentes. Podríamos llegar a percibir las consecuencias de alguna acción concreta sin tener totalmente claro a quién asociar la acción raíz.

Propiedades de los entornos de trabajo

Los agentes inteligentes se emplean en entornos muy variados y diversos. Aun así, es posible identificar un número de dimensiones concretas en las que categorizar estos entornos. Estas dimensiones influyen de manera crítica en el diseño del agente. Las dimensiones que podemos considerar son las siguientes:

Totalmente observable vs. parcialmente observable

Diremos que el entorno de trabajo es totalmente observable si los sensores del agente le proporcionan información sobre todos los aspectos relevantes para la toma de decisiones. En otro caso, el entorno de trabajo es parcialmente observable. Un entorno puede ser parcialmente observable debido al ruido y a la existencia de sensores poco exactos o porque los sensores no reciben información de parte del sistema. Por ejemplo, en un sistema de inversión bursátil automatizado hay que tomar decisiones sin tener visión de qué están plateando o ejecutando otros actores en ese mismo momento.

Determinista vs. estocástico

Un entorno de trabajo es **determinista cuando el siguiente estado del entorno está totalmente determinado por el estado actual y la acción ejecutada por el agente**. En otro caso, hablamos de un entorno estocástico. Un entorno estocástico añade incertidumbre a la toma de decisiones. Por ejemplo, y en el caso de uso de un coche autónomo, el entorno es claramente estocástico, ya que en cualquier momento

puede aparecer una avería, pinchazo o peatón inoportuno que altere el rumbo de los acontecimientos.

Secuencial vs. episódico

En un entorno **secuencial las acciones realizadas en el corto plazo pueden afectar a largo plazo**. Un ejemplo claro es el motor inteligente de un juego de ajedrez. Un mal movimiento puede dar al traste con una partida, aunque el jaque mate no llegue de manera inmediata. Por el contrario, **en un entorno de trabajo episódico, las acciones a realizar en el siguiente episodio no dependen de las acciones que se realizaron en episodios previos**. Por ejemplo, un robot ubicado en una cadena de montaje puede tener el objetivo de detectar piezas defectuosas y sacarlas del ciclo de fabricación. En este caso no se tiene en cuenta las piezas descartadas con anterioridad ni tampoco lo que se haga con esas piezas en el futuro. Los entornos episódicos son más simples puesto que no requieren el estudio de ciertas dependencias entre las acciones que se llevan a cabo.

Estático vs. dinámico

En un entorno de trabajo dinámico, el entorno puede cambiar mientras el agente está analizando la situación para decidir qué acción tomar. En otro caso, el entorno es estático. En el caso del coche autónomo, el entorno es dinámico puesto que todos los vehículos y peatones se están moviendo mientras el robot decide qué es lo próximo que debe hacer.

Discreto vs. continuo

Un entorno de trabajo discreto tiene un número finito de estados distintos, aunque este número sea muy elevado. Esta situación se da en juegos como el ajedrez, que poseen un elevadísimo número de combinaciones, pero aun así finito. Por el contrario, el recurrido caso del coche autónomo sería un ejemplo de entorno de trabajo continuo, puesto que la velocidad y ubicación de los coches y peatones

tienen un rango de valores continuos a los que hay que unir parámetros varios como ángulos de giro, inclinación de la carretera, etc.

Agente individual vs. multiagente

Un entorno de trabajo donde un único agente trata de resolver un determinado problema sin interactuar con otros entes inteligentes sería un ejemplo de entorno de trabajo con agente individual. Por el contrario, entornos de trabajo como el ajedrez, donde dos agentes compiten entre sí o como el caso de uso del coche autónomo, donde varios agentes inteligentes tienen que convivir, serían ejemplos de entorno de trabajo multiagente.

Encontraremos el caso más complejo ante un entorno de trabajo que sea parcialmente observable, estocástico, secuencial, dinámico, continuo y multiagente. Realmente, este caso extremo suele ser uno de los más frecuentes.

La tabla siguiente muestra la clasificación de algunos ejemplos de uso según la tipología del entorno de trabajo (Russell, 2004). Todos los casos se refieren a un agente inteligente realizando la labor referenciada, ya puede ser jugar a un determinado juego, conducir un taxi (robotizado) o enseñar inglés.

Entorno de trabajo	Observable	Determinista/estocástico	Secuencial/episódico	Estático/dinámico	Discreto/continuo	Individual/multiagente
Crucigrama	Totalmente	Determinista	Secuencial	Estático	Discreto	Individual
Ajedrez	Totalmente	Determinista	Secuencial	Semi	Discreto	Multi
Póker	Parcialmente	Determinista	Secuencial	Estático	Discreto	Multi
Backgammon	Totalmente	Estocástico	Secuencial	Estático	Discreto	Multi
Taxi autónomo	Parcialmente	Estocástico	Secuencial	Dinámico	Continuo	Multi
Diagnóstico médico	Parcialmente	Estocástico	Secuencial	Dinámico	Continuo	Individual
Análisis de imagen	Totalmente	Determinista	Episódico	Semi	Continuo	Individual
Robot clasificador	Parcialmente	Estocástico	Episódico	Dinámico	Continuo	Individual
Tutor interactivo de inglés	Parcialmente	Estocástico	Secuencial	Dinámico	Discreto	Multi

Tabla 1. Ejemplos de entorno de trabajo y sus características. Fuente: Russell, 2004, p. 50.

8.4. Estructura de los agentes inteligentes

Un agente se compone de **arquitectura más software**. Por arquitectura entendemos el conjunto de sensores físicos, unidades de procesamiento y todo tipo de dispositivo que permite al agente comunicarse con el entorno y desencadenar acciones. El *software* recoge las instrucciones que guían el comportamiento del agente.

Podemos generalizar los distintos tipos de agentes inteligentes en **cuatro grandes categorías de complejidad creciente**. Esto significa que agentes categorizados en capas de mayor complejidad podrían ser capaces de realizar tipologías de tareas asociadas a agentes más simples, pero no al revés.

En primer lugar, encontramos a los **agentes reactivos simples**. Estos agentes reaccionan ante un estímulo o información de entorno externo y actúan en función de un conjunto de reglas o instrucciones previamente estipuladas. Toda la información previa o histórica es descartada. Por ejemplo, supongamos que los sensores de un robot aspirador informan de que justo en la ubicación actual hay unas migas de pan. El robot pasaría a succionar la suciedad sin plantearse nada más.




Figura 2. Agente reactivo simple. Fuente: Russel, 2004, p. 54.

Estos agentes se encuentran bastante limitados, puesto que solo se puede tomar la decisión correcta si el entorno es totalmente observable.

Una evolución más completa de estos agentes son los **agentes reactivos basados en modelos**. Estos agentes incorporan el histórico de información a la toma de decisiones. La historia previa se refleja en un determinado estado interno del agente, por lo que ya no solo se considera la información proveniente del entorno, sino que además debo tener en cuenta el estado en el que se encuentra el agente. Por ejemplo, imaginemos un videojuego de acción donde en un momento dado están disparando a nuestro personaje. El nivel de salud del personaje podría bajar o, por el contrario, podría mantenerse estático si nos encontramos en un estado «protegido» porque previamente hemos capturado algún tipo de objeto que ha creado un escudo protector. El estado del juego sería capaz de representar este amplio abanico de situaciones y entender cómo funciona su mundo particular. Y para entender su mundo necesita representar dicho conocimiento de manera formal, ya sea mediante un sistema de reglas, transacciones de estados, circuitos *booleanos* o ecuaciones matemáticas. Esa representación es lo que conocemos como modelo. Un agente que

utilice este tipo de modelos es un agente basado en modelos.




Figura 3. Agente reactivo basado en modelos. Fuente: Russell, 2004, p. 56.

Los agentes inteligentes como los anteriores hacen que sea posible determinar de antemano un conjunto de reglas de condición-acción. Por ejemplo, si los sensores del vehículo autónomo detectan que el coche de delante frena, se debe iniciar la frenada. Si los sensores del robot aspirador detectan suciedad a la derecha, el robot debe desplazarse a la derecha.

En muchas ocasiones no se dispone del conocimiento necesario para poder construir este conjunto de reglas, por lo que se establece un objetivo a conseguir. Un objetivo o meta podría ser, por ejemplo, llegar a un destino concreto. Hablaremos en este caso de **agentes basados en objetivos**.

Agentes basados en objetivos y función de utilidad

La Figura 4 muestra la arquitectura general de un agente basado en objetivos.




Figura 4. Agente basado en objetivos. Fuente: Russell, 2004, p. 57.

Este tipo de agentes son más flexibles, puesto que el objetivo que les guía obliga a representar explícitamente el conocimiento que soporta su decisión. Pero también son más complejos (dependiendo del objetivo planteado). Por ejemplo, el objetivo puede llegar con el coche a una determinada ubicación. Este tipo de tareas obliga a realizar una búsqueda de las distintas soluciones posibles y planificar un itinerario.

Los agentes basados en objetivos no permiten satisfacer nuestras necesidades en un gran número de ocasiones. Podemos pedir al navegador del GPS de nuestro vehículo que nos lleve a una ciudad concreta, pero nos sentiremos tremendamente defraudados y enfadados si nos damos cuenta de que nos está haciendo dar un rodeo innecesario o nos lleva por caminos poco transitables. Nos gustaría considerar no solo la meta a conseguir sino también en qué condiciones se debe alcanzar dicha meta para que consideremos plenamente satisfactoria la solución planteada por el algoritmo. Factores como llegar en el mínimo tiempo posible, recoger la mínima distancia posible, evitar peajes, etc., nos aporta valor sobre la utilidad de la solución.

Los agentes basados en utilidad incorporan una función de utilidad al modelo de tal

forma que es posible medir la satisfacción de los usuarios con la solución. Esta función de utilidad suele contemplarse como una **función matemática a maximizar o minimizar**. Por ejemplo, y como se ha comentado antes, se puede minimizar la distancia recorrida, minimizar el gasto en combustible, minimizar el tiempo invertido. Debemos notar que, matemáticamente hablando, un problema de maximización es similar a un problema de minimización, puesto que el $\max\{f(x)\}$ es igual al $\min\{-f(x)\}$.




Figura 5. Agente basado en función de utilidad. Fuente: Russell, 2004, p. 59.

Se considera que un agente que posea una función de utilidad explícita puede tomar decisiones racionales con la ayuda de un algoritmo de propósito general que no dependa de la función específica de utilidad a maximizar o minimizar.

Con un **algoritmo de propósito general**, el tiempo de ejecución depende solamente del volumen o tamaño de los datos de entrada. Por el contrario, en un **algoritmo de propósito específico** el tiempo de ejecución depende de las propiedades asociadas a los parámetros de entrada y no tiene por qué estar directamente relacionado con el tamaño de los datos de entrada.

Agentes que aprenden

Los agentes explicados hasta ahora reciben «su conocimiento» del entorno a través de sus programadores. Son estos quienes introducen las reglas correspondientes, los objetivos a conseguir o la función de utilidad. Un enfoque diferente es enseñar a las máquinas a aprender por sí mismas las características de la tarea a abordar. De esta forma, la propia máquina podría ser capaz de descubrir nuevos enfoques y mecanismos eficientes para llevar a cabo la tarea asignada. Este tipo de agentes da pie a una nueva categoría, los **agentes que aprenden**.

Un agente que aprende se puede dividir en cuatro componentes conceptuales tal y como muestra la Figura 6 (Russell 2004).




Figura 6. Estructura de un agente que aprende. Fuente: Russell, 2004, p. 60.

La actuación del agente genera críticas, entendidas estas como evaluaciones sobre la actividad del agente inteligente. Los propios sensores del agente se convierten en receptores de las críticas. Debemos entender estas críticas como una retroalimentación muy valiosa para evolucionar y mejorar el funcionamiento del agente.

La retroalimentación recibida alimenta el elemento de aprendizaje, que es el motor encargado de desarrollar mejoras. Los cambios realizados son compartidos con el elemento de actuación. Este último componente es el responsable de seleccionar las acciones a ejecutar considerando los estímulos recibidos a través de los sensores.

Por último, el **generador de problemas** tiene la misión de sugerir acciones exploratorias (similares a un experimento) que, aunque puedan ser consideradas como no óptimas a corto plazo, son útiles para llegar a soluciones mejores que las actuales a largo plazo.

La arquitectura reflejada en la última imagen debe entenderse como una arquitectura de alto nivel donde solo se refleja la composición e interacción entre los elementos principales del esquema. De hecho, como **elemento de actuación** debe entenderse una representación simplificada de lo que anteriormente se había considerado como el agente completo ya que recibe estímulos y determina las acciones a realizar. Una posible implementación de este tipo de agentes es usando **aprendizaje por refuerzo**.

Para acabar de entender el último tipo de agente explicado podemos acudir al manual *Inteligencia Artificial: un enfoque moderno* (Russell, 2004). Los autores nos plantean el caso de un **taxi automatizado**, sin conductor. Podemos suponer que el usuario entra en el taxi e introduce la ubicación de destino. Aquí, el elemento de actuación agruparía todos los conocimientos y procedimientos que tiene el taxi para seleccionar las acciones a ejecutar en base a los requerimientos del conductor. La parte crítica, gracias a la observación del entorno, proporciona al elemento de aprendizaje la información necesaria para aprender y evolucionar su comportamiento. Un ejemplo puede ser un cambio de carril que ha provocado que un conductor proporcione un toque de atención con el claxon. El análisis de dicha situación puede servir para que el vehículo

ajuste los parámetros de actuación ampliando el límite de separación con los vehículos circundantes antes de volver a realizar una operación de estas características. Este tipo de reacción no tiene por qué ser inmediata. Según el caso, se puede requerir un «volumen de críticas» previo determinado, antes de considerar un cambio de comportamiento.

El ciclo de las acciones está presente de forma constante en la filosofía de estos agentes. Mis acciones provocan reacciones en el mundo con el que interactúo y dichas reacciones provocan que ajuste mi comportamiento. Por supuesto, siempre teniendo en cuenta los principios básicos de diseño del agente, el objetivo a cubrir o función de utilidad.

Un ejemplo real de este esquema puede ser el motor de inteligencia artificial **AlphaGo** desarrollado por DeepMind (Google). En mayo de 2017, AlphaGo derrotaba a Ke Jie, campeón (humano) del mundo de *Go* por la mínima. Por primera vez en la historia, una máquina superaba a un campeón mundial en este milenar juego. AlphaGo sorprendió a su rival con movimientos imaginativos y poco usuales.

Las versiones iniciales de este tipo de juegos se basaban en el análisis histórico de millones de partidas previamente cargadas. AlphaGo basa su fortaleza en su capacidad de autoaprendizaje, siendo capaz de jugar millones de partidas contra sí mismo y aprender de todas las situaciones que se van produciendo durante el juego. De esta forma, no solo es capaz de descubrir por sí mismo diferentes trucos que los mejores profesionales usan de forma cotidiana en sus partidas, sino que es capaz de evolucionar las jugadas ideando acciones originales capaces de sorprender al rival.

8.5. Proyectos de investigación en agentes inteligentes

Los proyectos de investigación en agentes son un campo muy de moda y que tiene un enorme futuro por delante debido a que son aplicables a multitud de sistemas *hardware* y *software*.

Además, son fácilmente englobables en *topics* de investigación punteros como el *machine learning* ya que un agente puede estar implementado con modelos de sistemas expertos o aprendizaje automático. Y, de hecho, normalmente en los últimos años es lo que suele suceder. Sus principales campos de actuación más de moda son los siguientes:

- ▶ *Trading* automático en bolsa.
- ▶ Agentes de negociación automáticos (llegan a acuerdos sin transacciones, sin intervención de humanos).
- ▶ Internet de las cosas. Todo tipo de agentes que se conectan a internet y realizan operaciones de forma automática por ti.
- ▶ Drones autónomos.
- ▶ Vehículos autónomos.
- ▶ Robótica e industria 4.0.
- ▶ Videojuegos: comportamiento de NPC, jugadores de lucha entrenados por ti que juegan en red en tu nombre (*killer Instinct*, *Smash Bros. Ultimate...*).

En cuanto a publicaciones, las principales revistas sobre este tema son las siguientes:

- ▶ *IEEE Transactions on Automatic Control.*
- ▶ *Automática.*
- ▶ *IEEE Transactions on Systems, Man, and Cybernetics.*
- ▶ *Autonomous Agent and Multy Agents.*
- ▶ *System and Control lectures.*
- ▶ *International Journal of Control.*

8.6. ¿Qué son los sistemas expertos?

Un sistema experto es un **sistema que emplea conocimiento humano capturado por un analista especializado en la toma de requisitos de sistemas expertos**, que después se almacena en una computadora y que, mediante una serie de reglas y modelos, permite al sistema resolver problemas similares a los que puede resolver los expertos consultados. Algunos de estos sistemas imitan el proceso de razonamiento que los expertos utilizan para resolver problemas específicos, de esta forma estos razonamientos pueden ser validados por los propios expertos para comprobar que sean correctos. Normalmente **utilizan un sistema de razonamiento o bien inductivo o deductivo**. Aunque cada vez hay más sistemas que utilizan modelos basados en *machine learning* donde esta característica en ocasiones se ve más comprometida, debido a que muchos de estos algoritmos son de caja negra (opacos, no se conoce exactamente cómo han llegado a la solución que generan).

Existen multitud de tipos de sistemas expertos pero los principales los podemos agrupar en tres tipos.

Basados en reglas

Se captura información de los expertos y se modeliza en forma de reglas. Estas reglas tienen una estructura:

SI X Entonces Y

Donde X es el antecedente de la regla e Y el consecuente.

El antecedente para cumplirse debe tener en la base de hechos (la memoria del sistema experto) una instancia de un objeto que sea compatible con esta. Ser compatible significa que cumpla con la descripción planteada en el antecedente. Por ejemplo:

Si p: Paciente p.fiebre > 38 Entonces

p.enfermo = true;

Esta regla se activará para cada uno de los elementos p de tipo paciente que tengan el atributo fiebre mayor que 38 y los marcará como enfermos.

De esta forma encadenando reglas se va generando nuevo conocimiento:

Si p: paciente, p.enfermo && not p.ingresado && camaslibres > 0
entonces:

camaslibres--, p.ingresado=true

A esta forma de razonar se le denomina **encadenamiento hacia delante**. Y se basa en el proceso deductivo o en la aplicación de la regla *modus ponens*.

Este tipo de sistemas expertos suelen implementarse con sistemas de reglas de producción. Algunas herramientas para esto son Clips, Jess, Lisa o Prolog.

Basados en casos

Se le suele denominar *case base reasoning* y es un **sistema de razonamiento que se basa en la premisa de encontrar el caso más similar de una base de casos y ejecutar la acción que se realizó para ese caso en un momento anterior**. Estos sistemas han dado tradicionalmente muy buenos resultados debido a que son capaces de plantear soluciones a problemas con base en los criterios del experto. Pero tienen algunos problemas en ciertos entornos. En los métodos basados en razonamiento, el razonamiento realizado para llegar a la conclusión puede ser trazado y mostrado a un experto que valide este. Esto da mucha confianza en los resultados que produce el sistema. Sin embargo, en los sistemas basados en casos, necesitamos encontrar un caso que sea lo más parecido posible. Esto tiene como problema principal que la función de similitud de casos a veces no funciona correctamente y no identifica bien el caso más similar, lo que puede conllevar elegir

un caso que realmente no era tan parecido como pensábamos. Aquí razonar por qué un caso es más similar que otro de la base de casos no es tan claro como en el razonamiento deductivo, y puede haber problemas de trazabilidad de la toma de decisiones del sistema experto. Aun así, no llega a ser un algoritmo de caja negra ni mucho menos y es preferible cuando necesitamos una cierta explicabilidad a modelos más opacos como las redes de neuronas.

Se suele utilizar KNN (*k-nearest neighbors*) o modelos derivados de este para la selección del conjunto de casos candidatos de la base de datos a tratar. Donde K representa el número de casos que vamos a recuperar para su consideración.

Basados en redes bayesianas

Las redes bayesianas **representan un conjunto de variables aleatorias y sus dependencias condicionales a través de un grafo acíclico dirigido** (DAG por sus siglas en inglés). Por ejemplo, una red bayesiana puede representar las relaciones probabilísticas entre enfermedades y síntomas. Dados los síntomas, la red puede ser usada para computar la probabilidad de la presencia de varias enfermedades. Esto aporta algo que lo hace muy interesante y es el concepto de probabilidad. Al dar una probabilidad, el experto puede finalmente valorar entre diferentes opciones ordenadas según la más probable por el sistema experto y da también una idea del posible error que el sistema pueda tener. Cosa que es más complicada con los otros dos modelos.

Aunque hay versiones de sistemas expertos basados en reglas que utilizan lógica difusa. Este tipo de lógica sí que usa probabilidades y también puede aportar una idea de cuál es el error que puede tener el razonamiento obtenido.

Para ejecutar redes bayesianas existen diferentes sistemas *software*, por ejemplo, Winbugs, Jags u OpenBUGS.

8.7. Proyectos de investigación en sistemas expertos

Los proyectos de investigación en sistemas expertos se centran en las **siguientes ramas**:

- ▶ Medicina.
- ▶ Internet de las cosas.
- ▶ Cultivos.
- ▶ Ganadería.
- ▶ Economía.
- ▶ Visión por computador.
- ▶ Apoyo a las decisiones.

Estos proyectos se caracterizan por ser **entornos de aplicabilidad** donde el sistema normalmente apoya la decisión última de un humano y son sistemas que se basan principalmente en profesionales cualificados de los que extraen el conocimiento. Así que puede ser aplicado a cualquier entorno donde el conocimiento se pueda modelar a base de reglas, sistemas de inferencias o probabilidades. Actualmente los sistemas basados en **lógica difusa** son los que más activos están a nivel académico.

Las **principales publicaciones** de este medio son:

- ▶ *Expert Systems With Applications.*
- ▶ *International Journal of Information Management.*
- ▶ *IEE Access.*

- ▶ *Expert System.*
- ▶ *Decision Support System.*

8.8. Referencias bibliográficas

Russell, S. (2004). *Inteligencia artificial: un enfoque moderno*. México: Pearson Educación.

Mastering the game of Go with deep neural networks and tree search

Silver, D. et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), 484-489. doi: 10.1038/nature16961. Recuperado de <https://storage.googleapis.com/deepmind-media/alphago/AlphaGoNaturePaper.pdf>

Artículo científico publicado en la prestigiosa revista *Nature* donde se exponen los fundamentos de AlphaGo.

Expert Systems

Andy. (17 de agosto de 2018). *What are expert system?* moral-robots.com.
Recuperado de <https://moral-robots.com/ai-society/what-are-expert-systems/>

Artículo interesante donde da una idea global de qué es un sistema experto.

1. ¿Cuáles de las siguientes frases son ciertas respecto a los agentes?
 - A. Solo pueden recibir información de forma directa de otros agentes.
 - B. Reciben información del entorno con el que se relacionan.
 - C. Sus acciones siempre afectan al entorno.
 - D. Su arquitectura se puede clasificar en diez tipologías distintas.

2. ¿Qué significa el acrónimo REAS?
 - A. Rendimiento, entorno, avisador, sensación.
 - B. Reutilización, entorno, acción, sensor.
 - C. Reutilización, entorno, acciones, sensores.
 - D. Rendimiento, entorno, actuadores, sensores.

3. ¿Cuáles de los siguientes pueden ser atributos de un entorno de trabajo?
 - A. Estocástico.
 - B. Parcialmente observable.
 - C. Episódico.
 - D. Todas las anteriores.

4. ¿Cuáles de los siguientes pueden ser atributos de un entorno de trabajo?
 - A. Discreto.
 - B. Discrecional.
 - C. Multiepisódico.
 - D. Todas las anteriores.

5. El entorno de trabajo en el que un agente inteligente debe desenvolverse para jugar al póker es un ejemplo de entorno de trabajo:
 - A. Parcialmente observable, secuencial y continuo.
 - B. Totalmente observable, secuencial y continuo.
 - C. Parcialmente observable, estático y discreto.
 - D. Parcialmente observable, dinámico y continuo.

6. Ejemplos válidos de distintos tipos de agentes inteligentes según su estructura son:
 - A. Reactivo simple, basado en modelos, basado en alcance.
 - B. Reactivo simple, reactivo basado en modelos.
 - C. Basado en objetivos, basado en función dinámica.
 - D. Agente que aprende, agente que juega.

7. Los agentes reactivos basados en modelos:
 - A. Tienen en cuenta el histórico de información para la toma de decisiones.
 - B. Solo tienen en cuenta un conjunto de reglas de condición-acción.
 - C. Consideran una función de utilidad.
 - D. Un agente de estas características ha derrotado al campeón mundial de *Go*.

8. Los sistemas expertos son útiles para:
 - A. Obtener conocimiento más allá del aportado por los expertos.
 - B. Suplantar al experto en la toma de decisiones.
 - C. Modelizar el comportamiento de expertos humanos para apoyar sus daciones.
 - D. Todas las anteriores.

9. El encadenamiento hacia delante:
- A. Es un método deductivo que se aplica en los sistemas expertos para obtener nuevo conocimiento a partir de una base de hechos y unas reglas de inferencia.
 - B. Es el mecanismo por el cual funcionan los sistemas de producción.
 - C. Permiten trazar el razonamiento del sistema experto.
 - D. Todas las anteriores.
10. El razonamiento basado en casos:
- A. Es más fácil de trazar la respuesta del sistema que los algoritmos de encadenamiento hacia delante.
 - B. Son un algoritmo de caja negra.
 - C. Tienen peores resultados que los sistemas basados en redes bayesianas.
 - D. Son más complejos de trazar que los sistemas de encadenamiento hacia delante.

Investigación y Gestión de Proyectos en Inteligencia
Artificial

Tema 9. Investigación en aprendizaje automático

Índice

Esquema


Ideas clave

- 9.1. Introducción y objetivos
- 9.2. ¿Cómo aprenden las máquinas?
- 9.3. Tipología de un proyecto de aprendizaje automático
- 9.4. Técnicas de aprendizaje automático
- 9.5. Proyectos de investigación sobre aprendizaje automático
- 9.6. Referencias bibliográficas

A fondo

- How AI is changing the video game industry: augmentation and synthetic media
- 4 Social Media Data Mining Techniques to Help Grow Your Online Business
- Deep Reinforcement Learning
- Neural Turing Machines

Test



9.1. Introducción y objetivos

En este tema se explica a alto nivel el **concepto de aprendizaje automático o *machine learning* (ML)**. Estos conceptos son fundamentales hoy en día en la inteligencia artificial y es uno de los campos más activos en esta.

De forma detallada, los **objetivos** que persigue esta unidad son:

- ▶ Ser capaz de entender cómo aprende una máquina.
- ▶ Conocer los tipos de algoritmos y problemas que existen y que pueden resolverse con *machine learning*.
- ▶ Identificar las principales técnicas y algoritmos de *machine learning* disponibles.
- ▶ Conocer los proyectos que se pueden crear usando *machine learning*.

9.2. ¿Cómo aprenden las máquinas?

Machine learning es uno de los temas más candentes de la inteligencia artificial actual. Pero como veremos durante este tema, es un inmenso campo de multitud de técnicas que darían cada una de ellas para una asignatura completa para poder tratarlas con profundidad. Lo que pretendemos en este tema es **dar las bases de cómo aprende una máquina y qué diversas implementaciones se han realizado en esta importante área de la inteligencia artificial.**

No está muy claro cuál es el mecanismo interno del aprendizaje del ser humano (o de otros animales). Por lo que **vamos a centrarnos en la funcionalidad**, más que en la estructura. Hay, por tanto, muchas definiciones de aprendizaje, pero vamos a resumirlo en la **capacidad que tienen los seres vivos de mejorar sus aptitudes**. Es decir, la capacidad que tienen los seres vivos de realizar tareas que no sabían hacer y por otro lado de mejorar aquellas que ya sabían hacer. Para esto tiene que haber algún tipo de memoria donde se almacene este nuevo conocimiento, pero no es suficiente con una memoria. Se necesita una abstracción que permita enfrentarse a problemas nuevos que no han sido estudiados previamente.

Una de las principales cualidades que permite el aprendizaje es la **flexibilidad**. Un sistema que aprende se puede adaptar a entornos cambiantes. Frente a soluciones programadas que necesitan para cambiar la modificación del propio programa ya que son soluciones **específicas**. De esta forma el aprendizaje permite a un sistema adaptarse a los cambios en el entorno. Es por ello por lo que está especialmente recomendado en entornos dinámicos.

Pero ¿cómo aprende una máquina? El proceso de aprendizaje consiste en **seleccionar de entre un conjunto de hipótesis posibles para realizar una tarea o resolver un problema, aquellas que realizan la tarea o resuelven el problema de la mejor forma posible**. Así que hay ciertos conceptos que son claves. Por un lado,

el sistema debe sacar conclusiones o crear un modelo que sirva para ser usado de forma general. Normalmente estas conclusiones se extraen de analizar casos particulares. Por lo cual, **se necesita extraer cuál es el patrón o las características más relevantes en las que se basa el problema o la tarea. Esto no es más que una muestra de lo que se conoce como **abstracción**. Los humanos deben abstraerse de los pequeños detalles para saber resolver una tarea, ya que para resolver una tarea no se puede atender a todos los pequeños detalles a la vez.** Pues básicamente eso es lo que en esencia hace un algoritmo de *machine learning*. Crea una descripción del problema de forma abstracta y resumida de este, que permite adaptar dicho modelo a múltiples problemas, que siendo diferentes entre ellos comparten unas características comunes que son las que lo identifican.

Por lo tanto, se necesita simplificar el problema y en este proceso de simplificación se introducen sesgos.

Los sesgos (o *bias* en inglés) **son un conjunto de datos establecidos a priori que ayuda a reducir la incertidumbre que caracteriza a la selección de la hipótesis correcta en el aprendizaje.** Por ejemplo, cuando usamos ejemplos para aprender, los algoritmos de *machine learning* introducen sesgos o generalizaciones que hacen perderse los detalles de los ejemplos introducidos. Pero esto es fundamental si queremos que el modelo pueda ser aplicado a otros ejemplos no usados en el entrenamiento. Porque, **si no se introdujesen estos sesgos en el aprendizaje, entonces los algoritmos de aprendizaje automático podrían resolver muy bien los ejemplos que se han usado para el aprendizaje, pero no serían capaces de resolver otros ejemplos diferentes. Es decir, se habrían especializado, pero no tendrían capacidad de generalización.**

Así que la introducción de sesgos es esencial para que un algoritmo aprenda. Y esto es algo que hacemos constantemente nosotros como humanos. La mayoría de las ecuaciones que se plantean en física tienen sesgos, ¿cuáles son esos sesgos? Por ejemplo, las ecuaciones de carga eléctrica asumen que los cuerpos están en el

vacío. El movimiento uniformemente acelerado asume que lo haces en el vacío (sin fricción) y que la tierra no es curva (ni el espacio es curvo por la fuerza de la gravedad). La famosa ecuación de la relatividad de Einstein ($E=mc^2$), en realidad solo se aplica en los casos donde haya partículas con masa. Es decir, no se puede aplicar a la luz (que no tiene masa, pero si energía. Por lo que la fórmula general es más compleja, pero esta nos sirve como buena aproximación para la mayoría de los casos). Las ecuaciones de física que estudias en el instituto y en la universidad tienen sesgos. Lo mismo que las reglas de ortografía que tienen excepciones. Como vemos no son reglas totalmente generales, pero se crean para ayudarnos en el proceso de abstracción.

Así que podemos decir que el mecanismo por el cual **una máquina** o un programa aprende es **gracias a que es capaz de construir un modelo simplificado de un problema con base en ejemplos parciales de ese problema**, intentando extraer las características generales que lo describen. A esto se le denomina sesgo y lo contrario, no introducir sesgos se le denomina **varianza** (*variance*) y es algo que normalmente no queremos. También se les denomina sobreajuste a los datos de entrenamiento. Este problema hace que el sistema pierda la capacidad de abstracción y, por tanto, procesará mal los ejemplos no introducidos como entrenamiento de la red. Paradójicamente, el sesgo introduce un error en el modelo como se puede ver en la figura 1. Pero dicho error nos permite predecir el comportamiento de una nueva variable mucho mejor que el modelo que no proporciona dicho error. A esto también se le denomina en algunos entornos **sobreadaptación** (*overfitting*) del modelo a los datos de entrenamiento.




Figura 1. Definición gráfica de sesgo (*bias*) y varianza (*variance*). Fuente: <https://skillsfuturetv.com/wp-content/uploads/2020/05/maxresdefault-360.jpg>

Ahora que tenemos claro que se necesita generalizar y, por tanto, introducir errores para conseguir aprender. Asimismo debemos tener en cuenta que esos errores no deben ser inducidos por una mala selección de los casos de ejemplo. Seleccionar los casos de entrenamientos ayuda a que el sistema no aprenda sesgos innecesarios o que no son recomendables. Esto ya lo veremos con más detalles, pero por adelantar el concepto aquí vamos a ver un caso de ejemplo de un sesgo aprendido, podemos suponer que si no seleccionamos correctamente un patrón de rostros lo suficientemente diverso a nivel étnico, un algoritmo de *machine learning* puede aprender a reconocer solo caras de occidentales pero no de asiáticos o africanos, ya que utilizará probablemente los rasgos distintivos comunes de las caras occidentales como un patrón común que le maximiza la distinción entre lo que es una cara y lo que no.

Como podemos ver en este caso, el sesgo utilizado para aprender es un **sesgo perjudicial**. Así que hay que tener mucho cuidado cuando se presentan los ejemplos para no introducir sesgos artificiales o que induzcan a un comportamiento del modelo no deseado.

Una vez visto cómo aprenden las máquinas a nivel teórico, queda por describir cómo se realiza a nivel práctico. ¿Cómo llegamos a este aprendizaje? Hay diferentes caminos. Podemos clasificar las diferentes técnicas de aprendizaje en distintos tipos en base a si el aprendizaje es guiado por el diseñador del problema o no.

9.3. Tipología de un proyecto de aprendizaje automático

Podemos clasificar los algoritmos de aprendizaje en tres grandes tipos en función de la intervención que tenga el diseñador del algoritmo en el aprendizaje.

Aprendizaje supervisado

Este tipo de algoritmo **requiere que los ejemplos que se introduzcan para aprender tengan también la solución al problema**. De esta forma, el aprendizaje supervisado intenta deducir una función que permita obtener a partir de los datos de entrada la solución deseada. Ambos valores se proporcionan al algoritmo de forma que este puede analizar cómo de lejos está su modelo actual de conseguir representar correctamente las salidas deseadas. Es decir, puede usar el error de entrenamiento para tomar decisiones en el aprendizaje. En algunos de estos modelos este error de entrenamiento es clave para mejorar el algoritmo como en el caso de las redes de neuronas.

Como ya hemos comentado en la introducción, **no hay aprendizaje si no hay capacidad de generalización**. Es decir, si no somos capaces de aplicar el modelo a ejemplos que no hemos visto antes y obtener un resultado correcto o aproximado. Por lo tanto, necesitamos que nuestra función prediga el valor de un objeto una vez entrenado, sin conocer cuál es el resultado correcto del mismo. Es decir, *necesitamos que haga una generalización*. Ejemplos de algoritmos de aprendizaje supervisado son las redes de neuronas, *support vector machines*, árboles de decisión, etc.

Para entrenar redes de aprendizaje supervisado, el diseñador debe seleccionar un conjunto de ejemplos de entrenamiento y un conjunto de ejemplos de validación. Esto es así para poder comprobar de forma empírica cuál es la capacidad de generalización de la red.

Así pues, se deberá crear una base de ejemplos con los atributos que describen dicho ejemplo y la clase a la que pertenece. De ellos, seleccionaremos un subconjunto de entrenamiento y otro de test. Normalmente se suele usar un 75 % de entrenamiento y un 25 % de validación o test. Pero no es una regla escrita y puede ser diferente en función del problema a tratar.

Una técnica de pruebas muy utilizada es el *cross validation* o la **validación cruzada**. Sirve para evaluar los resultados de un modelo y garantizar que son independientes de la partición entre datos de entrenamiento y prueba. Este método consiste en **calcular la media aritmética obtenida de las medidas de evaluación sobre diferentes particiones**. Se utiliza en entornos donde el objetivo principal es la predicción y se quiere estimar la precisión de un modelo que se llevará a cabo a la práctica. Por ejemplo, se puede dividir los datos en bloques en cuatro y coger tres de ellos para entrenar y uno para validar. Repitiendo el problema cuatro veces cambiando el bloque de validación en cada vez y calculando la media aritmética de las cuatro validaciones, obtendremos una mejor aproximación al error de aprendizaje y minimizaremos la introducción involuntaria de posibles sesgos a la hora de realizar la partición.

El aprendizaje no supervisado

El aprendizaje no supervisado **es aquel que se lleva a cabo sobre ejemplos que no informan del resultado esperado de este**. Por lo tanto, podemos decir que **no hay nadie que le está indicando al sistema cómo se resuelve el ejemplo propuesto**. Esto debe descubrirlo el propio algoritmo. Por lo tanto, **los algoritmos de aprendizaje no supervisado tratan las entradas como variables aleatorias y crean modelos de densidad para los diferentes conjuntos de datos**. Ejemplos de algoritmos de aprendizaje no supervisado son los mapas autoorganizados, el análisis multivariante, el clústering, los estimadores de máxima verosimilitud o las redes de neuronas de base radial. Algunos modelos de *deep learning* como los modelos de extracción de

características también son no supervisados. Aunque las redes de neuronas son algoritmos supervisados, existen algunos trucos que detallaremos más adelante para conseguirlo.

Para realizar un entrenamiento de un algoritmo de aprendizaje no supervisado, no debemos construir pares atributos-valor esperado, ya que no sabemos el valor esperado (o no lo necesita saber el algoritmo en cuestión). Esto hace más complejo e impreciso calcular el error de estos modelos. Pero **debemos medir si nuestro algoritmo está funcionando bien de todas formas, ¿cómo lo hacemos?** Debemos introducir medidas artificiales. Por ejemplo, en un algoritmo de agrupamiento podemos estimar la varianza total del sistema. Pero en estos casos, **visualizar las agrupaciones realizadas ayuda mucho a comprender si el agrupamiento se ha realizado correctamente.**




Figura 2. Ejemplo de funcionamiento de *k-means*, un algoritmo no supervisado y cómo visualizar si el agrupamiento realizado es correcto. Fuente: <http://www.cs.us.es/~fsancho/?e=77>

En el caso de que tengamos las soluciones de las clases de algunos ejemplos, podemos comprobar si ha clasificado correctamente los ejemplos *a posteriori*. Aunque como decimos, esta información solo nos servirá para estimar el error cometido, pero el algoritmo no toma ventaja de esta información para mejorar los resultados.

Aprendizaje por refuerzo

El algoritmo aprende observando el mundo que le rodea. Su información de entrada es el *feedback* o retroalimentación que obtiene del mundo exterior como respuesta a sus acciones. Por lo tanto, el **sistema aprende a base de ensayo-error**. Aunque no de forma aleatoria. Se podría considerar como un aprendizaje no supervisado por nadie, pero hay un pequeño matiz y es que los algoritmos no supervisados ni siquiera tienen el *feedback* de si lo están haciendo bien o mal. Aquí el entorno les está dando una retroalimentación de si lo que hacen está siendo efectivo o no. Por lo tanto, no podemos clasificarlos ni como aprendizaje supervisado ni como no supervisado.

El aprendizaje por refuerzo es el más general entre las tres categorías ya que en vez de que un instructor indique al agente qué hacer, **el agente inteligente debe aprender cómo se comporta el entorno mediante recompensas (refuerzos) o castigos de forma autónoma**, derivados del éxito o del fracaso de sus decisiones. El objetivo principal es aprender la función de valor que ayude al agente inteligente que lo utiliza a maximizar la señal de recompensa recibida y así optimizar sus políticas para comprender el comportamiento del entorno y de esta forma ser capaz de tomar buenas decisiones para conseguir sus objetivos. Por lo tanto, la versatilidad del sistema es máxima y un mismo sistema podría aprender a realizar cosas completamente diferentes en función del entorno donde se mueva. Ejemplos de este tipo de técnicas son *Q-learning*, *deep reinforcement learning*, simulaciones de Montecarlo, etc.

¿Y cómo se puede evaluar un algoritmo de aprendizaje por refuerzo? Pues hay que ejecutarlo en un escenario diferente al aprendido y tener una medida de calidad de este para saber si el algoritmo funciona y ha conseguido generalizar un modelo. En parte la propia función le dice al algoritmo si está haciendo las cosas bien o no sirve como medida de la calidad de este. Pero hay que probar el sistema en otros entornos para ver si ha sido capaz de aprender una política válida para cualquier entorno similar. Y ahí necesitaremos una medida de rendimiento. Imaginemos que tenemos un sistema de aprendizaje por refuerzo que ponemos a entrenar para que aprenda a jugar a un juego. El sistema debe aprender a jugar al juego a base de prueba y error y en cada decisión que tome de forma acertada, el sistema debe premiar esa política. Pero luego lo tenemos que poner a jugar al juego contra otros jugadores diferentes y tendremos que evaluar si consigue ganar a esos otros jugadores y cómo de rápido o de eficiente ha ganado (cuántas piezas ha perdido, cuántos puntos ha conseguido, en cuánto tiempo ha ganado...). De esta forma validaremos el sistema.

Tipos de problemas

Vistos los diferentes tipos de algoritmos de aprendizaje automático, nos queda por describir los diferentes tipos de problemas que estos pueden abordar. Principalmente **podemos agrupar los problemas en tres tipos: problemas de clasificación, de regresión y de agrupación.**

Es importante detectar cuándo un problema es de clasificación, de regresión o de agrupamiento, porque las técnicas empleadas y los métodos para obtener los datos no son iguales. Tampoco es igual la forma con la que evaluamos los errores que comenten los algoritmos en ambos modelos.

Problema de clasificación

La clasificación es el problema de identificar a cuál, de un conjunto de categorías (subpoblaciones), pertenece una nueva observación, sobre la base de un conjunto de datos de entrenamiento que contienen observaciones (o instancias) cuya

categoría es conocida.

Para que haya un problema de clasificación se deben conocer las clases *a priori* y además estas deben ser un conjunto finito.

Algunos algoritmos que resuelven problemas de clasificación son: árboles de decisión, *support vector machine*, redes de neuronas (discretizando la salida de la red), K-NN, redes bayesianas, *random forest*, etc.

Problema de regresión

Los problemas de regresión **son problemas en los que la salida que se espera es una salida continua.** Un número de casos infinito o al menos indefinido y, por tanto, lo que queremos normalmente es usar una estimación de esta salida lo más precisa posible. Los algoritmos que intentan realizar regresión intentan estimar la función de mapeo (f) de las variables de entrada (x) a las variables de salida numéricas o continuas (y). Ahora, la variable de salida podría ser un valor real, que puede ser un valor entero o de coma flotante.

Algunos algoritmos que resuelven problemas de regresión son: *regresión logística*, redes de neuronas, *regression support vector machines*, etc.

Problema de agrupamiento

Es decir, es no-supervisado

Un problema es de **agrupamiento si no se conoce *a priori* el número de clases ni el tipo de estas y lo que se pretende es precisamente conocer qué clases existen.** Los algoritmos que se aplican al agrupamiento pretenden encontrar cuáles son los grupos que existen en una población y cuáles son los criterios o las características que separan unas clases de otras.

Algunos algoritmos que resuelven problemas de agrupación son: *k-means*, *k-modes*, *mean-shift*, *binary split*, *deep belief networks*, *restricted boltzmann machines*, etc.

9.4. Técnicas de aprendizaje automático

A continuación, vamos a citar las principales técnicas y algoritmos de aprendizaje automático de forma resumida, identificado en qué se basan, cuáles son sus ventajas y cuál son sus inconvenientes.

K-NN (*K-nearest neighbor* o k vecinos más cercanos)

Este algoritmo de aprendizaje supervisado es también conocido como **aprendizaje perezoso**. El algoritmo no intenta extraer una característica de los datos haciendo un proceso de entrenamiento exhaustivo con ellos. **Simplemente los almacena para recuperarlos en el futuro**. Cuando se presenta un nuevo caso, este es comparado con la base de casos y se extrae aquel más similar (o los K más similares) para comprobar cuál era la clase (o la acción) que se llevó a cabo para el caso concreto. Asumiendo que, si el caso es similar, la acción tomada anteriormente será una acción que también será válida para el nuevo caso.

Para ello hay que definir una función de similitud entre dos ejemplos. La calidad de esta medida de similitud es la que más ayudará a que el sistema se comporte correctamente. Existen multitud de medidas de similitud, por ejemplo, la distancia euclídea, la distancia de Manhattan, la distancia de edición, la distancia de Minkowski, la distancia de Mahalanobis, etc. Cada una de ellas funciona mejor en unos dominios que en otros. También se pueden ponderar los pesos de los atributos para ajustar más la similitud, dando más importancia a ciertos rasgos que a otros.

Ventajas:

- No paramétrico (salvo que usemos distancias ponderadas). No hace suposiciones explícitas sobre la forma funcional de los datos, evitando los peligros de la distribución subyacente de los datos.

- ▶ Algoritmo simple tanto de explicar como de interpretar.
- ▶ Alta precisión (relativa). Es bastante alta, aunque no superior a otros modelos más sofisticados.
- ▶ El proceso de entrenamiento es inmediato.

Las **desventajas** de este algoritmo son:

- ▶ Es muy sensible a los atributos irrelevantes. Hacer una buena selección de atributos relevantes es fundamental para este algoritmo.
- ▶ Es sensible al ruido, ya que, si un ejemplo es un mal ejemplo de entrenamiento y es el seleccionado como el más similar, daremos una solución errónea. Esto se puede mitigar haciendo que K sea grande, es decir que el número de elementos cercanos sea mayor para que el peso del ruido sea menor.
- ▶ La ejecución de este es lenta si hay muchos datos de entrenamiento, ya que tiene que procesar todos los datos. Existen métodos para optimizarlo usando partición espacial pero aun así es más costoso que otros algoritmos.
- ▶ Es caro en memoria en tiempo de ejecución. Si la base de casos es muy grande ocupa mucha memoria.

Árboles de decisión

Es un modelo de predicción supervisado utilizado en diversos ámbitos que van desde la inteligencia artificial hasta la economía. **Estos árboles son muy útiles para visualizar las diversas opciones de las que se dispone para resolver un problema o modelar un comportamiento y cuál es la secuencia de pasos**

necesaria para llegar a dicha decisión, ya que se pueden convertir en reglas, que son mucho más legibles para el que investiga el funcionamiento del modelo. Además, se les pueden aplicar métodos de inducción, como por ejemplo la inducción hacia atrás, gracias a los cuales, mediante sencillos razonamientos, se puede descubrir la lógica que el sistema ha tomado para llegar a seleccionar una acción.

Un árbol de decisión está **compuesto de dos tipos de nodos**: un nodo condicional y una clase. Los nodos condicionales son los nodos internos del árbol y la clase, los nodos hoja o terminales.

Cada **nodo condicional** es una pregunta que se hace a las variables del entorno y solo tiene dos caminos, que la condición sea cierta o falsa. En función de si es una u otra, se tomará un camino y se llegará a un nodo hoja u otro. Cuando se llega a un nodo hoja, este determina la clase a la que pertenece el ejemplo suministrado.




Figura 3. Ejemplo de árbol de decisión. Fuente:

https://es.wikipedia.org/wiki/%C3%81rbol_de_decisi%C3%B3n#/media/Archivo:Arbol_decision.jpg

Algunas de las implementaciones más famosas de estos algoritmos son el ID3, J48 o C4.5.

Este algoritmo **utiliza la entropía** (medida de incertidumbre o de desorden) para

ayudar a decidir qué atributo debe ser el siguiente en ser evaluado en el árbol. También nos puede ayudar a descubrir qué atributos son los más relevantes, ya que el algoritmo los colocará más cerca de la raíz. En concreto se pretende maximizar la ganancia de información, donde la entropía se utiliza como una medida del orden de los datos. Es decir, el atributo seleccionado es aquel que deja la información más ordenada o, dicho de otra forma, mejor clasificada. La entropía se calcula con la ecuación.

$$Entropía(s) = \sum_{n=1}^c -p_i \log_2 p_i$$

Y la ganancia con la ecuación:

$$Ganancia(S,A) = Entropía(S) - \sum_{v \in Valores(A)} \frac{|S_v|}{|S|} Entropía(S_v)$$

Donde $Valores(A)$ es el conjunto de todos los valores posibles para el atributo A , y S_v , es el subconjunto de S para el cual el atributo A tiene el valor v .

En general, los atributos que separan mejor las clases tienden a reducir más la entropía y, por tal motivo, debe ser seleccionado primero.

Por lo tanto, este algoritmo divide el espacio de soluciones mediante hiperplanos, fijando una de las variables a un valor frontera.




Figura 4. Ejemplo de un hiperplano en 2 y 3 dimensiones que separa dos conjuntos de clases.

Ventajas:

- ▶ El entrenamiento es muy rápido.
- ▶ Es fácil de interpretar los resultados por un humano, es un algoritmo de caja blanca.
- ▶ Para algunos problemas consigue una buena precisión.
- ▶ Se pueden convertir fácilmente reglas.
- ▶ No requiere una preparación de los datos demasiado exigente.
- ▶ Puede trabajar con variables cualitativas y cuantitativas.

Desventajas:

- ▶ Es muy dependiente al ruido de la entrada.
- ▶ Los árboles de decisión tienden al sobreentrenamiento.

- ▶ No se puede garantizar que el árbol generado sea el óptimo.
- ▶ Hay conceptos que no son fácilmente aprendibles por los árboles de decisión, ya que las particiones del espacio de soluciones que puede hacer son aquellas que son representables mediante una sucesión de hiperplanos. Si no hay una aproximación lineal al problema, puede que den un modelo poco efectivo.
- ▶ Se recomienda balancear el conjunto de datos antes de entrenar.

Existen versiones más modernas de árboles de decisión como es el **random forest**.

Este ejecuta diferentes árboles de decisión y se realiza un proceso de votación para elegir cuál de los árboles ha generado una mejor predicción. Por ejemplo, nos podemos quedar con la predicción mayoritaria, con la media, etc. Estos métodos obtienen mejores resultados en general que los árboles de decisión convencionales, aunque dificultan la comprensión del modelo generado.

Redes de neuronas

Las redes de neuronas son una analogía del funcionamiento del cerebro humano, que permiten a las computadoras adoptar ciertas capacidades que se pueden definir como inteligentes, y que resuelven un importante subconjunto de problemas que otras técnicas computacionales o matemáticas no resuelven o lo hacen de forma más ineficiente, tanto en tiempo como en los resultados obtenidos. Debido a su semejanza con el cerebro, posee muchas capacidades similares a la mente humana. Por ejemplo, son capaces de aprender de la experiencia, de generalizar de casos anteriores a nuevos casos, de abstraer características esenciales a partir de entradas que representan información irrelevante, etc. Esto hace que ofrezcan numerosas ventajas y que este tipo de tecnología se esté aplicando en múltiples áreas, como aprendizaje adaptativo, autoorganización, tolerancia a fallos, etc.

Las redes de neuronas se basan en los trabajos realizados por Warren

McCulloch y Walter Pittis en 1943, que han servido de base para la aparición de multitud de arquitecturas obtenidas durante los últimos setenta años. Las redes de neuronas se caracterizan por contar con un número de neuronas organizadas de diversas formas, que están conectadas unas a otras a través de enlaces ponderados por unos pesos, que suelen ser recalculables por la propia red, de forma más o menos autónoma, para proporcionar una de las capacidades más importantes de la mayoría de las redes de neuronas, que es su capacidad de aprendizaje. **Al igual que el cerebro humano, las neuronas y las redes de neuronas artificiales sustentan su capacidad de cálculo no en el núcleo de las neuronas sino principalmente en las interconexiones que se realizan entre ellas.**

Normalmente se suelen diferenciar **tres tipos de neuronas en una red**, dependiendo de su función:

- ▶ **Neuronas de entrada.** Son las encargadas de recibir los datos del exterior de la red e inician la propagación de dichos datos por toda la estructura. Las conexiones de entrada de estas neuronas (sus dendritas) no realizan ningún cómputo, solo el hecho de captar la información para la red.
- ▶ **Neuronas ocultas.** Son aquellas neuronas que permiten enlazar las neuronas de entrada y las neuronas de salida, aunque también pueden estar conectadas a otras neuronas ocultas; y en sus interconexiones es donde precisamente se realiza el proceso de cómputo, tanto al enviar la información a todas las neuronas con las que está interconectada, como al recibir la información.
- ▶ **Neuronas de salida.** Son las que muestran al exterior los resultados obtenidos después de que la entrada haya recorrido toda la red. Las conexiones de salida de las neuronas de salida no realizan ningún cómputo.




Figura 5. Esquema de una red de neuronas.

Existen **multitud de tipos de redes** de neuronas las principales son las siguientes:

- ▶ **Perceptrón multicapa:** es el modelo más simple que consta de una capa de entrada, n capas ocultas y una capa de salida. Es un aproximador universal.
- ▶ **Redes de neuronas recurrentes:** algunas de las neuronas de salida son también neuronas de entrada del siguiente ejemplo a procesar. Este tipo de neuronas viene muy bien para predecir sistemas que tengan alguna relación temporal entre los diferentes ejemplos. Por ejemplo, para procesar series temporales o datos secuenciales.
- ▶ **Redes de base radial:** calculan la salida de la función en función de la distancia a un punto denominado centro. Al igual que con los perceptrones multicapa, sirven como aproximadores universales y solo tienen una capa oculta. Mientras que las neuronas ocultas poseen carácter local, las neuronas de salida realizan una

combinación lineal de las activaciones de las neuronas ocultas. Este tipo de redes construyen aproximaciones que son combinaciones lineales de múltiples funciones locales no lineales. Entre sus aplicaciones se encuentran análisis de series temporales, procesamiento de imágenes, etc.

- ▶ **Redes estocásticas:** son redes recurrentes que utilizan redes bayesianas.
- ▶ **Red de Hopfield:** se usan como sistemas de memoria asociativa con unidades binarias. Están diseñadas para converger a un mínimo local, pero la convergencia a uno de los patrones almacenados no está garantizada.

Normalmente, se utiliza para aprender el algoritmo de **retropropagación del error cometido por la red**. No entraremos en detalles, pero la idea es que la derivada del error producido entre la salida generada y la esperada va modificando los pesos de la red en una especie de descenso de gradiente. Esto se hace indispensable para que la red aprenda y conozca el dato correcto del ejemplo que procesa. Como otros algoritmos, si se entrena demasiado tiende a la especialización y a perder capacidad de generalización. Es importante detener el entrenamiento cuando se detecte que este comienza a ofrecer un error de validación creciente. Es decir, que en este tipo de redes es importante entrenar y evaluar con datos no entrenados para saber si la red se sobreadapta a los ejemplos de entrenamiento o no.

El **concepto de deep learning** viene precisamente de crear modelos de redes de neuronas con un gran número de capas ocultas. Estos modelos de redes de neuronas ahora son posibles debido a las nuevas técnicas de aprendizaje que se utilizan y al incremento de la potencia de cálculo disponible. Pero en líneas generales siguen las mismas directrices que los modelos simples. Una descripción más detallada de este tipo de redes se sale del objetivo de esta asignatura, pero vamos a enumerar los modelos más conocidos.

Autoencoders

Son **redes neuronales con el objetivo de generar nuevos datos**, primero comprimiendo la entrada en un espacio de variables latentes y luego reconstruyendo la salida con base en la información adquirida. La parte comprimida es una abstracción que sirve para extraer las características importantes de los datos. Este tipo de red **consta de dos partes**:

- ▶ **Encoder**: la parte de la red que comprime la entrada en un espacio de variables latentes.
- ▶ **Decoder**: la parte que trata de reconstruir la entrada en base a la información recolectada previamente. Se representa mediante la función de decodificación $r = g(h)$.




Figura 6. Esquema de un *autoencoder*.

Redes convolucionales

Las redes neuronales convolucionales **son un tipo de redes neuronales donde las neuronas corresponden a campos receptivos de una manera muy similar a las neuronas en la corteza visual**. Este tipo de red es una variación de un perceptrón multicapa, sin embargo, debido a que su aplicación es realizada en matrices bidimensionales, son muy efectivas para tareas de visión artificial, como en la clasificación y segmentación de imágenes, entre otras aplicaciones. Consisten en múltiples capas de filtros convolucionales de una o más dimensiones. Después de cada capa, por lo general, se añade una función para realizar un mapeo causal no lineal. Como cualquier red empleada para clasificación, al principio estas redes tienen una fase de extracción de características, compuesta de neuronas

convolucionales, luego hay una reducción por muestreo y al final tendremos neuronas de perceptrón más sencillas para realizar la clasificación final sobre las características extraídas.

Neural Turing machines

Una máquina de Turing neural es una **red neural extendida con una memoria de trabajo que le proporciona unas altas capacidades de aprendizaje**. La arquitectura de una máquina de Turing neural (NTM) contiene dos componentes básicos: un controlador de red neural y un banco de memoria. Como la mayoría de las redes neuronales, el controlador interactúa con el mundo exterior a través de vectores de entrada y salida. A diferencia de una red estándar, también interactúa con una matriz de memoria utilizando operaciones selectivas de lectura y escritura. Por analogía con la máquina de Turing, las salidas de la red que parametrizan estas operaciones se llaman cabezas, como la cabeza lectora de la máquina de Turing.

Redes recurrentes profundas

Son versiones profundas de las redes recurrentes. Tienen conexiones de retroalimentación. No solo pueden procesar puntos de datos individuales (como imágenes), sino también secuencias enteras de datos (como voz o vídeo). Una de las redes de este tipo más conocidas es la red LSTM (*Long short-term memory*). Esta red es aplicable a tareas como el reconocimiento de escritura, traducción automática, el reconocimiento de voz y la detección de anomalías en el tráfico de la red o sistemas de detección de intrusos.

Ventajas:

- ▶ De muy alta precisión.
- ▶ Sirven para regresión y para clasificación.

- ▶ Las nuevas técnicas las hacen muy escalables.
- ▶ Muy tolerantes al ruido.

Inconvenientes:

- ▶ Los modelos profundos son muy caros de calcular, se necesita muchísima potencia de cómputo para entrenar.
- ▶ Tienden a la sobreadaptación. Hay que vigilar con cuidado el entrenamiento para que no pierdan capacidad de abstracción.
- ▶ Son algoritmos de caja negra muy difíciles de analizar por los diseñadores.
- ▶ Dependen de ciertos pesos o parámetros iniciales y de cómo se inicien los valores.

Máquinas de vectores de soporte (SVM)

Son un **conjunto de algoritmos de aprendizaje supervisado desarrollados por Vladimir Vapnik** y su equipo en los laboratorios AT&T.

Estos métodos están propiamente relacionados con problemas de clasificación y regresión. Dado un conjunto de ejemplos de entrenamiento podemos etiquetar las clases y entrenar una SVM para construir un modelo que prediga la clase de una nueva muestra.

Los **vectores de soporte son los puntos que definen el margen máximo de separación del hiperplano que separa las clases**. Se llaman vectores porque estos puntos tienen tantos elementos como dimensiones tenga nuestro espacio de entrada. Es decir, estos puntos multidimensionales se representan con vector de n

dimensiones.

Hay veces en las que no hay forma de encontrar un hiperplano que permita separar dos clases. En estos casos, decimos que las clases no son linealmente separables. Para resolver este problema **se puede usar un kernel**. El truco del kernel consiste en inventar una dimensión nueva en la que podamos encontrar un hiperplano para separar las clases.




Figura 7. Kernel en SVM. Fuente: <https://www.iaartificial.net/maquinas-de-vectores-de-soporte-svm/>

Algunos casos de éxito de las **máquinas de vectores de soporte** son:

- ▶ Reconocimiento óptico de caracteres.
- ▶ Detección de caras para que las cámaras digitales enfoquen correctamente.
- ▶ Filtros de spam para correo electrónico.
- ▶ Reconocimiento de imágenes a bordo de satélites (saber qué partes de una imagen tienen nubes, tierra, agua, hielo, etc.).

Ventajas:

- ▶ Eficaz en espacios de grandes dimensiones.
- ▶ Todavía eficaz en casos donde el número de dimensiones es mayor que el número de muestras.
- ▶ Utiliza un subconjunto de puntos de entrenamiento en la función de decisión (llamada vectores de soporte), por lo que también es eficiente en memoria.
- ▶ Versátil: se pueden especificar diferentes funciones del núcleo para la función de decisión. Se proporcionan *kernels* comunes, pero también es posible especificar *kernels* personalizados.

Las **desventajas** son:

- ▶ Si el número de características es mucho mayor que el número de muestras evita el exceso de ajuste al elegir las funciones del *kernel* y el término de regularización es crucial.
- ▶ Los SVM no proporcionan directamente estimaciones de probabilidad, estas se calculan utilizando una validación cruzada.

Aprendizaje por refuerzo

El aprendizaje por refuerzo es una **serie de técnicas inspiradas en la psicología conductista**, cuya ocupación es determinar qué acciones debe escoger un agente *software* en un entorno dado con el fin de maximizar alguna noción de recompensa o premio acumulado. Esta recompensa o premio se da cuando el agente realiza la acción correcta en un momento dado.

El agente que aprende **sigue un proceso de decisión de Markov**:

- ▶ El agente percibe un conjunto finito (S) de estados distintos en su entorno, y dispone de un conjunto finito (A) de acciones para interactuar con él.
- ▶ El tiempo avanza de forma discreta, y en cada instante de tiempo (t) el agente percibe un estado concreto.
- ▶ El entorno responde a la acción del agente por medio de una recompensa. Se formaliza esta recompensa/castigo por medio de un número.
- ▶ Tanto la recompensa como el estado siguiente obtenido no tienen por qué ser conocidos a priori por el agente, y dependen únicamente del estado actual y de la acción tomada.




Figura 8. Esquema de aprendizaje por refuerzo. Fuente: <https://wiki.pathmind.com/deep-reinforcement-learning>

El objetivo del aprendizaje por refuerzo es extraer qué acciones deben ser elegidas en los diferentes estados para maximizar la recompensa. Buscamos, por tanto, **que el agente aprenda una política**. Esta política no es más que un criterio a la hora de seleccionar una acción o la otra.

Existen diferentes implementaciones de aprendizaje por refuerzo, pero nos vamos a centrar en **cómo aprende la política el algoritmo Q-learning**.

El algoritmo, por tanto, tiene una función que calcula la calidad de una combinación estado-acción:

$$Q : S \times A \rightarrow \mathbb{R}.$$

Antes de que comience el aprendizaje se inicializa a un valor arbitrario constante. Después, en cada tiempo el agente selecciona una acción (a) observa una recompensa (r) introduce un estado nuevo $s(t+1)$ que depende del estado anterior y de la acción seleccionada, actualizando Q. El núcleo del algoritmo es una actualización del valor de la iteración simple, haciendo la media ponderada del valor antiguo y la información nueva:

$$Q^{new}(s_t, a_t) \leftarrow (1 - \alpha) \cdot \underbrace{Q(s_t, a_t)}_{\text{old value}} + \underbrace{\alpha}_{\text{learning rate}} \cdot \left(\underbrace{r_t}_{\text{reward}} + \underbrace{\gamma}_{\text{discount factor}} \cdot \underbrace{\max_a Q(s_{t+1}, a)}_{\substack{\text{estimate of optimal future value} \\ \text{learned value}}} \right)$$

Estos valores se van almacenando en lo que se denomina tabla Q que almacena los valores que se van produciendo. La probabilidad de seleccionar un camino bueno es mayor que uno malo. De esta forma el agente cada vez tiende a hacer las acciones que más recompensa le han generado. Aunque se permite la exploración de nuevas políticas dejando siempre una probabilidad de seleccionar otra acción.

Initialized		Actions						
Q-Table		South (S)	North (N)	East (E)	West (W)	Pickup (A)	Dropoff (D)	
States	0	0	0	0	0	0	0	
	1	0	0	0	0	0	0	
	2	0	0	0	0	0	0	
	3	0	0	0	0	0	0	
	4	0	0	0	0	0	0	
699		0	0	0	0	0	0	

Training		Actions						
Q-Table		South (S)	North (N)	East (E)	West (W)	Pickup (A)	Dropoff (D)	
States	0	0	0	0	0	0	0	
	1	-2.300805	-1.91092096	-2.30357004	-2.20599839	-0.3607344	-8.558307	
	2	0	0	0	0	0	0	
	3	0	0	0	0	0	0	
	4	0	0	0	0	0	0	
699		9.94984239	4.02706992	12.96022777	29	3.32877873	3.38230603	

Figura 9. Tabla Q inicializada y actualizada con el entrenamiento.

Existe una versión más avanzada de Q-learning que se **denomina deep reinforcement learning**, que es el algoritmo usado por AlphaGo y AlphaStar para

aprender a jugar a *Go* y *Starcraft*. También es el utilizado por OpenAI para aprender a jugar juegos arcade.

El aprendizaje por refuerzo profundo combina redes neuronales artificiales con una arquitectura de aprendizaje por refuerzo que permite a los agentes aprender las mejores acciones posibles en un entorno virtual para alcanzar sus objetivos. Es decir, une la aproximación a la función y la optimización del objetivo, mapeando los pares de estado y acción a las recompensas esperadas. Una red neuronal puede utilizarse para aproximar una función de valor o una función de política. Es decir, las redes neuronales pueden aprender a mapear estados a valores o pares estado-acción a valores Q. En lugar de utilizar una tabla de búsqueda para almacenar, indexar y actualizar todos los posibles estados y sus valores (lo cual es imposible con problemas muy grandes) podemos entrenar una red neuronal en muestras del espacio de estado o acción para aprender a predecir cuan valiosos son estos en relación con nuestro objetivo en el aprendizaje de refuerzo.

Clústering

Los algoritmos de clústering o agrupamiento son **algoritmos de aprendizaje no supervisado que pretenden obtener el conjunto de clases que conforman una determinada colección de valores de entrenamiento**. Suelen realizar una clasificación a partir de un representante, denominado centroide. Este representante es el elemento que mejor divide cada clúster o grupo y los demás se asocian a él por proximidad. Este tipo de algoritmos normalmente son dependientes del número de clases que estimemos que existen. Aunque existen métodos que son capaces de inferir el número de clases que hay.

Para evaluarlos es muy importante la visualización de estos porque no hay un método analítico para saber si la agrupación es del todo correcta si asumimos que los datos no están etiquetados. Podemos, para entrenar el sistema, tener datos etiquetados y con ellos validar el clúster que ha realizado el algoritmo. Pero estos

valores no son tenidos en cuenta por el algoritmo. La medida más utilizada para medir la similitud entre los casos es la matriz de correlación entre los $n \times n$ casos. Sin embargo, también existen muchos algoritmos que se basan en la maximización de una propiedad estadística llamada verosimilitud. Generalmente, los vectores de un mismo grupo (o clústeres) comparten propiedades comunes. El conocimiento de los grupos puede permitir una descripción sintética de un conjunto de datos multidimensional complejo. De ahí su uso en minería de datos. Esta descripción sintética se consigue sustituyendo la descripción de todos los elementos de un grupo por la de un representante característico de este.

Uno de los algoritmos más conocidos es ***k-means***.




Figura 10. Ejemplo de cómo *k-means* agrupa un conjunto de datos.

K-means necesita como dato de entrada el número de grupos en los que vamos a segmentar la población. A partir de este número k de clúster, el algoritmo coloca primero k puntos aleatorios (centroides). Luego asigna a cualquiera de esos puntos todas las muestras con las distancias más pequeñas.

A continuación, el punto se desplaza a la media de las muestras más cercanas. Esto generará una nueva asignación de muestras, ya que algunas muestras están ahora más cerca de otro centroide. Este proceso se repite de forma iterativa y los grupos se van ajustando hasta que la asignación no cambia más moviendo los puntos.

9.5. Proyectos de investigación sobre aprendizaje automático

Los proyectos de investigación en *machine learning* son actualmente los más prolíficos en inteligencia artificial. Pueden ser aplicados a prácticamente todo, pero por hacer un resumen rápido podemos centrarnos en:

- ▶ Todo tipo de clasificación automática.
- ▶ Reconocimiento de imágenes.
- ▶ Programación de agentes autónomos y robótica.
- ▶ Regresión.
- ▶ Sistemas de recomendación.
- ▶ Procesado de imágenes.
- ▶ Generación de modelos de predicción de todo tipo.
- ▶ Procesado del lenguaje natural.
- ▶ Sistemas cognitivos.
- ▶ Experiencia de usuario.
- ▶ *Lead scoring*: algoritmo que tiene en cuenta una serie de parámetros de los diferentes clientes potenciales que llegan para ordenarlos por prioridad y que los agentes comerciales trabajen de una manera más eficaz.
- ▶ Producción inteligente. Con estos proyectos se logra identificar nuevos modelos, tendencias y estacionalidades que permiten a las empresas adelantarse a futuras ventas y cubrir las necesidades del *stock*.

Los proyectos de *machine learning* suelen requerir de grandes cantidades de computación, por lo que es muy recomendable acudir a soluciones de terceros. Además, como hemos visto, son muy dependientes de la calidad de los datos y de poder acceder a ellos. Se estima que la mayor parte del coste en este tipo de proyectos es la adquisición, procesado y refinamiento de estos datos. Hay que tener en cuenta estas cuestiones a la hora de embarcarse en un proyecto de aprendizaje automático.

Las **principales publicaciones de este medio** son:

- ▶ *EEE Transactions on Pattern Analysis and Machine Intelligence.*
- ▶ *arXiv: Computer Vision and Pattern Recognition.*
- ▶ *Journal of Machine Learning Research.*
- ▶ *arXiv: Learning.*
- ▶ *Expert System with Application.*
- ▶ *International Journal of Computer Vision.*

9.6. Referencias bibliográficas

Marsland, S. (2015). *Machine learning: an algorithmic perspective*. CRC press.

How AI is changing the video game industry: augmentation and synthetic media

AI Business. (26 de febrero de 2020). How AI is changing the video game industry: augmentation and synthetic media. *aibusiness.com*. Recuperado de https://aibusiness.com/author.asp?section_id=789&doc_id=761220

Artículo donde se habla de cómo la IA revolucionará la industria del videojuego.

4 Social Media Data Mining Techniques to Help Grow Your Online Business

Lim, H. (15 de marzo de 2020). 4 Social Media Data Mining Techniques to Help Grow Your Online Business. *hackernoon.com*. Recuperado de <https://hackernoon.com/4-social-media-data-mining-techniques-to-help-grow-your-online-business-o6ch32q4>

Artículo que describe diferentes técnicas de minería de datos útiles para ayudar al crecimiento del negocio *online*.

Deep Reinforcement Learning

Silver, D. (17 de junio de 2016). *Deep Reinforcement Learning* [Mensaje en un blog]. DeepMind. Recuperado de <https://deepmind.com/blog/article/deep-reinforcement-learning>

Artículo donde Deep Mind explica cómo funciona el *deep reinforcement learning* y los experimentos que lo demuestran.

Neural Turing Machines

Graves, A., Wayne, G. y Danihelka, I. (1 de junio de 2014). Neural Turing Machines. *deepmind.com*. Recuperado de <https://deepmind.com/research/publications/neural-turing-machines>

Artículo donde *Deep Mind* donde explica cómo funciona el neural Turing machine.

1. La capacidad de generalización de un algoritmo de *machine learning* viene determinado por:
 - A. Las máquinas no son capaces de aprender, solo repiten patrones previamente almacenados. Es solo una ilusión de que están aprendiendo.
 - B. El sesgo que introduce en el aprendizaje.
 - C. Su capacidad para adaptarse a los datos de entrenamiento.
 - D. A su similitud con la forma que tiene el cerebro de aprender.

2. Los algoritmos de *machine learning* pueden ser de los siguientes tipos:
 - A. Supervisado, individual y multivariante.
 - B. No supervisado, supervisado y clústering.
 - C. No supervisado, supervisado y por refuerzo.
 - D. Por refuerzo, clústering y supervisado.

3. El aprendizaje supervisado se caracteriza por:
 - A. Usar la solución de cada ejemplo como parte del aprendizaje.
 - B. No conocer la solución de los ejemplos para realizar el aprendizaje.
 - C. Usar o supervisado, supervisado y por refuerzo.
 - D. Por refuerzo, clústering y supervisado.

4. El aprendizaje por refuerzo se caracteriza por:
 - A. No necesitar a un instructor que guíe el entrenamiento.
 - B. Usar el *feedback* del entorno como guía para saber si la acción realizada es la correcta.
 - C. Selecciona de forma aleatoria la siguiente acción con base en el *feedback* acumulado.
 - D. Todas las anteriores son correctas.

5. Un problema de clasificación es un problema donde:
 - A. La variable dependiente es discreta y finita.
 - B. Es continua e infinita.
 - C. Es discreta e infinita.
 - D. Ninguna de las anteriores.

6. ¿Cuál de estas afirmaciones es cierta sobre K-NN?
 - A. Es un algoritmo de aprendizaje no supervisado que busca almacenar estados antiguos y su solución para recuperarlas posteriormente.
 - B. Es un algoritmo de aprendizaje supervisado que busca almacenar estados antiguos y su solución para recuperarlas posteriormente.
 - C. Es un algoritmo de aprendizaje no supervisado que agrupa a los ejemplos por proximidad formando clúster.
 - D. Ninguna de las anteriores.

7. ¿Cuál de estas afirmaciones es cierta sobre los árboles de decisión?
 - A. Es un algoritmo no supervisado que permite crear reglas.
 - B. Segmenta el problema con aproximaciones no lineales.
 - C. Es un algoritmo de caja negra.
 - D. Ninguna de las anteriores.

8. ¿Cuál de estas afirmaciones es cierta sobre las redes de neuronas?
 - A. Es un algoritmo de aprendizaje supervisado muy resistente al ruido.
 - B. Es un algoritmo de caja negra.
 - C. Sirve para clasificación y para regresión.
 - D. Todas las anteriores son correctas.

9. ¿Cuál de estas afirmaciones es cierta sobre el aprendizaje por refuerzo?
- A. Utiliza la función de refuerzo que le proporciona el entorno para actualizar la política.
 - B. Solo se almacena el último *feedback* recibido.
 - C. El aprendizaje por refuerzo profundo sustituye la función de recompensa por una red de neuronas.
 - D. Todas las anteriores son correctas.
10. ¿Cuál de estas afirmaciones es cierta sobre el *k-means*?
- A. *K-means* agrupa con base en la distancia de un centroide que se le proporciona como ejemplo.
 - B. *K-means* agrupa con base en la distancia de un centroide que se va calculando en cada iteración como la media de las muestras clasificadas.
 - C. *K-means* agrupa con base en la distancia de un centroide que se va calculando en cada iteración como el elemento más alejado de los elementos del grupo.
 - D. Todas las anteriores son falsas.

Investigación y Gestión de Proyectos en Inteligencia
Artificial

Tema 10. Investigación en sistemas cognitivos

Índice

Esquema


Ideas clave

- 10.1. Introducción y objetivos
- 10.2. Introducción a la computación cognitiva
- 10.3. Elementos de un sistema cognitivo
- 10.4. Big data y computación cognitiva
- 10.5. Percepción computacional
- 10.6. Procesamiento de lenguaje natural
- 10.7. Proyectos de investigación sobre sistemas cognitivos
- 10.8. Referencias bibliográficas

A fondo

- The rise of cognitive computing
- Watson and the Jeopardy! Challenge

Test



10.1. Introducción y objetivos

Los sistemas cognitivos están en auge en los últimos tiempos. Aquí se proporciona una **descripción conceptual de la computación cognitiva y un listado de sus aplicaciones más inmediatas**. Los objetivos planteados son los siguientes:

- ▶ Reconocer las peculiaridades de un sistema cognitivo.
- ▶ Conocer las utilidades de las aplicaciones cognitivas en el ámbito empresarial.
- ▶ Ser capaz de identificar limitaciones de los sistemas cognitivos.

10.2. Introducción a la computación cognitiva

En los últimos años algunos errores asociados a las aplicaciones de inteligencia artificial han aparecido en los medios especializados. Conocido fue el caso de *chatbot* de Microsoft, que en el mismo día realizó comentarios racistas, antisemitas e incluso misóginos.

Accede a la noticia a través del siguiente enlace:

<http://www.elmundo.es/tecnologia/2016/03/28/56f95c2146163fdd268b45d2.html>

Pero hay más, como por ejemplo el caso del *chatbot* de Facebook que «inventó» un nuevo idioma, el sistema de detección facial del iPhone X engañado por una máscara, un coche de conducción autónoma involucrado en un accidente en Las Vegas, etc.

Accede al artículo a través del siguiente enlace:

<https://medium.com/@Synced/2017-in-review-10-ai-failures-4a88da1bdf01>

Estos errores son la prueba de que, aunque son muy importantes los logros conseguidos por la disciplina, todavía queda mucho camino por recorrer.

Muchos de estos fallos se deben a que los creadores de las aplicaciones no han sido capaces de proporcionar a la máquina el contexto adecuado a su caso de uso.

Por ejemplo, en el caso de Face ID, la aplicación de reconocimiento facial del móvil iPhone X, los desarrolladores han entrenado a la aplicación para poder identificar rostros y, por consiguiente, personas. Pero una persona está unida a un tronco, tiene una cabeza, respira... Realmente, ¿entiende la máquina que está identificando a una persona o, por el contrario, se

limita a analizar unas similitudes entre dos representaciones de una realidad? ¿Entiende la máquina de forma plena el contexto de la actividad que está realizando? La respuesta a esta pregunta no es trivial, porque primero tendremos que acordar qué significa «entiende». No obstante, parece obvio que la máquina maneja un contexto mucho más reducido que el que contempla un humano, puesto que este último nunca hubiese proporcionado acceso al teléfono a alguien con una máscara. El humano (medianamente avisado) reconocería que se trata de una máscara y pediría a su portador que se identificase correctamente.

La computación cognitiva se ocupa de la búsqueda de soluciones eficientes que permitan a los humanos colaborar con las máquinas de forma plena y eficaz, para generar nuevos conocimientos y experiencias.

Para ello, una de las principales necesidades es **proporcionar a la máquina contexto sobre el entorno y el objetivo a conseguir**. Por este motivo, las soluciones cognitivas deben hacer uso de un volumen de información muy amplio y diverso, surge aquí la relación entre la computación cognitiva y el paradigma *big data*.

La gran disponibilidad de datos, la reducción del coste de almacenamiento y las mejoras tecnológicas que permiten procesar grandes volúmenes de datos a altas velocidades han impulsado este tipo de soluciones.

Un sistema cognitivo se compone fundamentalmente de **tres principios fundamentales**:

- **Aprendizaje**: el sistema debe ser capaz de aprender en base a un conjunto de observaciones y realizar predicciones sobre un dominio concreto.

- ▶ **Modelado**: el aprendizaje toma como base la representación de un modelo y un conjunto de reglas de inferencia.
- ▶ **Generación de hipótesis**: un sistema cognitivo debe asumir que no existe una única respuesta válida. Es decir, un sistema cognitivo es un sistema probabilístico capaz de emitir varias respuestas dando una probabilidad a cada una de ellas.

Estos tres principios fundamentales **se basan todos en el almacenamiento, catalogación y uso eficiente de datos** que guían la toma de decisiones. Los sistemas cognitivos se encuentran todavía en una fase de desarrollo incipiente. El desarrollo de este tipo de productos involucra aspectos provenientes de otras disciplinas técnicas como el aprendizaje automático, el procesamiento de grandes volúmenes de datos, el internet de las cosas, procesamiento del lenguaje natural, razonamiento probabilístico, visualización, etc.

Los sistemas cognitivos están orientados a entornos probabilísticos, no determinísticos.

Un ejemplo típico de este escenario es el entorno clínico. Los síntomas del paciente invitan a pensar en una enfermedad concreta con una determinada probabilidad de acierto. El trabajo del facultativo en muchas ocasiones consiste en ir explorando el amplio abanico de opciones hasta localizar la raíz del problema de forma concreta. En general, se puede decir que este tipo de sistemas está enfocado para contextos que deben trabajar en un entorno de incertidumbre teniendo a su disposición una importante variedad de datos de distinta complejidad.

10.3. Elementos de un sistema cognitivo

Un sistema cognitivo consta de diferentes elementos que incluyen desde la capa de *hardware* al *software* y modelos implementados. Aunque cada solución concreta particulariza su propio diseño, es posible caracterizar una serie de elementos comunes. La Figura 1 muestra los componentes principales de un sistema cognitivo:




Figura 1. Elementos de un sistema cognitivo. Fuente: Hurwitz, Kaufman y Bowles, 2015.

Un **sistema cognitivo se alimenta de datos**. Estos datos pueden ser estructurados (por ejemplo, los procedentes de bases de datos relacionales) o **no estructurados** (fotografías, vídeos, sonido, texto...).

Los datos constituirán la base para la toma de decisiones. **Gracias a ellos el sistema puede interpretar el entorno y crear los modelos adecuados**. Los datos precisan de una infraestructura de almacenamiento. Esta infraestructura admite muchas modalidades, normalmente basadas en productos en la nube.

De cara a planificar los recursos necesarios, debemos comprender que un sistema de estas características no solo tiene que almacenar los datos que recibe de entrada, la propia actividad del sistema y los modelos desarrollados crean nuevos datos que también alimentan al sistema. Además, el producto también puede contar con fuentes de datos internas y permanentes como, por ejemplo, las referidas a restricciones de contexto que se quieren mantener de forma constante.

El acceso a los datos se gestiona a través de una capa cuya labor es precisamente intermediar con la capa de almacenamiento. **El módulo de acceso a datos prepara los datos para su consumo y es el encargado de verificar que la calidad de los datos es adecuada**, monitorizando constantemente el proceso. Sobre esta capa se mantiene un corpus, con el cometido de codificar computacionalmente el conocimiento existente, una capa de servicios de procesamiento y una capa de servicios analíticos.

Un corpus de conocimiento estructura y codifica todo el conocimiento asociado a un ámbito concreto. Para su construcción es habitual recurrir al uso de ontologías. Estas ontologías permiten definir los conceptos, establecer sus propiedades y fijar relaciones entre ellos.

De forma continuada un proceso de aprendizaje automático alimenta la toma de decisiones del sistema. El proceso parte de una hipótesis como explicación verificable ante un hecho observado. Dicha hipótesis es verificada mediante datos para finalmente llegar a una conclusión que culmina en una acción o decisión. El proceso de aprendizaje conlleva un ajuste continuo del modelo o de los modelos.

Por último, es preciso crear varios componentes que facilitan la interacción máquina-humano e, incluso, máquina-máquina. La capa de visualización ayuda a interpretar los resultados y acciones sugeridas por el sistema, mientras que los servicios API

(por sus siglas en inglés: *Application Program Interface*) facilitan el acceso automatizado a las funcionalidades que ofrece el sistema.

Diseño de sistemas cognitivos

En su sistema de computación cognitiva el modelo hace referencia tanto al corpus como a los algoritmos que permiten ejecutar la toma de decisiones. El modelo desarrollado por los programadores iniciales está cambiando continuamente. El **aprendizaje continuo es la esencia de un sistema cognitivo**. Dicho aprendizaje solo se culmina si el sistema es capaz de actualizar constantemente el modelo que guía su actividad. Asegurar esta actualización continua del modelo es el principal requisito a la hora de diseñar un sistema cognitivo.

Todo sistema cognitivo se debe diseñar de forma que:

- ▶ Permita la ingesta en el sistema de toda la información necesaria.
- ▶ Organice los datos de forma que se permita el acceso y análisis de forma eficiente.
- ▶ Permita actualizar el corpus y los modelos iniciales.
- ▶ Asegure el cumplimiento de la normativa vigente y los estándares de seguridad adecuados.
- ▶ Permita emplear las técnicas adecuadas para la extracción de conocimiento y toma de decisiones.

Ontologías

Las ontologías **permiten la representación formal de los conceptos de un dominio y las relaciones entre ellos**. De esta forma no solo se modela el conocimiento existente, sino que, además, permite la estandarización del dominio

creando un mapa conceptual que es compartido y comúnmente usado. Las ontologías facilitan el almacenamiento ordenado de información, la búsqueda de recursos y la comunicación entre distintos dispositivos. Gracias a las ontologías podemos también formalizar muchas de las suposiciones de partida entre los elementos, en base a relaciones entre conceptos, atributos de los elementos, etc.

Las ontologías se suelen representar gráficamente en forma de grafo para facilitar su comprensión.




Figura 2. Ejemplo de parte de una ontología asociada al dominio del vino. Fuente:

https://protege.stanford.edu/publications/ontology_development/image002.jpg

Otro ejemplo algo más elaborado podría ser el que representa la Figura 3.




Figura 3. Ejemplo de ontología clínica para una aplicación de telemedicina. Fuente:

https://www.researchgate.net/figure/E-health-application-ontology-Medical-applications-which-are-currently-available-on-the_269700233

La herramienta Prótegé (<https://protege.stanford.edu/>), gestionada ahora por la Universidad de Stanford en colaboración con la Universidad de Manchester, es una de las herramientas más útiles para la creación de ontologías.

10.4. Big data y computación cognitiva

Se ha insistido mucho en este tema en la necesidad de disponer de grandes volúmenes de datos como materia primera para generar aplicaciones realmente eficaces. En otro caso, los sistemas cognitivos podrían encontrar serias dificultades para mostrar resultados consistentes, fiables y relevantes. Además, y dado que se precisa tanto de datos estructurados como no estructurados, es necesario emplear otras tecnologías distintas de las bases de datos relacionales, puesto que estas últimas están diseñadas específicamente para interactuar con datos relacionales.

Big data no hace referencia a una tecnología concreta. Big data hace referencia a un paradigma centrado en capturar información de fuentes de datos diversas, que se generan a una velocidad considerable y con un gran volumen. Y esta actividad viene inevitablemente unida a la obtención de valor para el negocio.

Acumular datos sin más no tiene ningún sentido. Es la obtención de información útil y conocimiento que apoye la toma de decisiones la razón de ser de este paradigma.

Las tecnologías que apoyan este nuevo proceso son varias y diversas. Intentado hacer una generalización, podríamos detectar algunas grandes categorías:

- ▶ Bases de datos NoSQL (por sus siglas en inglés *Structured Query Language*).
- ▶ Sistemas de archivos distribuidos.
- ▶ Sistemas de cómputo en paralelo.

Bases de datos NoSQL

NoSQL hace referencia a Non-only SQL. Estas bases de datos **se caracterizan por la facilidad de desarrollo, el desempeño escalable, la alta disponibilidad y la resiliencia.**

A cambio de permitir mayores cotas de flexibilidad y versatilidad, **estas herramientas han debido renunciar en mayor o menor medida a las propiedades ACID (*Atomicity, Consistency, Isolation and Durability*)** de los sistemas de bases de datos relacionales tradicionales.

ACID, como acabamos de ver, es el acrónimo para referirse a las propiedades de atomicidad, consistencia, aislamiento y durabilidad:

- ▶ La **atomicidad** implica que una transacción se ejecuta completamente o no se ejecuta en absoluto.
- ▶ **Consistencia** quiere decir que una vez se ha ejecutado una transacción, los datos deben acoplarse al esquema de la base de datos.
- ▶ El **aislamiento** requiere que las transacciones simultáneas se ejecuten por separado.
- ▶ La **durabilidad** es la capacidad de recuperarse de un error inesperado del sistema o de un corte de energía y volver al último estado conocido.

Mantener estas propiedades ayuda a construir bases de datos más robustas, menos propensas a fallos y más formales. Sin embargo, para conseguir estas propiedades, los sistemas gestores de bases de datos incurren en penalización de rendimiento que no son sostenibles cuando la base de datos escala a grandes tamaños. Por ese

motivo, los sistemas NoSQL buscan crear bases de datos sin estas restricciones para ser mucho más rápidos y poder procesar mayor número de datos. A cambio, estos sistemas son más vulnerables a fallos.

Existen diversos tipos de bases de datos NoSQL, incluyendo bases de datos documentales y bases de datos orientadas a grafos. Un ejemplo es MongoDB o Cassandra.

Sistemas de archivos distribuidos

Un sistema de archivos distribuidos **proporciona un sistema de almacenamiento permanente apoyándose en una infraestructura en red**. De esta forma se puede aprovechar el potencial de una red de computadoras y escalar las capacidades de almacenamiento en un sistema multiusuario.

Los sistemas de archivos distribuidos son esenciales en el ecosistema *big data*. **La replicación de la información es una de sus características esenciales**. De esta forma se facilita el acceso concurrente de los usuarios a la información. Adicionalmente, los sistemas *big data* de archivos distribuidos cuentan con una configuración diferente a los sistemas de archivos tradicionales.

Una de las diferencias más relevantes es el **tamaño de bloque de disco**. El tamaño de bloque de disco es mucho más grande en los sistemas *big data* que en sistemas de archivos tradicionales. De esta forma y con una sola búsqueda y acceso se accede a mucha más información de golpe. A cambio, los sistemas *big data* son una muy mala opción si una de las funcionalidades principales del sistema debe ser la actualización y modificación continua de la información.

Sistemas de cómputo en paralelo

Gran parte de los procesamiento de aprendizaje automático implican la realización de múltiples cálculos repetitivos o susceptibles de ser descompuestos en tareas similares que se realizan una y otra vez. Los sistemas de cómputo en paralelo

aprovechan la capacidad de cálculo de redes de computadoras conectadas entre sí proporcionando la escalabilidad de cómputo necesaria para procesar grandes volúmenes de información de forma eficiente.

10.5. Percepción computacional

Los **sistemas cognitivos intentan interactuar con los humanos usando su mismo lenguaje**. Como hemos comentado anteriormente, la idea es que los sistemas cognitivos puedan procesar el lenguaje natural para que puedan entender a los usuarios que los usan, por ejemplo, mediante órdenes de voz. También necesitan en según qué entornos percibir lo que le rodea. La percepción computacional es una serie de algoritmos que permiten a un *software* reconocer imágenes, sonidos, etc. De forma que puede procesar la voz humana o puede procesar el rostro de una persona para reconocerle.

Podemos definir la **percepción** como la capacidad de los organismos para obtener información sobre su ambiente a partir de los efectos que los estímulos producen sobre los sistemas sensoriales. La **percepción computacional** es la capacidad que tiene las máquinas de imitar la percepción de los organismos.

Tradicionalmente, hacer que una computadora procesara imágenes, por ejemplo, en tiempo real, era algo bastante difícil de conseguir. Sin embargo, con las mejoras de las técnicas y el aumento de la potencia de cálculo disponible, **actualmente un computador puede reconocer, clasificar, etiquetar y analizar imágenes de forma bastante solvente**. Aunque sigue siendo una de las tareas pendientes de mejora, las técnicas de *machine learning* utilizadas para la visión por computador, por ejemplo, nos permiten hacer cosas que eran impensables hace tiempo.

Las redes más usadas para el procesado de imágenes son las **redes convolucionales y los autoencoders**. Estas se van aplicando por capas y estas capas se concatenan unas con las otras. Es muy típico que en las primeras capas la red aprenda unas simples características y sobre ellas se va construyendo otras capas que realizan otras áreas, por ejemplo, la diferenciación de objetos.

Los **autoencoders** ayudan a la extracción de características de una imagen, lo que hace que se elimine el paso previo de clasificación que se solía dar antiguamente.

Las **redes convolucionales** se utilizan también para procesar las imágenes. Normalmente se aplican en las primeras capas para extraer características, reducir la dimensión de la imagen, etc.

Finalmente, se suelen utilizar **perceptrones multicapa simples** para la etapa de **clasificación**. Un ejemplo de esta arquitectura por capas se puede ver en la Figura 4.




Figura 4. Esquema de una red que procesa imágenes con diferentes capas. Fuente:

<https://www.ellaberintodefalken.com/2019/10/vision-artificial-redes-convolucionales-CNN.html>

Con estos modelos se han conseguido importantes avances en esta área. Aquí tenemos un ejemplo de una aplicación para crear tiendas autónomas sin dependientes:

Accede al siguiente enlace: <https://computerhoy.com/noticias/tecnologia/startup-francesa-tiendas-autonomas-inteligencia-vision-artificial-712177>

La **visión artificial** tiene diferentes aplicaciones, podemos resumirlas como:

- ▶ **Reconocimiento de objetos:** decir qué objetos hay en una imagen, etiquetar las caras en una fotografía, etc.
- ▶ **Reconstrucción de objetos 3D a partir de objetos 2D.** Poder construir a partir de una serie de imágenes en 2D un objeto en 3D. Se le suele denominar **fotometría**.
- ▶ **Análisis de vídeo:** reconocer en tiempo real intrusos, la posición de un objeto, la distancia. A veces se apoyan en sensores de infrarrojo que ayudan a estos cálculos.
- ▶ **Aplicaciones industriales.** Por ejemplo, se utiliza visión artificial para el control de calidad de ciertos productos, para su clasificación, el guiado de robots, la medición de objetos, etc.

Para conseguir esos resultados se necesita normalmente varias etapas. Normalmente hay que procesar de alguna forma la señal visual para ayudar a los algoritmos de *machine learning* a trabajar con las imágenes. Así que pueden procesarse la imagen para eliminar ruido, aplicar la transformada de Fourier para analizarla, detectar los bordes de los objetos, etc.

La **iluminación** es un aspecto clave en la visión artificial. Muchas veces un objeto no se reconoce por cambios en la iluminación de la escena. Así que, si utilizamos la visión artificial en un entorno controlado, es mejor ayudar al sistema de visión con una iluminación apropiada.

Ventajas de la visión artificial

Algunas **ventajas de la visión artificial sobre la humana** son las siguientes: la visión humana es mejor para la interpretación cualitativa y para interpretar escenas sin estructura, mientras que en la visión artificial destaca que es mejor en tomar medidas cuantitativas sobre escenas con cierta estructura, precisión y repetibilidad.

Por ejemplo, en una línea de producción, un sistema de visión artificial puede inspeccionar cientos, o incluso miles, de piezas por minuto. También puede procesar detalles más pequeños si la cámara tiene mucha resolución o aumento.

Procesamiento y generación de sonido

Además de la visión como percepción computacional debemos tener en cuenta también el **procesamiento del sonido**. Y no solo el procesamiento sino la generación de sonido. Trabajos relacionados con esta área son los siguientes:

- ▶ Síntesis de voz.
- ▶ Reconocimiento del habla.
- ▶ Traducción automática.
- ▶ Generación de música.
- ▶ Reconocimiento de objetos mediante el audio.

10.6. Procesamiento de lenguaje natural

Se ha insistido mucho en lo que llevamos de tema en que los sistemas cognitivos introducen nuevos elementos en la relación humano-máquina. Efectivamente, muchos de estos sistemas contemplan en su funcionalidad una interacción continua entre las personas y las máquinas.

El principal medio de expresión de los humanos es el lenguaje, ya sea oral o escrito. Por tanto, las **técnicas de procesamiento del lenguaje natural** forman un papel esencial aquí.

Para comprender el mensaje emitido, las técnicas de procesamiento del lenguaje natural deben considerar el momento o fecha en la que se emite el mensaje, identificar al emisor, detectar los pronombres y reconocer a quién se están refiriendo, quién habla de quién, etc.

Es preciso catalogar correctamente los diferentes conceptos (personas, lugares, cosas) y la relación que guardan entre ellos. El orden de las palabras, la propia sintaxis, el uso de sinónimos y antónimos, frases hechas..., producen variaciones y particularizaciones del significado que es preciso aprehender.

La ambigüedad y el uso de palabras como los conectores contribuyen a añadir una capa adicional de complejidad al proceso. El análisis probabilístico de las palabras que aparecen (y el orden en el que lo hacen) en los textos empleados durante el proceso de aprendizaje puede añadir algo de claridad a la tarea.

Las **cadenas de Márkov** son ampliamente utilizadas para el análisis probabilístico de cadenas de texto. En la teoría de la probabilidad se conoce como cadena de Márkov o modelo de Márkov a un **tipo especial de proceso estocástico discreto** en el que la probabilidad de que ocurra un evento depende solamente del evento inmediatamente anterior.

Esta característica de falta de memoria recibe el nombre de propiedad de Markov: https://es.wikipedia.org/wiki/Cadena_de_M%C3%A1rkov

El lenguaje hablado o escrito constituye un ejemplo de dato no estructurado. Interpretar correctamente mensajes lingüísticos es una tarea nada trivial debido a la importancia del contexto. El significado de una expresión concreta puede variar en función de la situación y la entonación. Por ejemplo, imaginemos el siguiente diálogo:

—Buenas tardes, Sr. Martín. Le llamamos del servicio de atención al cliente para hacerle una pregunta rápida que nos ayuda a mejorar: ¿está satisfecho con nuestros servicios?

—Sí, mucho.

¿Qué ha interpretado la operadora ante la respuesta del cliente? Leyendo el texto sin disponer de más información, parece simple deducir que la respuesta del cliente es positiva. Por tanto, un punto extra para la compañía y su impecable servicio. No obstante, un mensaje oral viene acompañado de una entonación concreta. El tono del mensaje forma parte del mensaje al igual que los gestos del emisor. El tono del mensaje puede transmitir sarcasmo, ironía, alegría y un sinnúmero de connotaciones que complementan el mensaje.

Las técnicas de *deep learning* han permitido evolucionar las técnicas de procesamiento del lenguaje gracias a su potencia para representar el proceso de aprendizaje y el propio conocimiento. En este ámbito, una de las mayores innovaciones ha sido **considerar el vecindario de una palabra como fuente muy**

relevante para determinar el significado concreto de esa palabra. De esta forma, gracias al *deep learning* se ha conseguido crear redes que son capaces de categorizar una palabra por proximidad, usando redes de reducción de dimensionalidad con algoritmos no supervisados. Estos algoritmos se conocen con el nombre de **embedding** y permiten comprimir una red de palabras representada como vectores equidistantes de un espacio multidimensional K (por ejemplo, usando *one-hot encoding*) a un espacio multidimensional N menor que K que representa la distancia semántica entre diferentes palabras. Una de las principales herramientas para conseguir esto es **Word2vec**. Word2Vec es una red preentrenada que agrupa palabras de forma compacta.




Figura 5. Ejemplo de uso de Word2vec con ciertas palabras. Fuente: <https://www.springboard.com/blog/introduction-word-embeddings/>

Usando este tipo de herramientas se consigue codificar palabras que, usando redes de neuronas profundas, son capaces de realizar multitud de tareas.

De forma concreta, se han mostrado **aplicaciones muy relevantes** en campos como:

- **Clasificación de texto y documentos:** incluyendo clasificar mensajes según la tonalidad positiva o negativa mostrada, filtrado de correo electrónico no deseado, clasificación automática de noticias, sentencias, informes, según su categoría, etc.

- ▶ **Modelado del lenguaje:** con el objetivo de sugerir correcciones gramaticales, sugerencias de palabras, etc.
- ▶ **Reconocimiento del habla:** posibilitando, por ejemplo, generar de forma automática los subtítulos de un vídeo.
- ▶ **Descripción automática:** posibilitando describir una imagen, vídeo... de forma automática.
- ▶ **Traducción automática.**
- ▶ **Resumen automático de documentos:** lo que permitiría, por ejemplo, resumir de forma automática una sentencia judicial.
- ▶ **Respuesta automática:** faculta a la máquina para interactuar con el humano proporcionando de forma directa la pregunta a una pregunta formulada.
- ▶ **Generación automática de texto (GPT 2/3).**

10.7. Proyectos de investigación sobre sistemas cognitivos

A nivel empresarial, el objetivo principal de la computación cognitiva es apoyar el proceso de toma de decisiones presentando el conocimiento necesario en el momento oportuno de la forma adecuada. Gracias a estas aplicaciones, las compañías pueden diferenciar sus productos y servicios y obtener ventaja sobre sus competidores.

10.8. Referencias bibliográficas

Hurwitz, J., Kaufman, M. y Bowles, A. (2015). *Cognitive Computing and Big Data Analytics*. Estados Unidos: Wiley.

The rise of cognitive computing

Dickinson, M. (9 de noviembre de 2016). The rise of cognitive computing. *BBC Future*. Recuperado de <http://www.bbc.com/storyworks/future/an-intelligent-future/the-rise-of-cognitive-computing>

Reportaje de la BBC sobre la computación cognitiva, aplicaciones y futuro.

Watson and the Jeopardy! Challenge

IBM Research (6 de noviembre de 2013). *Watson and the Jeopardy! Challenge* [Vídeo]. YouTube. Recuperado de <https://youtu.be/P18EdAKuC1U>

Este vídeo nos permite conocer un poco más a fondo la historia de Watson y su participación en el programa *Jeopardy*.

1. En lo que se refiere a la relación entre *big data* y computación cognitiva:
 - A. Las soluciones cognitivas ayudan a que las tecnologías *big data* sean más eficientes.
 - B. Los sistemas cognitivos se alimentan de información *big data* para tomar las mejores decisiones.
 - C. Ambos usan las mismas tecnologías.
 - D. La computación cognitiva abarata los costes de las tecnologías *big data*.

2. Los tres principios fundamentales que componen un sistema cognitivo son:
 - A. Aprendizaje, modelado y análisis estadístico.
 - B. Inferencia, modelado y módulo de procesamiento de lenguaje natural.
 - C. Aprendizaje, modelado y módulo de procesamiento de lenguaje natural.
 - D. Aprendizaje, modelado y generación de hipótesis.

3. Son elementos de un sistema cognitivo:
 - A. Una infraestructura de almacenamiento.
 - B. Una capa de servicios analíticos.
 - C. Una capa de servicios de visualización.
 - D. Todos los anteriores.

4. Las ontologías sirven para:
 - A. Representar formalmente el conocimiento asociado a un dominio con las relaciones entre conceptos.
 - B. Analizar grafos.
 - C. Acceder a datos *big data*.
 - D. Ninguno de los anteriores.

5. Para diseñar un sistema cognitivo se debe tener en cuenta:
 - A. Organizar los datos de forma eficiente.
 - B. Permitir la ingesta de todos los datos necesarios.
 - C. Asegurar el cumplimiento de la normativa vigente.
 - D. Todas las anteriores.

6. ¿Qué es el *embedding*?
 - A. Usar tecnologías *deep learning* para clasificar palabras en grupos gramaticales.
 - B. El uso de *deep learning* para agrupar texto como vectores de distancia de forma compacta.
 - C. Emplear *deep learning* para generar texto de forma automática.
 - D. Ninguna de las anteriores.

7. Las bases de datos NoSQL:
 - A. Son adecuadas para datos estructurados.
 - B. Son las más lentas de todas.
 - C. Son adecuadas para datos no estructurados.
 - D. Prohíben el uso de SQL o variantes parecidas.

8. Los sistemas de archivos distribuidos para el *big data*:
 - A. No replican los datos, pues es ineficiente.
 - B. Replican la información para agilizar el acceso.
 - C. Tienen un tamaño de bloque similar a los sistemas operativos básicos.
 - D. Todas la anteriores son ciertas.

9. El sistema de IBM Watson:

- A. Es un ejemplo muy primitivo de lo que se puede conseguir con la computación cognitiva.
- B. Es una innovación total que ya está preparado para usarse a gran escala independientemente del dominio en multitud de entornos, aunque todavía hay un campo grande de mejora e investigación.
- C. Ha resultado un fracaso total.
- D. No tiene aplicaciones comerciales.

10. Los sistemas de percepción computacional han mejorado mucho en los últimos años principalmente debido a:

- A. Al descubrimiento de nuevos algoritmos de filtrado de imagen.
- B. A la mejora de los modelos basados en *deep learning* y el aumento de la capacidad computacional.
- C. A un aumento de la capacidad de las cámaras y sensores disponibles.
- D. Ninguna de las anteriores.

Investigación y Gestión de Proyectos en Inteligencia
Artificial

Tema 11. Investigación en computación bioinspirada

Índice

Esquema


Ideas clave

- 11.1. Introducción y objetivos
- 11.2. Introducción a la computación bioinspirada
- 11.3. Algoritmos bioinspirados
- 11.4. Sistemas emergentes
- 11.5. Proyectos de investigación sobre computación bioinspirada
- 11.6. Referencias bibliográficas

A fondo

- Algoritmos genéticos y computación evolutiva
 - ¿Qué son los algoritmos genéticos?
- Algoritmo Inmune de Selección Clonal para el problema de Job Shop Scheduling
- Drawing with Ants: Generative Art with Ant Colony Optimization Algorithms

Test



11.1. Introducción y objetivos

En este tema se explica a alto nivel las **diferentes técnicas y algoritmos de inteligencia artificial que han surgido con inspiración en la biología**. Así pues, en este tema presentaremos un conjunto de técnicas y algoritmos o aproximaciones que se han inspirado de alguna forma en sistemas presentes en la naturaleza. Este campo es inmenso y solo queremos dar unas pinceladas sobre el tema, para que tengas un concepto general sobre este tipo de tecnologías.

Tradicionalmente, los humanos hemos intentado imitar el comportamiento de ciertos individuos o procesos naturales para el avance tecnológico. No siempre se han adaptado los sistemas biológicos tal cual existen en la naturaleza (por ejemplo, el hombre no vuela como las aves), pero su estudio siempre ha sido un campo de inspiración para el avance científico y técnico.

No hay que confundir la **computación biológica con la biología computacional**. La computación biológica estudia cómo podemos utilizar elementos de naturaleza biológica para obtener mejores resultados a problemas en la computación. Sin embargo, la biología computacional es el uso de técnicas de computación en el estudio de la biología molecular, procesamiento de ADN, etc. Las ideas detrás de ambos enfoques son similares pero la finalidad no tiene nada que ver.

De forma detallada, los **objetivos** que persigue esta unidad son:

- ▶ Ser capaz de entender cómo funcionan estos sistemas bioinspirados.
- ▶ Conocer los tipos de algoritmos y problemas que existen y que pueden resolverse con ellos.
- ▶ Identificar las principales técnicas y algoritmos, en especial, los relacionados con la computación evolutiva.

- ▶ Conocer los proyectos que se pueden crear o resolver usando computación bioinspirada.

11.2. Introducción a la computación bioinspirada

Como hemos definido anteriormente, la computación bioinspirada o computación biológica es un **área de la inteligencia artificial que se apoya en soluciones inspiradas en la biología para resolver problemas computacionales**. La variedad de algoritmos y de técnicas es enorme y, además, muchas de ellas están siendo la punta de lanza de la IA (inteligencia artificial) actualmente, obteniendo unos resultados asombrosos. Por la inmensidad del área a abarcar, vamos a centrarnos en los **algoritmos de computación evolutiva** y después mencionaremos otros enfoques con menor profundidad.

Para comprender la computación evolutiva tenemos que acudir a las bases de la **teoría de la evolución propuesta por Charles Darwin (1809-1882)** y su **teoría de la selección natural**.

Esta teoría surge después de visitar las islas Galápagos en una expedición geológica. En ellas Darwin observó algunas anécdotas biológicas muy interesantes que le hizo interesarse por la evolución de las especies, ya que encontró similitudes con especies de América pero a la vez diferencias. Darwin en realidad no era biólogo sino geólogo, y no fue hasta este momento cuando comenzó a interesarse más a fondo en temas de biología y de especies.

Por ejemplo, se percató de que, en cada isla, un grupo de especies diferentes de pájaros, muy similares en color, aspecto y tamaño, tenían modificaciones en su pico adaptadas a las necesidades de obtención de alimento, que eran diferentes en cada isla. Por ejemplo, unos tenían el pico más largo, o más curvo o de diferente tamaño.

Tardo varios años en recopilar toda la información que necesitaba para formular su teoría. En ella, describe que las especies evolucionan unas de otras, ramificándose a partir de padres comunes. Algunas de estas especies terminan en extinción y otras

volviéndose a ramificar en nuevas especies, lo que le confiere una forma de árbol. También relacionó el desarrollo embrionario de un individuo con el desarrollo evolutivo de sus estirpes (esto lo extrajo de los fósiles que recolectó en su vida como geólogo), y que las islas u otras barreras geológicas hacían que las especies se adaptaran al entorno de esas zonas.

Darwin sabía que las especies evolucionaban y que el medio en el que se desarrollaban influía, pero no sabía el mecanismo de cómo evolucionaban estas especies. Esto se descubrió paralelamente por **Mendel** (1857-1968) que describió cómo funcionaba la mutación haciendo unos experimentos con plantas de guisantes.

De esta forma, años después con el descubrimiento del ADN, se conformó la teoría completa que sustenta lo que hoy conocemos como la **teoría de la evolución**.

La teoría de la evolución dice que la presión ambiental (reproductiva, por obtener alimentación, competencia con otros animales) es el vehículo del cambio en las especies y el mecanismo del cambio es el cruce genético y la mutación. Es decir, el cruce entre dos especies provoca que parte del ADN de una de ellas se mezcle con parte del ADN de la otra. De forma que el nuevo individuo no tiene exactamente el mismo ADN que los progenitores, sino una mezcla de ambos. Además de esto, otro mecanismo para el cambio es la mutación, que consiste en pequeños cambios en los genes que se producen o no, de forma aleatoria en cada réplica del ADN. De esta forma, un nuevo individuo puede tener un ADN diferente al de sus progenitores. Algunos de estos cambios producen individuos más aptos para el medio en el que se desenvuelven. Mientras que otros cambios hacen a estos individuos menos aptos para su supervivencia. La presión selectiva hace que no todos los individuos acaben transmitiendo sus genes a sus descendientes, bien porque no consiguen aparearse (no son el macho dominante con ese derecho en una manada, por ejemplo) o bien porque mueren antes de poder hacerlo. De esta forma, la probabilidad de que un cambio genético que perjudique la supervivencia de un individuo en un entorno concreto se transmita a los descendientes es menor que la probabilidad de que lo

haga uno beneficioso, ya que este tendrá más probabilidades de reproducirse. Y el tiempo hace el resto. De forma que, en sucesivas generaciones, los individuos con modificaciones que le permiten adaptarse mejor al medio han proliferado y han transmitido estas modificaciones a la mayoría de la población.

Si miramos esto desde un punto de vista computacional, lo que hace la selección natural es un **método de optimización**. La selección natural optimiza a los individuos para resolver una tarea concreta. Que en el caso de la biología es sobrevivir y reproducirse, con todo lo que ello implica. Si una especie no se adapta a los cambios desaparece, lo que da lugar a las extinciones, ya sea porque no se adaptan a un cambio repentino del medio, ya sea porque una versión mejorada de ellos mismos los sustituya en su nicho ecológico.

Ahora extrapolemos esto a un problema de computación. ¿Podemos generar una solución a un problema de computación y hacerla evolucionar para que encuentre la forma de resolver ese problema de la forma más óptima posible?

De esta pregunta surge la **computación evolutiva**.

Computación evolutiva

La computación evolutiva es una **rama de la inteligencia artificial que busca resolver problemas de optimización, inspirándose en los mecanismos de evolución biológica**. Existen diferentes métodos y algoritmos que se pueden englobar dentro de este campo como los algoritmos genéticos, las estrategias evolutivas, la programación genética etc. Ya los desgranaremos en el resto del tema. Pero por ahora vamos a asentar las bases de los conceptos en los que se sustentan todas ellas.

Podemos definir **gen como la unidad mínima de transferencia genética**. Es decir, la unidad mínima que es capaz de sintetizar una macromolécula con función celular. Estos genes tienen memoria y esto permite la herencia ente descendientes.

El **genotipo** es el conjunto de todos los genes de un individuo.

El **fenotipo** es la expresión del genotipo en un individuo concreto, dentro de un ambiente concreto. Es decir, la implementación de ese genotipo.

Ejemplo: hay un gen que codifica el color de los ojos de un individuo. Su genotipo sería la secuencia de bases del gen en concreto y su fenotipo el color que genera al final.

Con estas definiciones, lo que buscan los algoritmos evolutivos es crear una analogía con la evolución natural. Así pues, habrá que representar una cadena de ADN con información mínima útil para realizar una tarea (gen). Estos genes se reproducirán (o no) cruzándose con otros genes y ocasionalmente se cambiará la información de alguno de estos genes mediante una mutación. Este proceso se repetirá hasta encontrar un individuo lo suficientemente bueno como para que resuelva la tarea que debe realizar.

¿Y cómo sabemos si resuelve la tarea? Pues ejecutando dicha tarea y «puntuando» lo bien que lo ha hecho. Esa puntuación es una valoración de lo adaptado que está el individuo al medio.

Aplicaciones

Las aplicaciones de este tipo de algoritmos evolutivos son muchas y está enmarcadas dentro de los algoritmos de optimización. Son capaces de encontrar una forma eficiente de realizar una tarea. Vistos así puede el lector pensar que no son muy diferentes a un algoritmo de búsqueda, que busca la mejor solución entre las posibles soluciones y es cierto. La mayoría de estos algoritmos pueden ser considerados algoritmos de búsqueda, pero tiene ciertas peculiaridades que los hacen especialmente efectivos en determinados entornos. Y es que son bastante buenos en encontrar soluciones subóptimas en problemas que tienen una alta complejidad y donde algoritmos como A* no son viables. También son bastante

robustos a mínimos locales en las búsquedas debido a su componente aleatorio. Por otro lado, su complejidad computacional viene determinada principalmente por **lo costoso que sea evaluar la calidad de la solución**. Es decir, la calidad que cada individuo tiene para resolver el problema. Sí es muy costoso hacerlo, estos algoritmos suelen ser demasiado costosos ya que normalmente necesitan poblaciones grandes de individuos (o soluciones), y habrá que ejecutar la función de evaluación para cada individuo y para cada generación.

Más en concreto, se han utilizado en **diferentes campos** como:

- ▶ La robótica.
- ▶ La optimización de procesos.
- ▶ Fabricación industrial.
- ▶ Economía.
- ▶ Aprendizaje automático en por ejemplo la optimización de algoritmos *de machine learning* como redes de neuronales.

A continuación, veremos algunas de estos métodos con más detalle.

11.3. Algoritmos bioinspirados

A continuación, explicaremos las principales técnicas englobadas en los denominados algoritmos bioinspirados. Haremos más hincapié en los más comunes y utilizados, basándonos en las explicaciones de la selección natural que hemos realizado en el anterior apartado.

Algoritmos genéticos

Los algoritmos genéticos son unos **algoritmos evolutivos que se basan en los principios explicados de la selección natural**. Estos algoritmos pretenden resolver problemas de optimización y búsqueda representando la solución en forma de genes. Estos se cruzan y mutan en sucesivos ciclos para conseguir individuos que son capaces de resolver el problema cada vez mejor.

Así pues, debemos obtener la mejor solución dentro del espacio de soluciones que resuelva un problema planteado, atendiendo a un criterio de evaluación del rendimiento de la solución obtenida. Esto se puede aplicar por tanto a:

- ▶ Búsqueda en un espacio de estados.
- ▶ Clasificación: cuál es el procedimiento que mejor clasifica.
- ▶ Predicción: encontrar el procedimiento que tenga menos fallos.
- ▶ Control: procedimiento que maximice una tarea de control.

En los algoritmos genéticos es muy importante la **codificación**. Es la principal tarea del diseñador del algoritmo. Los algoritmos genéticos deben codificar las diferentes soluciones como un vector o matriz de genes. Estos vectores de genes se los

denomina individuos y codifican una solución particular dentro del espacio de soluciones.

Una **población** es el conjunto de soluciones (individuos) que disponemos en un momento dado. Inicialmente esta población se puede generar de forma aleatoria o con algo más de conocimiento del dominio. A cada uno de estos individuos se le aplica una serie de operadores genéticos que transforman una población en otra.

¿Y cuáles son esos operadores genéticos?

- ▶ **Selección.** Se selecciona a los mejores candidatos para la reproducción. Se genera una población intermedia del mismo tamaño que la original normalmente. Hay diferentes técnicas a la hora de seleccionar cuáles son los individuos candidatos para reproducirse.
- ▶ **Cruce.** Se seleccionan de dos en dos los individuos de esa población intermedia y se cruzan de alguna forma. Hay diferentes técnicas de cruce como cruce simple por la mitad, cruce uniforme donde cada gen se cruza con su homónimo en la pareja, cruzar por múltiples puntos, etc.
- ▶ **Mutación.** Se modifica de forma aleatoria mediante una probabilidad de mutación los genes de los individuos recién cruzados.
- ▶ **Inversión.** Se invierten algunos de los genes (en caso de que la codificación sea binaria), también se puede coger un grupo de ellos y darles la vuelta.

Para finalizar tenemos una función que se denomina **función de fitness** que evalúa las soluciones (los individuos) para determinar cuáles son los más aptos, es decir, los que mejor resuelven el problema. Esta función de fitness debe resumir el comportamiento del individuo con un número para poder comparar unos con otros.

Los algoritmos genéticos son muy eficientes a la hora de encontrar soluciones más o menos optimas a un problema. Y son propensos a una convergencia prematura en un mínimo local. Sobre todo, si solo usamos cruce. Esto es debido a **que ciertos rasgos genéticos se pierden** (a esto se le denomina pérdida de alelos) en los cruces con lo que se pierde variabilidad genética. La mutación aquí es un factor importante para mantener esa variabilidad genética. Después de unas cuantas generaciones, todos los individuos tienen un valor de adecuación o fitness similar, por lo tanto, deja de haber **presión selectiva** y, por tanto, se deja de evolucionar (todos tiene la misma probabilidad de reproducirse). Par evitarlo, **surgen diferentes técnicas** que favorecen que aumente o disminuya la presión selectiva para dar oportunidades a que rasgos óptimos en individuos no óptimos puedan formar parte de soluciones mejores y no se pierdan por el camino. Para ellos hay diferentes tipos de selección.

Tipos de selección

La selección por ruleta es similar a tirar un dado donde los individuos con mejor fitness tienen más probabilidades de acertar. Acertar en este caso es reproducirse.




Figura 1. Selección por ruleta. Fuente: <https://stackoverflow.com/questions/23183862/genetic-programming-difference-between-roulette-rank-and-tournament-selection>

En la **selección jerárquica** se ordena a la población de mayor a menor según su fitness y se selecciona el individuo en proporción al rango que ocupa calculando una probabilidad.

En la selección por **torneos** se eligen K elementos de la población y se selecciona aquel que tenga mejor *fitness*. Normalmente este tipo de selección relaja la presión selectiva lo que hace que la diversidad genética sea mayor.




Figura 2. Selección por torneos. Fuente: <https://jeongchul.tistory.com/573>

La mutación es muy importante en los algoritmos genéticos. Sin ella, estos algoritmos convergerían muy rápidamente a un mínimo local. Además, la mutación permite evitar la pérdida de información genética ya que puede recuperar alelos perdidos mediante cruces. También permite aleatorizar las búsquedas y así poder encontrar nuevos mínimos locales. Normalmente en las primeras fases se potencia más la exploración (mutación) y después la explotación (cruce), aunque para salir de un mínimo se puede dar algún arreón de mutación en algún momento concreto. En cualquier caso, la probabilidad de mutación puede ser variable bajo algún criterio que fije el diseñador del algoritmo.

Y, por último, la función de **fitness** que es la que nos determina cómo de bueno es un individuo y la que guía la búsqueda. Normalmente se busca minimizar la función, aunque también se puede maximizar en función de cómo lo consideres.

Ejemplo

Vamos a ver un ejemplo de cómo codificar el problema del viajero usando algoritmos genéticos y realizaremos una iteración de este.

Imaginemos que queremos codificar cuatro ciudades, podemos utilizar 2 bits.

Codificación
00
01
10
11

La codificación de un individuo puede ser 2 bits y un individuo codificarse así:

1 => 3 => 2 => 4 = 00100111

Generamos una población aleatoria:

10101010

11011001

00010101

01010101

Después valoramos con la función de fitness (la distancia recorrida):

10101010 => 3

11011001 => 2

00010101 => 4

01010101 => 2

Si usamos ruleta decimos que la probabilidad de ser elegido será más alta para el individuo 2 y 4. Supongamos que se eligen ambos para el cruce. Se cruzan con cruce simple.

11011001 x **01010101** => 11010101

Se muta con una probabilidad 11010101 => 11010111

Se repite hasta tener cuatro nuevos individuos.

Se repite el proceso hasta que no se mejore más.

Esta codificación tiene un problema y es que permite visitar la misma ciudad dos veces. Estos individuos serían erróneos. ¿Qué sucede con ellos? Se les pueden penalizar fuertemente con el fitness o impedir que se generen. Pero la solución más eficiente es codificar de otra forma el problema.

Podemos codificar el problema de forma que ordenamos las ciudades de menor a mayor según un criterio arbitrario. Cuando codificamos un número, en binario, codificamos la posición de la ciudad en la lista. De forma que 0101 no significa que vayamos de la ciudad 2 a la 2 sino de la 2 a la 3 (la número 2 de la lista una vez que hemos quitado la segunda). De esta forma podemos codificar el sistema de forma más eficiente (con menos bits) y evitar individuos erróneos. Piensa que cuanto más grandes sean los individuos, el espacio de búsqueda será mayor.

Otra de las cuestiones que debemos tener en cuenta es que, en el cruce, normalmente va implícito una relación entre las diferentes posiciones de los genes. Si la codificación no mantiene esa relación de posición, el cruce guía peor la búsqueda y esta se vuelve más aleatoria.

El algoritmo se muestra en la siguiente Figura 3:




Figura 3. Diagrama de un algoritmo genético.

Estrategias evolutivas

Las estrategias evolutivas son similares a los algoritmos genéticos. La principal diferencia es que **opera con una codificación de valores continuos**. Esto implica que la mutación debe cambiar ya que no existe el concepto de mutación discreta, es decir, no podemos elegir una de las diferentes alternativas del valor del gen, ya que ahora hay infinitos valores. La mutación va a seguir una distribución normal de probabilidad. Esto hace que la heurística de búsqueda se establezca precisamente en el operador de mutación y no en el cruce como en los algoritmos genéticos.

Se codifican los individuos con un vector de codificación x_i y un vector de varianzas σ_i que indica lo alejado que se encuentra de la solución del problema. Pero no sabemos cuál es la solución óptima, por lo tanto, este vector de varianzas en realidad

son predicciones de la distancia al óptimo. Este vector también se evoluciona, por lo tanto, es de esperar que esta predicción mejore con el tiempo.

Los diferentes algoritmos de estrategias evolutivas siguen la notación $(\mu/\rho,\alpha)$ donde:

μ Tamaño de la población.

ρ número de padres que se seleccionan para recombinarse.

α número de individuos en la descendencia.

Lo más simple, el modelo (1+1) - EE

Este es el **algoritmo más básico y es un método de escalada puro**. Un individuo se denota de la siguiente forma $P = x, \sigma$ donde x y σ son el vector de codificación y el de varianza.

En este algoritmo se genera una población intermedia mutando al individuo y después se evalúa. Si es mejor se reemplaza y si no se mantiene el actual. Como solo hay un individuo no hay cruce.

La mutación del vector de soluciones se realiza usando una distribución normal de media 0 y varianza σ .

$$x'_i = x_i + \sigma'_i \cdot N(0,1)$$

Esto tiene sentido debido a que la varianza al principio será muy grande (la distancia a la solución) y los saltos que se produzcan serán más grandes. A medida que nos vayamos acercándonos a la solución, los saltos son más pequeños porque estamos más cerca (exploración vs. explotación).

Para actualizar la varianza se usa la regla de 1/5. Dicha regla lleva una estadística del número de veces que la población ha cambiado y se ha encontrado una mejor solución. Para ello establecemos un valor del número de generaciones que vamos a

tener en cuenta y cuántas veces se ha cambiado en esas generaciones. Esto se denota como γ_s^t donde t es el número de veces que se ha realizado reemplazo y s el número de generaciones anteriores que tenemos en cuenta. Si la ratio ente ellas varia de $1/5$ se incrementa o se decrementa el valor de la varianza siguiendo la siguiente regla:

$$\sigma' = \sigma \cdot \text{const}_d \leftrightarrow \gamma_s^t < 1/5$$

$$\sigma' = \sigma \cdot \text{const}_i \leftrightarrow \gamma_s^t > 1/5$$

Donde const_d y const_i son dos valores. El primero menor que 1 y el segundo mayor que 1.

De esta forma vamos evolucionando el algoritmo hasta que no cambie sustancialmente en una iteración o hasta que encuentre la solución (el error sea admisible).

Este es el ejemplo más simple, pero se pueden extender a modelos con múltiples individuos.

Modelos con múltiples individuos

Estos modelos comparten gran parte de las ideas del ejemplo simple, pero incorporan el operador de cruce. El cruce de dos individuos se realiza haciendo la media aritmética de cada uno de ellos. También hay que cruzar el vector de varianzas, pero este se debe hacer calculando la raíz cuadrada de la suma de las varianzas de los dos individuos.

$$x' = \frac{1}{2} \cdot (x_1 + x_2)$$

$$\sigma' = \sqrt{\sigma_1 + \sigma_2}$$

El ámbito de aplicación de estos algoritmos es el mismo que los algoritmos

genéticos, y se utilizan en vez de estos cuando el sistema a optimizar maneja valores continuos. Así pues, cualquier aplicación realizada con algoritmos genéticos con números reales puede aplicarse a las estrategias evolutivas. Se han demostrado especialmente útiles por ejemplo en el entrenamiento de redes de neuronas, modificando sus pesos mediante estrategias evolutivas.

Programación genética

La programación genética es un algoritmo evolutivo derivado de los algoritmos genéticos propuestos en 1989 por John Koza.

La idea de la programación genética es **evolucionar programas completos**. Para poder hacer esto, debemos crear un lenguaje de programación más sencillo que nos permita encontrar una solución a un problema concreto que queremos obtener. De esta forma a la programación genética debemos darle los operadores y funciones necesarios que estimemos que va a necesitar el algoritmo de la solución. Por ejemplo, si vamos a resolver una ecuación, pues introduciremos operadores, variables, constantes, etc.

La idea del algoritmo consiste en generar una población de programas que intentan resolver el problema que se plantea. En la figura se muestra un ejemplo de un individuo.




Figura 4. Ejemplo de un individuo que calcula una función usando programación genética. Fuente:

https://es.wikipedia.org/wiki/Programaci%C3%B3n_gen%C3%A9tica

Si queremos hacer un programa que calcule una ecuación, el algoritmo funcionaría de la siguiente forma:

- ▶ Se genera un conjunto de ecuaciones aleatorias en forma de árbol (notación polaca o polaca inversa, por ejemplo).
- ▶ Cada ecuación del conjunto de ejemplos contendrá un valor para las variables que se necesitan.
- ▶ Se sustituyen dichos valores en la ecuación representada por el individuo a evaluar, y así se obtiene un valor de la ecuación.
- ▶ Se compara el valor con el esperado y si es el mismo, el individuo resuelve la ecuación y si no es así, la diferencia se utilizará para el cálculo del fitness del individuo.

Se aplican las mismas ideas que en los algoritmos genéticos. Por ejemplo, el **cruce** consistirá en coger un subárbol de cada individuo e intercambiarlos.




Figura 5. Cruce en programación genética.

La **mutación** consiste en cambiar un operador por otro o un valor o variable por otro. También se puede mutar un subárbol generándolo aleatoriamente.

Redes de neuronas

Las redes de neuronas son otros de los sistemas más exitosos con inspiración biológica que se utilizan actualmente. Ya hablamos de ellas anteriormente, por lo que no nos extenderemos demasiado aquí. Simplemente recordaremos su inspiración biológica, basada en la organización del cerebro animal, donde **la potencia de**

cálculo principal se encuentra en las reacciones químicas que se producen en las interconexiones de las células o neuronas. Así pues, las redes de neuronas artificiales llevan el cálculo a las interconexiones de las neuronas y no tanto a estas, que simplemente procesan mínimamente la señal recibida con funciones simple como la sigmoideal.




Figura 6. Esquema de una neurona.

Su uso, como sabemos con el éxito del *deep learning*, está muy extendido actualmente y puede utilizarse en multitud de dominios, debido a que se le considera un aproximador universal de funciones.

Sistema inmunitario artificial

Los sistemas inmunitarios artificiales (AIS) **son una clase de máquinas de aprendizaje basado en reglas computacionalmente inteligentes, inspiradas en los principios y procesos del sistema inmunitario de los seres vivos.** Esos algoritmos son modelados a partir de las características de aprendizaje y memorización del sistema inmunitario y están enfocados en la resolución de problemas, de forma similar a los algoritmos genéticos.

Las técnicas comunes están inspiradas en teorías inmunológicas que explican el

funcionamiento y el comportamiento del sistema inmunitario adquirido. Existen diferentes técnicas, pero nos centramos en la más común, el ***clonal selection algorithm*** o **algoritmo de selección clonal**.

Los algoritmos de selección clonal son una **clase de algoritmos inspirados en la teoría de selección clonal de la inmunidad adquirida**, que explica cómo los linfocitos B y T mejoran su respuesta ante antígenos con el tiempo mediante la maduración de la afinidad. Son interesantes porque pretenden obtener las características del sistema inmunitario que son:

- ▶ Tolerante a fallos.
- ▶ Robusto.
- ▶ Dinámico.
- ▶ Descentralizado.
- ▶ Adaptativo.
- ▶ Autoprotegido.
- ▶ Diverso.

¿Cómo funciona el sistema inmune?

Cuando un animal es expuesto a un antígeno, algunas de sus células derivadas de la médula ósea (linfocitos B) responden produciendo anticuerpos. Cada célula secreta solo un tipo de anticuerpo, que es específico para el antígeno detectado. Al unirse a estos anticuerpos (receptores), y con una segunda señal de células accesorias, como las células T, el antígeno estimula al linfocito B para que prolifere (se divida) y

madure en células secretoras de anticuerpos terminales. A diferencia de los linfocitos B, estas células no se pueden clonar. A estas células terminales se la denomina **células de plasma**. Los linfocitos T son los reguladores de esta respuesta de los linfocitos B. En realidad, son los que detectan a los antígenos cuando estos han infectado alguna célula o han sido procesados por macrófagos mediante un patrón de afinidad. Cada linfocito T responde a un antígeno concreto.

La **selección clonal** hace una analogía de las soluciones candidatas a anticuerpos buscando afinidad. La **afinidad se mide como la semejanza con un patrón antígeno** mediante la evaluación de una función, similar a la función de *fitness*. De forma que el antígeno en realidad es la función de afinidad. Los anticuerpos con mejor afinidad se someten a una clonación proporcional a dicho valor de afinidad y a la mutación de dichos clones. Esta mutación es mayor cuanto menor es la afinidad. Una vez realizada la clonación, estos compiten con la población de anticuerpos existente por ser miembro de la próxima generación.

El **algoritmo** sería el siguiente:

- ▶ Se genera un conjunto de soluciones P candidatas aleatorias.
- ▶ Se selecciona los n mejores individuos en base a una función de afinidad con el patrón antígeno presentado (el problema a resolver).
- ▶ Se clonan los n individuos un número de veces por cada individuo seleccionado. Este número es proporcional a la afinidad de cada individuo. Se puede utilizar la siguiente ecuación donde β es un parámetro ajustable.

$$N_i = \beta \cdot \frac{N}{affinity(i)}$$

- ▶ Se mutan en proporción a la afinidad. Si hay menor afinidad, la mutación es más agresiva. Se puede utilizar la siguiente ecuación para calcular la tasa de mutación donde ρ es un parámetro ajustable.

$$mutationrate(\alpha) = \exp\left(-\rho \cdot \frac{affinityMin}{affinityMax}\right)$$

- ▶ El número de clones se puede realizar siguiendo una distribución normal de media 0 y desviación típica α .
- ▶ Se evalúan de nuevo cada anticuerpo de los generados por clonación.
- ▶ De entre las nuevas soluciones generadas se seleccionan los n mejores y se reemplazan en la población original.
- ▶ Los d anticuerpos con menor afinidad son sustituidos por otros anticuerpos generados aleatoriamente.
- ▶ El proceso continúa hasta alcanzar el criterio de parada.

Algunas **aplicaciones** sobre de estos algoritmos son:

- ▶ Detección de intrusos.
- ▶ Extracción de características.
- ▶ Problemas de optimización.

Optimización multiobjetivo

En un problema de optimización **se tratará de encontrar una solución que represente el valor óptimo para una función objetivo**. Pero en ciencias e ingeniería se dan, en bastantes ocasiones, problemas que requieren la optimización simultánea de más de un objetivo. A esto se le denomina **optimización multiobjetivo**.

Estos problemas se resuelven principalmente con la **optimización de frente de Pareto**. El frente de Pareto es un concepto proveniente de las ciencias económicas que consiste en **realizar una asignación de recursos a los diferentes objetivos de forma que no se pueda mejorar uno sin perjudicar otro**. A esto se le denomina frente de Pareto óptimo o eficiente. Existen multitud de algoritmos que buscan resolver este problema. Uno de los más comunes es NSGA II.

NSGA II (*Non dominated sorting genetic algorithm*)

Se deben definir unas funciones objetivas que se pretenden maximizar. Normalmente ambas funciones son contrarias, es decir, si mejoramos una empeoramos otra. Por ejemplo, una función de beneficio y una función de coste.

Se denomina **dominancia de una solución sobre otra** si cumple las siguientes condiciones:

- ▶ La primera solución es mejor que la segunda en todos los objetivos.
- ▶ La primera solución es estrictamente mejor que la segunda en al menos uno de los objetivos.




Figura 7. Frente de Pareto. La opción C no está en el frente de Pareto ya que A y B lo dominan. Estos a su vez no son dominados por ningún otro, consecuentemente están en la frontera. Fuente:

https://es.wikipedia.org/wiki/Eficiencia_de_Pareto#/media/Archivo:Front_pareto.svg

Para la optimización de un problema con múltiples objetivos no existe una única solución, sino un conjunto de soluciones no dominadas, en la cual no existen soluciones mejores en todos los objetivos.

NSGA II funciona muy similar a un algoritmo genético normal. Tiene las mismas etapas de selección cruce y mutación. La diferencia es que se debe calcular el frente de Pareto de la solución frente a las diferentes funciones de coste y beneficio. Y los criterios de selección se realizan en función de aquellos individuos que generan un frente de Pareto más eficiente sin generar soluciones no dominadas. La nueva población es generada a partir de las configuraciones de los frentes no dominados. Esta nueva población empieza a ser construida con el mejor frente no dominado (F1), continúa con las soluciones del segundo frente (F2), tercero (F3) y así sucesivamente. Como la población es de tamaño $2N$, y solamente existen N

configuraciones que conforman la población descendiente, no todas las configuraciones podrán ser acomodados en la nueva población. Aquellos frentes que no pueden ser acomodados desaparecen.

Este proceso se repite hasta que se obtiene un individuo que satisface los criterios planteados como criterio de parada.

11.4. Sistemas emergentes

Los sistemas emergentes son **sistemas complejos compuestos normalmente por elementos con un comportamiento muy simple, pero que realizan en conjunto un comportamiento poco esperado**. Algunas técnicas empleadas en computación se han basado en este tipo de sistemas para conseguir solucionar problemas complejos. Se caracterizan por resolver problemas, al menos en apariencia, espontáneamente; es decir, sin recurrir a una inteligencia de tipo centralizado o jerarquizado (descendente), sino de forma ascendente, desde la base, a partir de masas de elementos relativamente no inteligentes.

Existen muchas aproximaciones de este tipo para modelizar comportamientos y simularlos computacionalmente como por ejemplo para **simular el comportamiento de manadas (*flock*) o de multitudes se pueden utilizar sistemas de enjambres (*swarm*)** en los que cada individuo se modela con simples reglas que afectan solo a su entorno local. A parte de estas simulaciones que están inspiradas en cómo se comportan los enjambres y manadas de aves, mamíferos o insectos y cómo evitan, por ejemplo, chocarse, existe un grupo de algoritmos que utilizan estos conceptos más allá de la modelización de sistemas sino para resolver problemas de optimización. A continuación, veremos algunos de ellos.

Colonias de hormigas

Los algoritmos basados en colonias de hormigas son algoritmos bioinspirados, que se aprovechan de una característica interesante de las colonias de hormigas. Y es que son capaces de encontrar el camino más corto entre dos puntos de forma automática.



Figura 8. Las hormigas son capaces de encontrar el camino más corto. Fuente:

<http://ornewspaper.blogspot.com/2011/11/la-investigacion-de-operaciones-en-la.html>

El sistema funciona a través del concepto de feromona. Las hormigas artificiales son unas unidades o pequeños agentes que se mueven de forma aleatoria por el espacio de soluciones. Al moverse van dejando una feromona a su paso.

La sustancia emitida puede ser detectada por otras hormigas:

- ▶ La hormiga elige el camino proporcional a la feromona que esté en dicho camino.
- ▶ La feromona del camino se disipa con el tiempo, y si no se vuelve a generar desaparece.
- ▶ Los caminos poco frecuentados casi no tienen posibilidad de ser utilizados, a menos que se encuentre comida y se repita el proceso.

Este comportamiento elemental explica como las hormigas son capaces de seguir caminos cortos hacia lugares relativamente alejados. También son capaces de adaptarse a cambios producidos en el entorno, por ejemplo, a encontrar un nuevo camino si hay un obstáculo.

Lo interesante de las colonias de hormigas es que encontrar el camino más corto

entre dos puntos es una **propiedad emergente** de la propia interacción con el entorno.

Llevado esto al terreno computacional, una hormiga no es más que un pequeño agente que se mueve de forma semialeatoria. Tiene mayor probabilidad de moverse hacia una posición donde antes ha pasado una hormiga que haya dejado su feromona depositada, pero no lo garantiza. Esta aleatoriedad le da al algoritmo cierta capacidad de exploración. También hace que pueda adaptarse las soluciones si el entorno ha cambiado. Las hormigas, por tanto, solo utilizan información local para tomar las decisiones y la memoria colectiva que las comunica es la feromona.

Para que el algoritmo funcione debemos **discretizar el espacio de búsqueda**. La emisión de feromona de nuestra hormiga virtual puede ser global en todo el camino o no. Las hormigas tienen también una cierta memoria. Dicha memoria impide que la hormiga vuelva sobre sus pasos.

La feromona que van dejando las hormigas se va disipando con las sucesivas iteraciones. Esto implica que se van olvidando los caminos por donde no pasan las hormigas (se van olvidando soluciones antiguas subóptimas).

Cada hormiga tiene una simple tabla de decisiones que tiene una entrada por cada nodo al que pueda transitar dentro del espacio de estados discreto. Esta entrada es inversamente proporcional al coste de alcanzar el nodo y directamente proporcional a la feromona del tramo. Se puede usar la siguiente ecuación donde α y β son parámetros de ajuste.

$$probabilidad(tramo\ iaj) a_{ij} = \frac{feromona_{ij}^{\alpha} \cdot \frac{1}{coste_{ij}}^{\beta}}{\sum_{I \in Nodos_i} feromona_{iI}^{\alpha} \cdot \frac{1}{coste_{iI}}^{\beta}}$$

Es decir, la probabilidad de elegir un nodo es el producto entre la feromona del nodo y la inversa del coste de dicho nodo, ajustado por dos parámetros α y β entre el acumulado de todas las feromonas y los costes de todos los posibles nodos

adyacentes al nodo actual donde está la hormiga.

El rastro de la feromona que deja la hormiga en cada tramo se puede calcular con la siguiente ecuación:

$$\Delta\tau_{ij} = \begin{cases} \frac{1}{Longitud(C)} & si\ i,j \in C \\ 0 & en\ caso\ contrario \end{cases}$$

La disipación de la feromona con el tiempo se calcula de la siguiente forma:

$$\tau_{ij} = (1 - \rho) \cdot \tau_{ij} + \Delta\tau_{ij}$$

Donde ρ es un parámetro entre 0 y 1 que se le conoce como coeficiente de evaporación.

Podamos añadir **elitismo** si establecemos que la hormiga que ha hecho el camino más corto agrega más feromona.

Aplicaciones de las colonias de hormigas

Los algoritmos de optimización de colonias de hormigas son aplicados en muchos algoritmos de **optimización combinatorio**. Se han adaptado a problemas dinámicos en variables reales, problemas estocásticos, programación paralela y multiobjetivo. Estos algoritmos tienen una ventaja sobre algoritmos genéticos cuando el grafo puede cambiar su estructura de manera dinámica. Los algoritmos de colonias de hormigas pueden seguir ejecutándose de forma permanente y adaptarse a la nueva estructura del grafo. Esto es de mucho interés en los campos de enrutamiento de redes y en los sistemas de transportes urbanos. También se han utilizado para generar arte.

Optimización de enjambres de partículas

Es una **metaheurística que evoca el comportamiento de las partículas en la naturaleza**. En un principio fueron concebidos para elaborar modelos de conducta

social, como por ejemplo los movimientos descritos por los seres vivos en una bandada de aves o en un banco de peces. Sin embargo, se vio que estos algoritmos eran adecuados para resolver problemas de optimización.

Estos algoritmos permiten optimizar un problema a partir de una población de soluciones candidatas, que denominamos partículas. Estas partículas se mueven dentro del espacio de búsqueda según una serie de reglas matemáticas sencillas que tienen en cuenta la posición y la velocidad de la partícula. El movimiento de cada partícula depende de su mejor posición obtenida, así como de la mejor posición global hallada en todo el espacio de búsqueda. A medida que se descubren nuevas y mejores posiciones, estas pasan a orientar los movimientos de las partículas. El proceso se repite con el objetivo, no garantizado, de hallar en algún momento una solución lo suficientemente satisfactoria.

Así pues, cada partícula recuerda su mejor posición y se desplaza con cierta aleatoriedad por el espacio, pero siempre en torno a su mejor posición. Con el tiempo las partículas convergen en los mínimos locales.

Como tienen cierta aleatoriedad, pueden salir de los mínimos locales. Se puede jugar con el grado de aleatoriedad en el cambio de la dirección de la partícula.




Figura 9. Ejemplo de optimización por enjambre de partículas. Fuente:

https://en.wikipedia.org/wiki/Particle_swarm_optimization#/media/File:ParticleSwarmArrowsAnimation.gif

11.5. Proyectos de investigación sobre computación bioinspirada

Los proyectos de investigación en computación bioinspirada son uno de los más activos dentro de la investigación actual. Son áreas candentes en esta investigación e l *deep learning*, los algoritmos genéticos, colonias de hormigas, sistemas de optimización de partículas y enjambres para drones, robótica, etc., Los problemas donde se pueden aplicar estos sistemas de algoritmos son casi infinitos, pero vamos a concretar los más importantes describiendo algunos de ellos:

- ▶ Todo tipo de clasificación automática.
- ▶ Reconocimiento de imágenes.
- ▶ Generación artística artificial.
- ▶ Simulación de vida artificial.
- ▶ Programación de agentes automáticos.
- ▶ Optimización.
- ▶ Sistemas dinámicos.
- ▶ Sistemas de optimización multiobjetivo.

Los proyectos de computación evolutiva y optimización suelen requerir de grandes cantidades de computación, por lo que es muy recomendable acudir a soluciones de terceros. Están en una situación similar a los algoritmos de *machine learning*. Aquí la dependencia de los datos es menor que en *machine learning*, ya que la mayoría de estos algoritmos se emplean en modelos de optimización más que en la de ciencia de datos. Aunque se han visto soluciones híbridas de *machine learning* y metaheurísticas bioinspiradas en multitud de proyectos.

Las **principales publicaciones** de este medio son:

- ▶ *Computers & Structures.*
- ▶ *Journal of Global Optimization.*
- ▶ *IEEE Transactions on Evolutionary Computation.*
- ▶ *Expert System with Application.*
- ▶ *Evolutionary Computation.*

11.6. Referencias bibliográficas

Davis, L. (1991). *Handbook of genetic algorithms*. New York: Van Nostrand Reinhold Company.

Gestal, M., Rabuñal, J. R., Dorado, J. Pazos, A. y Rivero, D. (2010). *Introducción a los algoritmos genéticos y la programación genética*. A Coruña: Universidade da Coruña.

Algoritmos genéticos y computación evolutiva

Marczyk, A. (2004). Algoritmos genéticos y computación evolutiva. *the-geek.org*.
Recuperado de <https://the-geek.org/docs/algen/algen.html>

Libro web donde puede expandir los conocimientos de algunos de los algoritmos que exponemos en este tema.

¿Qué son los algoritmos genéticos?

Brunvelop. (2 de abril de 2020). *Esta I.A. Aprende a caminar con algoritmos genéticos* [Vídeo]. YouTube. https://www.youtube.com/watch?time_continue=27&v=06iwEZokIGk&feature=emb_title

Vídeo explicativo de cómo funciona un algoritmo genético.

Algoritmo Inmune de Selección Clonal para el problema de Job Shop Scheduling

Gómez, W. A. (agosto de 2013). Algoritmo Inmune de Selección Clonal para el problema de Job Shop Scheduling. *Conference IV Congreso Internacional de Computación e Informática del Norte de Chile*. Recuperado de https://www.researchgate.net/publication/258110429_Algoritmo_Inmune_de_Seleccion_Clonal_para_el_problema_de_Job_Shop_Scheduling#:~:text=El%20algoritmo%20de%20selecci%C3%B3n%20clonal%20%28CLONALG%29%20%5B16%5D%20se,la%20cu%20al%20implica%20la%20selecci%C3%B3n%20de%20anticuerpos

Artículo donde se ve una aplicación de la selección clonal de sistemas inmunes en un problema de planificación de tareas.

Drawing with Ants: Generative Art with Ant Colony Optimization Algorithms

LOBSTERS. (18 de enero de 2020). Drawing with Ants: Generative Art with Ant Colony Optimization Algorithms. *colabug.com*. Recuperado de <https://www.colabug.com/2020/0118/6871092/>

Artículo donde se explica cómo generar arte usando colonias de hormigas.

1. ¿Qué es la computación biológica?
 - A. Es el área de conocimiento que estudia cómo podemos utilizar elementos de naturaleza biológica para obtener mejores resultados en problemas de computación.
 - B. Es el uso de técnicas de computación en el estudio de la biología.
 - C. Es el estudio de la biología haciendo una analogía con la computación.
 - D. Ninguna de las anteriores.

2. En la teoría de la selección natural, la presión selectiva sirve para:
 - A. Que se detenga la evolución.
 - B. Que la evolución se produzca, ya que es el mecanismo por el cual las células transmiten la herencia genética.
 - C. Guiar a la evolución para adaptar los individuos al entorno.
 - D. Favorece la mutación de los individuos.

3. ¿Qué es la computación evolutiva?
 - A. Es un conjunto de técnicas que permite a las máquinas aprender de forma supervisada y usar la solución de cada ejemplo como parte del aprendizaje.
 - B. Es la rama de la IA que busca resolver problemas de optimización, inspirándose en mecanismos evolutivos.
 - C. Es la rama de la IA que busca resolver problemas de clasificación, inspirándose en mecanismos evolutivos.
 - D. Ninguna de las anteriores.

4. En los algoritmos genéticos, la mutación sirve para:
 - A. Aportar variabilidad genética.
 - B. Buscar nuevas soluciones y salir de mínimos locales.
 - C. Mantener o recuperar los alelos perdidos.
 - D. Todas las anteriores son correctas.

5. Si hay más presión selectiva en un algoritmo genético, ¿qué sucede?
 - A. Que disminuye la diversidad genética.
 - B. Que aumenta la diversidad genética.
 - C. Que la solución que se obtenga será más óptima.
 - D. Ninguna de las anteriores.

6. Indica el motivo por el cual un algoritmo genético se puede estancar prematuramente:
 - A. Que apenas haya presión selectiva.
 - B. Que apenas haya diversidad genética.
 - C. Que esté estancado en un mínimo local y el mínimo global esté muy lejos, siendo la tasa de mutación no lo suficientemente grande.
 - D. Todas las anteriores.

7. ¿Cómo configurarías un algoritmo genético para maximizar los resultados?
 - A. Al principio pondría tasas de mutación baja para explotar y con el tiempo pondría tasas de mutación alta para explorar.
 - B. No pondría mutación.
 - C. Al principio pondría tasas de mutación alta para explorar y con el tiempo pondría tasas de mutación baja para explotar.
 - D. Ninguna de las anteriores.

8. Las estrategias evolutivas:
- A. Son similares a los algoritmos genéticos pero los datos que procesan son discretos.
 - B. Son similares a los algoritmos genéticos pero los datos que procesan son continuos.
 - C. Sirve para clasificación y para regresión.
 - D. Todas las anteriores son correctas.
9. En cuanto a la optimización multiobjetivo:
- A. Se calcula el frente de Pareto que determina la región de decisión óptima que hace que no se mejore ni empeore ninguna de las funciones objetivo para cada uno de los posibles valores del dominio.
 - B. Pretende optimizar dos algoritmos simultáneamente.
 - C. Pretende aprender un único valor que optimice los múltiples objetivos buscados.
 - D. Todas las anteriores son correctas.
10. ¿Qué es un sistema emergente?
- A. Son sesgos no esperados en los comportamientos aprendidos por los algoritmos de *machine learning*.
 - B. Sistemas complejos compuestos por elementos muy simples de cuyo comportamiento no se puede extrapolar el comportamiento final del conjunto.
 - C. Un sistema que es capaz de extraer soluciones que otros sistemas no permite extraer.
 - D. Todas las anteriores son falsas.

Investigación y Gestión de Proyectos en Inteligencia
Artificial

Tema 12. Implicaciones filosóficas, éticas y legales en la aplicación de la inteligencia artificial

Índice

Esquema

Ideas clave

12.1. Introducción y objetivos

12.2. Contexto legal aplicable a proyectos de inteligencia artificial

12.3. Sesgos, legalidad y responsabilidad

12.4. Seguridad y tolerancia ante ataques

12.5. Explicabilidad de algoritmos

12.6. Referencias bibliográficas


A fondo

Orientaciones y garantías en los procedimientos de anonimización de datos personales

Código de buenas prácticas en protección de datos para proyectos Big Data

Adversarial Examples

Test



12.1. Introducción y objetivos

La aplicación de la inteligencia artificial está unida no solo a retos técnicos o científicos sino también a **retos éticos y legales** propios de una disciplina que está llamada a cambiar notablemente la forma en la que interactuamos con los demás, los métodos de trabajo y toda la actividad económica. En esta unidad nos planteamos los **objetivos** siguientes:

- ▶ Identificar retos éticos y filosóficos en el empleo de la IA (inteligencia artificial).
- ▶ Conocer las peculiaridades legales del trabajo basado en datos.
- ▶ Identificar nuevas tendencias regulatorias que implican cambios a la hora de trabajar con datos.

12.2. Contexto legal aplicable a proyectos de inteligencia artificial

Los proyectos de inteligencia artificial están **basados en datos**. Necesitamos datos para entrenar y para validar los modelos. También necesitamos almacenar y analizar los datos que genera la interacción con el modelo, solo así seremos capaces de determinar si la puesta en práctica de la solución cumple con los objetivos previstos. La evaluación constante de los modelos es lo que permite su mejora y evolución.

Por tanto, los proyectos de inteligencia artificial se ven claramente influenciados por la legislación vigente en materia de protección de datos.

En España, la Agencia Española de Protección de Datos (AEPD), como autoridad de control independiente, tiene encargada la misión de velar por el cumplimiento de la normativa de protección de la información personal.

La agencia es un ente de derecho público, con personalidad jurídica propia y plena capacidad pública y privada, que actúa con plena independencia de las Administraciones públicas en el ejercicio de sus funciones. Se relaciona con el Gobierno a través del Ministerio de Justicia. La **Ley Orgánica de Protección de Datos de Carácter Personal (LOPD) 15/1999, de 13 de diciembre**, regula gran parte de las directrices que se deben tener en cuenta a la hora de manipular información personal.



Figura 1. Página web de la AEPD. Fuente: <https://www.agpd.es/portaIwebAGPD/index-ides-idphp.php>

Bajo el paraguas de la Unión Europea surge el Reglamento General de Protección de Datos (RGPD), con la aspiración de unificar los regímenes de todos los Estados miembros sobre la materia. Aunque entró en vigor el día 25 de mayo de 2016, su cumplimiento solo será obligatorio transcurridos dos años desde esta fecha.

A continuación, se desglosarán **algunas de las características más destacadas de estas normativas**, así como sus implicaciones para la tipología de los proyectos que nos ocupa.

Protección de datos de carácter personal

Se considera un dato de carácter personal **cualquier información concerniente a personas físicas identificadas o identificables**. Por tanto, la legislación no solo contempla como datos de carácter personal aquellos casos en los que es posible identificar unívocamente al individuo en base a un atributo exclusivo como el documento nacional de identidad. También contempla la posibilidad de que dicha identificación pueda producirse en el futuro vía cruce de datos de distintas tipologías.

Por ejemplo, supongamos que tenemos almacenada en un fichero o base de datos información sobre los clientes de una determinada compañía. Supongamos ahora que contamos con campos poco relevantes y genéricos. En esta situación, la compañía decide añadir la edad de cada usuario a la información existente. Si los datos anteriores realmente son

irrelevantes (siempre referido a cuestiones de identificación personal), la edad por sí sola no podría servir para identificar a un individuo, puesto que, ¿cuántas personas hay de 20 años?, ¿y de 35? Las opciones son muy diversas. En estas condiciones, la compañía decide incorporar a la base de datos el género. Ahora las opciones se reducen, evidentemente, hay más personas que tienen 35 años a personas que tienen 35 años y son mujeres (por ejemplo). No obstante, parece poco creíble pensar que solo existe una única persona que tenga 35 años y sea mujer. Animados por lo útil que es insertar este tipo de atributos en el estudio, el responsable del proyecto decide ahora incorporar el código postal del usuario. En esta situación, y si la compañía dispone de especialistas en seguridad y normativa de protección de datos, se levantará una señal de alarma. Con la edad, género y código postal sí que existe una mínima posibilidad de que se pueda identificar de forma unívoca a una persona (especialmente en grupos de edades menos frecuente). En diversos entornos de la materia, a la combinación de los atributos edad, género y código postal se la conoce con el nombre de triada.

Antes de continuar, queremos dejar patente que no se prohíbe el almacenamiento de información personal. Si así fuese, ninguna empresa o institución pública podría funcionar. La **misión de la ley es establecer distintos niveles obligatorios de seguridad y control** en función de la tipología de la información. Incluso dentro de la información que puede ser considerada como información personal existen distintos niveles de criticidad. No es lo mismo almacenar edad, género y código postal, que almacenar el número de la cuenta bancaria o, más crítico todavía, el número completo de la tarjeta de crédito con su fecha de caducidad y código de seguridad.

Las distintas iniciativas regulatorias que van surgiendo se encaminan a posibilitar a los usuarios finales o clientes un mayor control sobre los datos que ceden a las

compañías y el uso que estas hacen de estos datos. En su artículo 4, la LOPD dice:

«1. Los datos de carácter personal solo se podrán recoger para su tratamiento, así como someterlos a dicho tratamiento, cuando sean adecuados, pertinentes y no excesivos en relación con el ámbito y las finalidades determinadas, explícitas y legítimas para las que se hayan obtenido.

»2. Los datos de carácter personal objeto de tratamiento no podrán usarse para finalidades incompatibles con aquellas para las que los datos hubieran sido recogidos. No se considerará incompatible el tratamiento posterior de estos con fines históricos, estadísticos o científicos».

Es por tanto preciso **que el propietario de los datos autorice el almacenamiento y tratamiento de su información personal**. Así mismo, los responsables del repositorio de datos deben garantizar a los usuarios los métodos adecuados para la rectificación, modificación, acceso y cancelación de la información suministrada.

Confianza

Dentro de ciertos sectores sociales existe una preocupación relevante por el uso que determinadas compañías están haciendo con sus datos, y quizá esta preocupación esté justificada si nos basamos en ciertos titulares periodísticos que se han publicado en los últimos años. En este tipo de cuestiones entraremos más en detalle en el próximo apartado. Ahora intentaremos explicar cómo se puede establecer una relación de confianza entre el usuario y la organización para que este ceda sus datos.

Supongamos que un paciente estándar de 50 años está en la revisión anual con su médico. El hospital está interesado en crear un banco de datos y compartirlos con personal externo. Dado que es obligatorio otorgar permiso explícito para ceder datos de carácter personal, el facultativo nos pide delante un formulario donde simplemente se indica el texto: «autorizo la cesión de mis datos...».

Sin disponer de más información, ¿qué haría el lector? Cambiemos la situación yendo a un caso algo más extremo.

Supongamos que ese mismo paciente ha sido diagnosticado recientemente de una enfermedad que tiene una incidencia muy baja, pero, desgraciadamente, sus efectos en el enfermo son importantes. Textualmente, lo que nos comenta ahora el médico es:

«Nos gustaría que nos cediese su datos personales y clínicos para incorporarlos a nuestro banco de datos. Lo que pretendemos con este proyecto es compartir información con especialistas de todo el país e investigadores muy destacados en el área. Dado que su enfermedad es extremadamente rara, consideramos que sería muy útil compartir sus datos con la comunidad científica. Seguro que así podremos recibir recomendaciones que nos ayudaría a personalizar el tratamiento a sus características. Además, no compartiremos sus datos personales más íntimos, toda la información estará anonimizada. Ante cualquier cuestión, seremos nosotros quienes nos comunicaremos con usted como venimos haciendo hasta ahora».

¿Qué haría el lector en esta hipotética situación?

Es probable que las respuestas ante ambos casos de uso sean muy distintas. Y sería normal, puesto que se trata de dos casos muy diferentes. En la primera situación, el paciente no aprecia el retorno de valor que le produce la cesión de sus datos. Además, al recibir poca información sobre el proyecto es difícil generar una relación de confianza. En el segundo caso, el beneficio que el paciente percibe como consecuencia de la cesión de datos es evidente y relevante. La comunidad podría aportar un tratamiento que retarde la enfermedad o incluso la cure. Pero para que

esto sea una realidad es preciso que especialistas compartan información sobre qué tratamientos han funcionado, cuáles no, cuáles han sido los efectos secundarios, qué peculiaridades tenían los pacientes... Además, el facultativo ha trabajado la confianza al solicitar la cesión de los datos, ha explicado la utilidad de la cesión de los datos y ha establecido unas garantías que invitan al paciente a estar tranquilo sobre quién podrá contactarle. ¿Cuántas veces hemos recibido llamadas publicitarias ofreciendo productos sin ningún tipo de interés para nosotros y sin saber cómo habían accedido a nuestros datos?

Lo que se ha pretendido explicar en los párrafos anteriores se puede resumir en los siguientes puntos:

- ▶ Los algoritmos de inteligencia artificial (por ejemplo, los algoritmos de aprendizaje automático) emplean datos como materia prima.
- ▶ Muchas veces estos datos incluyen información personal.
- ▶ Para manipular información personal (aunque esté anonimizada) el usuario debe haber emitido su autorización.
- ▶ Para que el usuario ceda sus datos personales es preciso trabajar un entorno de confianza. Este entorno de confianza se basa en los siguientes puntos:
 - El usuario tiene claro a quién (a nivel de institución) y para qué va a acceder los datos.
 - El usuario tiene claro qué se va a hacer con sus datos.
 - El usuario percibe un retorno de valor evidente que le invita a permitir la cesión de datos.
 - El usuario es informado de que sus datos van a ser tratados de forma adecuada y

segura.

Establecer mecanismos que cultiven e implementen esta relación de confianza entre el usuario o cliente y la empresa o la institución es uno de los grandes retos a los que se enfrenta la industria hoy en día.

Anonimización de datos personales

El tratamiento, análisis y explotación de grandes volúmenes de datos puede producir infinitud de beneficios a la sociedad, pero es preciso compatibilizar dicho almacenamiento y manipulación con el respeto a la protección de datos personales.

El mecanismo principal que permite alinear la generación de beneficios tangibles con el respeto a la privacidad es la **anonimización de la información**. Según la RAE, anonimizar es «expresar un dato relativo a entidades o personas, eliminando la referencia a su identidad». Por otro lado, y según la AEPD, «un proceso de anonimización es aquel que elimina o reduce al mínimo los riesgos de identificación de los datos anonimizados manteniendo la veracidad de los resultados tras el tratamiento de estos».

Para garantizar su efectividad, **este proceso de anonimización debe ser irreversible**. Es decir, no debe existir posibilidad de recuperar el dato adicional empleando solo los datos anonimizados. Es necesario precisar que, debido a los avances tecnológicos y algorítmicos, no es posible garantizar de forma absoluta y completa la anonimización de la información. El objetivo realizable es proporcionar las mayores garantías posibles de cara a asegurar el respeto a la privacidad de las personas.

Según la AEPD, el proceso de anonimización debe atender a los siguientes **principios**:

- ▶ **Principio proactivo.** La privacidad se debe garantizar de forma proactiva y no de forma reactiva y una vez que se haya producido alguna fuga de información.
- ▶ **Principio de veracidad por defecto.** Se debe considerar la granularidad o grado de detalle final que deben tener los datos anonimizados. Esto lleva a que, en ocasiones, se exija la eliminación de ciertos datos para garantizar la anonimización del conjunto.
- ▶ **Principio de privacidad objetiva.** Siempre existirá un error residual de riesgo de reidentificación que deberá ser aceptable en función de la información anonimizada, conocido por el usuario y asumido por el responsable del fichero.
- ▶ **Principio de plena funcionalidad.** El proceso de anonimización debe garantizar la utilidad de los datos anonimizados en base a los objetivos inicialmente establecidos.
- ▶ **Principio de privacidad en el ciclo de vida de la información.** El respeto a la privacidad de los usuarios debe garantizarse durante todo el proceso de anonimización. Por ejemplo, realizando el proceso de anonimización en los sistemas preparados y autorizados a almacenar la información sin anonimizar.
- ▶ **Principio de información y formación.** Todo el personal con acceso a datos anonimizados o no deben estar correctamente formados e informados acerca de sus obligaciones.

Técnicamente hablando, existen varios **procedimientos para asegurar la anonimización de la información**. Algunos de los más destacados son:

- ▶ **Desnaturalizar:** consistente en transformar la naturaleza del dato. Por ejemplo, en lugar de representar la edad (edad = 42), podemos indicar el rango de edad al que pertenece en base a alguna división previamente establecida (edad = 5 donde 5

hace referencia al intervalo [40, 50]).

- ▶ **Cifrar:** consiste en hacer ilegible un mensaje concreto con base en la aplicación de un algoritmo que precisa de un conjunto de claves. En este caso, el descifrado de la información es posible siempre que se disponga del algoritmo de las claves necesarias.
- ▶ **Tokenizar:** se reemplaza el valor a anonimizar por un valor distinto (token) que no suele respetar la naturaleza del dato. Por ejemplo, se *tokeniza* el DNI 04345566D cambiándolo por el valor YID884S3VVQW4ZZY1. Se puede observar cómo no se respeta el formato estándar de un DNI. Para que el proceso mantenga la coherencia, al mismo valor le debe siempre corresponder el mismo *token*. La reversibilidad es posible siempre que se disponga del *token* correspondiente a cada valor.
- ▶ **Funciones *hash*:** es un método parecido a la *tokenización*. En este caso se aplica una función matemática al valor a anonimizar. Dicho valor reemplaza al valor original. En este caso, y por la propia naturaleza del proceso, se garantiza la irreversibilidad del proceso. No obstante, esta técnica podría, ocasionalmente, generar el mismo valor hash para distintos valores de entrada.
- ▶ **Disociar:** eliminar parte de la información para evitar la identificación personal. Por ejemplo, pongamos que disponemos de la siguiente información sobre un paciente: fecha de la consulta, hora de la consulta, código postal, edad, sexo y síntomas. Con esa información encima de la mesa existiría un riesgo de identificar al paciente, ya que solo la fecha y hora de la consulta proporcionan bastante información. La disociación consistiría en eliminar ciertos campos quedándonos solo (por ejemplo), con código postal, sexo y síntomas. De esta forma se reduce el riesgo de identificación.

Reglamento General de Protección de Datos (RGPD)

Aunque diseñada en el año 2016, el RGPD de la Unión Europea pasó a ser de

obligado cumplimiento en el año 2018. La aplicación de esta normativa supone un gran reto para muchas compañías en las que el dato y la analítica sobre el mismo constituye un eje esencial de su actividad. El incumplimiento de la normativa implica cuantiosas multas para los infractores.

El RGPD exige **medidas adicionales que garanticen la transparencia en el tratamiento de datos personales**. Se pretende así empoderar al ciudadano para que tome las decisiones más adecuadas. Las organizaciones deben informar al usuario sobre el tipo de perfilado o modelización que realizan en base a su dato personal facilitándole la denegación del permiso para realizar dicho tratamiento si así es solicitado.

Especialmente en el entorno financiero y asegurador, una de las medidas que más impacto causará es el **derecho a explicación**. Esta medida obliga, por ejemplo, a las entidades financieras a explicar las razones por las que un crédito ha sido denegado. De esta forma, el usuario puede actuar en consecuencia buscando alternativas para obtener una mejor clasificación en el futuro.

Además, los algoritmos implementados deben asegurar que se garantiza la no discriminación a la hora de tomar decisiones basadas en datos. No podrán tomarse decisiones basadas en criterios como la raza, la edad, el sexo, la religión, etc.

La Unión Europea ha habilitado el portal <https://www.eugdpr.org/> donde se desglosa todo tipo de información sobre esta regulación.



Figura 2. Portal de la RGPD. Fuente: <https://www.eugdpr.org/>

En esta unidad se propondrá al alumno la realización de un trabajo que versará, precisamente, sobre esta normativa.

12.3. Sesgos, legalidad y responsabilidad

Lo que hace unos años era una cuestión ética, evitar la discriminación a la hora de emplear datos y algoritmos en la toma de decisiones, ahora se ha convertido en ley. En un entorno tecnológico y científico con una evolución tan rápida e impredecible, el entorno regulatorio no siempre es capaz de llegar a tiempo para proteger los derechos de los ciudadanos, por lo que el especialista, científico o técnico debe mantener altos estándares éticos en el día a día de su trabajo.

Hay una serie de puntos para tener en cuenta en este sentido:

- ▶ Tener siempre presente la normativa de protección de datos.
- ▶ Asegurarse que los algoritmos que empleamos no conllevan la toma de decisiones implicando la discriminación de algún colectivo por edad, sexo, raza, religión o cualquier otro aspecto.
- ▶ Comprobar que los datos empleados no contienen sesgos que puedan llevar a tomar decisiones equivocadas.
- ▶ Interpretar los resultados de los modelos científicamente, evitando interpretaciones interesadas y no ajustadas a la realidad.
- ▶ Emplear los métodos de trabajo adecuados que garanticen la fiabilidad de los resultados.

Conceptos como inteligencia artificial y aprendizaje automático forman parte del vocabulario diario de comités de empresa y gobiernos de todo el mundo. Las decisiones que se toman con base en estos modelos afectan a millones de personas.

Por tanto, es responsabilidad de los expertos asegurar que el objetivo final es aportar beneficio a la sociedad en general o los clientes de la compañía en particular, respetando los derechos fundamentales de la ciudadanía.

Sesgos: el motivo por el que los algoritmos aprenden y su principal punto débil

Como ya vimos anteriormente, **los sesgos son imposibles de eliminar ya que es el mecanismo por el que los algoritmos aprenden**. Crear sesgos y hacer suposiciones globales despreciando los detalles concretos es la base del aprendizaje y, por tanto, las excepciones siempre van a estar ahí. Lo importante en este caso es minimizarlos y que estos sesgos no aprendidos no sean sesgos inducidos por el entrenamiento debido a una mala elección de los datos de entrenamiento.

Es por tanto muy importante tener en cuenta este tipo de cuestiones en entornos sensibles y con sesgos que pueden incurrir en discriminaciones de cualquier tipo. Si no se puede discriminar a un individuo por razones ideológicas, de sexo, étnicos, etc., los algoritmos no pueden hacerlo tampoco.

¿Cómo evitar este hecho?

- ▶ Seleccionar cuidadosamente los datos de entrenamiento.
- ▶ Validar los algoritmos no solo con los datos provenientes del primer mundo o de nuestra área de influencia sino de otras partes del mundo con rasgos, culturas o éticas diferentes.
- ▶ Mantener una vigilancia continua de las decisiones que estos toman, para intervenir lo antes posible si se detectan estos sesgos.
- ▶ Tener evaluadores humanos que confirmen las decisiones tomadas por los algoritmos o al menos que los usuarios que se vean afectados por ellos puedan acudir para que se revise su caso particular.

Este va a ser uno de los retos más importante de aquí a unos años cuando los algoritmos de IA sean los que vayan controlando cada vez más y más procesos en los que la vida de los ciudadanos se vea afectada.

En cuanto a la **responsabilidad de los errores de estos algoritmos**, pues es bastante complicado establecerla y es algo en lo que debemos esforzarnos como sociedad. Obviamente, la responsabilidad siempre debe ser de la organización que use estos algoritmos que deben probarlos correctamente. Pero nada está exento de errores al 100 %. Así que hay que establecer cuál es el margen de error admisible para cada tarea que se delegue a la IA. Al fin y al cabo, los humanos también nos equivocamos. La diferencia aquí es que la cadena de responsabilidad entre los humanos es trazable y queda más o menos clara. Cuando entra dentro un algoritmo de IA ya no está tan clara, ¿es de los diseñadores del algoritmo?, ¿es de quien seleccionó los datos de entrenamiento? ¿Es de quien no revisó correctamente dicha decisión? Se entra en un terreno desde nuestro punto de vista pantanoso que tendremos que ir valorando con el tiempo y con leyes nuevas que probablemente lleguen tarde para algunos casos. Este es un reto importante a tener en cuenta en el futuro.

Implicaciones de la inteligencia artificial

La explosión de la inteligencia artificial ha marcado o marcará el inicio de una nueva revolución de dimensiones equivalentes a la Revolución Industrial. Como en toda gran transformación, y a pesar de las nuevas posibilidades que deslumbran, surgen también dudas y temores. Por ejemplo:

- ¿Perderán las personas su trabajo siendo reemplazadas por máquinas?

- ▶ ¿En qué trabajarán los humanos? ¿Cuánto tiempo?
- ▶ ¿Cómo se transformará nuestro tiempo de ocio?
- ▶ ¿Qué sucederá con nuestro derecho a la privacidad?
- ▶ ¿Cómo interactuaremos con los sistemas basados en inteligencia artificial? ¿Quién liderará la relación?
- ▶ ¿Podrán las máquinas sentir? ¿Cómo actuaremos entonces?
- ▶ ¿Dominarán los robots a la raza humana?

A la mayoría de estas preguntas no es posible responderla en estos momentos. Sin embargo, el debate sobre las implicaciones laborales de la robótica y la inteligencia artificial ya ha empezado.

En primer lugar, la gran mayoría de flujos de trabajo serán automatizados y no requerirán intervención humana. Esto permitirá mejorar la eficiencia de los procesos y, quizá, reducir los costes.

Los **algoritmos se convertirán en los principales agentes en ciertos escenarios**. Por ejemplo, muchas de las operaciones bursátiles que se llevan a cabo hoy en día son ejecutadas de forma automática mediante algoritmos que evalúan la evolución del mercado e incluso el contexto informativo analizando la información que circula sobre el contexto económico y social.

Los robots no solo han transformado las fábricas del siglo XXI, también están introduciéndose en el terreno sanitario e incluso militar.

El reto que tenemos por delante es **convertir los riesgos en oportunidades reales**.

Igual que sucedió con la Revolución Industrial, muchos trabajos desaparecerán

porque ya no serán necesarios al poder realizarse de forma automática. Sin embargo, surgirán otros muchos nuevos trabajos y, por supuesto, los métodos de trabajo cambiarán radicalmente. La **educación adquiere una relevancia especial** para dirigir la transformación global de habilidades y conocimientos que permita la inmersión en el nuevo ecosistema. Algunos autores sugieren gravar mediante nuevos impuestos ciertos productos basados en inteligencia artificial, como los robots industriales para que el Estado reciba, al menos temporalmente, fuentes adicionales de financiación que permitan ayudar a aquellas personas que se queden sin trabajo debido a la automatización de sus posiciones y, además, pueda impulsar un nuevo sistema educativo que promueva la creatividad y genere el ecosistema humano que este nuevo paradigma necesita. A esto se le ha denominado que los **robots paguen impuestos**. Otros autores comentan que se debe crear una renta básica que permita la subsistencia mínima individual. En cualquier caso, es un reto muy importante que debemos abordar en los próximos años.

La inteligencia artificial redefinirá la economía del futuro impulsando la productividad y generando una oleada de productos personalizados basados en las necesidades del cliente. Este impacto se extenderá por todos los ámbitos de actividad.

Regulando la inteligencia artificial

En los últimos años, destacados y muy relevantes personajes públicos han planteado la necesidad de regular de forma más exigente el ámbito de la inteligencia artificial de cara a evitar un mal uso de esta.

Entre estos actores destaca especialmente la organización Future of Life (<https://futureoflife.org/>). Esta fundación propone medidas para mitigar los riesgos de un mal uso no solo de la inteligencia artificial, sino también de la biotecnología o de las armas nucleares. Además, contemplan acciones para mitigar el cambio climático.




Figura 3. Página web de Future of Life. Fuente: <https://futureoflife.org/>

La lista de personalidades detrás de este proyecto es absolutamente espectacular. Entre sus fundadores podemos encontrar destacados científicos procedentes del MIT, DeepMind, Universidad de Santa Cruz o Boston, además de a Jaan Tallinn, cofundador de Skype. La labor de la institución está apoyada públicamente por figuras como Alan Alda, Erik Brynjolfsson (director del MIT Center for Digital Business), Morgan Freeman, el conocidísimo Stephen Hawking, Elon Musk (fundador de Tesla), Stuart Russell (autor del libro de referencia en esta asignatura) y un largo etcétera.

Una de las grandes preocupaciones de este grupo es la **aplicación de la inteligencia artificial con fines militares**. Atributos como la empatía, la justicia, la responsabilidad, la compasión, etc., son de momento atributos puramente humanos que las máquinas no tienen ocasión de contemplar.

Future of Life también se plantea romper con muchos de los mitos ligados a la inteligencia artificial:



Figura 4. Mitos asociados a la inteligencia artificial según Future of Life. Fuente:

<https://futureoflife.org/background/benefits-risks-of-artificial-intelligence/>

La imagen anterior podría resumirse en los siguientes puntos:

- ▶ No es preciso definir qué es lo que seremos capaces de conseguir y cuándo.
- ▶ Muchos y grandes expertos están muy preocupados sobre el uso que se podría hacer de la inteligencia artificial.
- ▶ En ocasiones la inteligencia artificial puede producir soluciones no alienadas con los objetivos adecuados.
- ▶ No es solo cuestión de preocuparse por los robots, los algoritmos autónomos son también una cuestión que hay que vigilar.

- ▶ Ciertas soluciones de inteligencia artificial podrían condicionar y controlar el comportamiento humano.
- ▶ Las máquinas pueden plantearse un objetivo de forma predefinida.
- ▶ Es mejor prevenir que curar. Actuemos antes de que sea tarde estableciendo las bases que permitan el desarrollo de una inteligencia artificial segura y alineada con las necesidades humanas.

Hay que destacar que este grupo no está en contra de la inteligencia artificial. De hecho, mucho de sus colaboradores forman parte de la élite investigadora de la materia. Lo que se pide no es abandonar el desarrollo de la inteligencia artificial, sino **establecer unas bases regulatorias adecuadas** que permitan asegurar que su desarrollo se produce de forma segura.

12.4. Seguridad y tolerancia ante ataques

Con el uso cada vez mayor de la inteligencia artificial y de la compartición de datos, las posibilidades de ataques en este tipo de sistemas están aumentando considerablemente. El uso intensivo de datos en los sistemas de IA hace que estos mejoren y se puedan aplicar a múltiples entornos que antes no eran posibles. Pero nos surge una duda, ¿cómo queda la seguridad y la privacidad de mis datos al adoptarla?

Ahora mismo muchas compañías están utilizando sistemas y modelos que van aprendiendo sobre la marcha y estos modelos no solo son usados por una compañía. Muchas veces, distintas compañías hacen uso de los mismos modelos debido a que la mayoría de estos modelos se enfocan al uso del *software* como servicio. De forma que, de una u otra forma, tus datos forman parte de una red que usa más gente. Por esta razón, ¿están seguros esos datos?

Por otro lado, con la creciente digitalización cada vez habrá más datos conectados a Internet y, por tanto, más puertas abiertas que pueden ser aprovechadas por los ciberatacantes. Por eso, es muy importante que estos datos estén bien protegidos; sobre todo, si son datos sensibles.

También comienzan a verse ataques a los propios algoritmos de IA. Como todo sistema informático, estos sistemas pueden tener agujeros de seguridad. Pero también podemos ir más allá. Los sistemas de IA y de *machine learning* como sabemos tienen sesgos y los atacantes pueden utilizar esos sesgos a su favor. Por ejemplo, falseando los datos de entrada, aprovechando de alguna vulnerabilidad del algoritmo para que este falle en su beneficio. Por ejemplo, para conseguir que una IA descarte o acepte un préstamo en un banco.

Los sistemas de reconocimiento de texto y de lenguaje natural, por ejemplo, han

avanzado enormemente en los últimos años, pero los programas de IA que analizan el texto pueden ser engañados por frases cuidadosamente elaboradas. Una frase que parece sencilla para un humano puede engañar a un algoritmo de IA. Esto puede implicar, por ejemplo, que un sistema que filtre noticias falsas sea engañado colando una noticia falsa sutilmente camuflada o que rechace o clasifique correctamente un posible candidato a un empleo. A este tipo de ejemplos que se le conoce con el nombre de adversarial *examples*.

Podemos definir, por tanto, un **adversarial example** como un caso con pequeñas perturbaciones intencionales de características que hacen que un modelo de aprendizaje de una máquina haga una predicción falsa.

Algunos ejemplos de este tipo de adversarial examples pueden ser:

- ▶ Un auto que se conduce a sí mismo choca con otro coche porque ignora una señal modificada para que el algoritmo lo identificara erróneamente.
- ▶ Armas diseñadas para engañar los sistemas de escaneo de un aeropuerto.
- ▶ Engañamos a un sistema recomendador para que recomiende nuestros productos cuando los usuarios buscan el de la competencia.

En la siguiente figura podemos ver un ejemplo de cómo se ha conseguido engañar a AlexNet, un conocido clasificador de imágenes. En las imágenes de la izquierda el algoritmo los reconoce, pero al aplicar el ruido de la imagen central, el algoritmo clasifica todas las imágenes como avestruces.




Figura 5. Algunas imágenes adversarias que engañan a Alexnet. Fuente:

<https://christophm.github.io/interpretable-ml-book/adversarial.html>

¿Cómo podemos defendernos de estos ataques? Es complicado, pero debemos ser conscientes de ello para intentar remediarlo. Podemos mitigar el riesgo con las **siguientes medidas**:

- ▶ **Conocer a tu adversario.** Conocer cuáles son las motivaciones que un atacante tiene para hacerlo.
- ▶ **Ser proactivo,** esto es, intentar engañar constantemente a los sistemas con tus propios ejemplos de adversario para intentar detectar los posibles errores.
- ▶ **Protegerte a ti mismo** con reentrenamientos activos con adversarios o utilizar varios clasificadores y decidir en mayoría.

12.5. Explicabilidad de algoritmos

Como hemos visto en el apartado anterior, es posible engañar a los algoritmos de *machine learning* entregando ejemplos preparados para que estos se equivoquen. Si podemos explicar el modelo que se genera en el proceso de aprendizaje es más fácil evitar o predecir estos errores. Pero esto no siempre es posible, debido a que no todos los algoritmos son explicables o fácilmente explicables.

Los modelos que generan los algoritmos de *machine learning* podemos clasificarlos en función de su explicabilidad: en modelos de caja negra y modelos de caja blanca.

Los **modelos de caja negra** son aquellos en los que conseguir entender el modelo para poder analizarlo es muy complejo o casi imposible. Potencialmente todos pueden ser de caja negra si el número de parámetros de configuración es muy alto. Pero, en general, son propensos a ser algoritmos que generan modelos de caja negra las redes de neuronas, los *random forest*, el razonamiento basado en casos con medidas de distancia compleja, etc.




Figura 6. Modelo de caja negra.

Los **modelos de caja blanca**, por el contrario, son más sencillos de explicar y, por tanto, de analizar. Los árboles de decisión simples son algoritmos que generan modelos de cajas blancas. También las redes bayesianas o cualquier sistema que utilice lógica de predicados, con encadenamiento hacia delante o hacia atrás.

La **explicabilidad** nos da una serie de ventajas que debemos tener en cuenta como,

por ejemplo:

- ▶ **Confiabilidad.** Es muy importante poder confiar en las decisiones de un **algoritmo**, sobre todo si este está a cargo de algo importante. Por ejemplo, está conduciendo un vehículo por ti, tomando decisiones de compra en bolsa o manejando una central nuclear. Pero también para otros temas menores es importante saber qué decisión está tomando el algoritmo debido a que este puede incurrir en, como hemos visto durante este tema, sesgos, discriminaciones etc. Saber cómo llega a esa decisión puede ayudarnos a prevenir estos malos comportamientos de los algoritmos.
- ▶ **Adquirir nuevo conocimiento.** Los algoritmos a veces **son capaces de resolver problemas o descubrir nuevas soluciones a problemas que antes no se conocían**. Pero estos problemas muchas veces no pueden ser analizados correctamente debido a que no sabemos cómo el algoritmo ha llegado a esa conclusión. Por lo tanto, perdemos los detalles de ese nuevo conocimiento adquirido.
- ▶ **Detección de fallos.** Si el modelo tiene fallos y conocemos el modelo, podremos predecirlos, mitigarlos o reentrenarlo. Hasta ahora, solo podemos saber si un algoritmo de caja negra tiene fallos probándolo exhaustivamente. Pero siempre puede haber casos que no se han contemplado en los que el algoritmo falle. Durante el tema hemos visto varios de ellos.

Pero eso no significa que dejemos de usar algoritmos de caja negra. Hay ciertos entornos donde no hay problema por usar algoritmos de caja negra debido a que la necesidad de verificación del modelo no es crítica. Pensemos en algoritmos que controlan la calidad de imagen en un videojuego (DLSS), el algoritmo de YouTube o el recomendador de Netflix, o en algoritmos que ayuden a los científicos de la NASA a encontrar nuevos exoplanetas. Si hay algún error en estos algoritmos que clasifica un exoplaneta como planeta que no lo es, el error no es de vital importancia. Con el tiempo se descubrirá que no lo es, pero no tiene un coste de error alto y es mayor el beneficio de poder haber encontrado cientos de exoplanetas que sin la IA no

hubieran podido ser encontrados.

En resumen, hay que ser conscientes en qué dominios que el modelo no sea explicable no es un problema y que los beneficios de estos modelos compensen la falta de explicabilidad, y en qué dominios es recomendable usar algoritmos explicables, aunque obtengan peor rendimiento.

La aproximación, normalmente, a este tipo de dominios sensible es **tener soluciones híbridas entre algoritmos de caja negra y algoritmos de caja blanca**. Es decir, que parte del razonamiento esté inducido por algoritmos de caja blanca para que el cuerpo principal de la solución sea explicable y se use los algoritmos de caja negra en aquellas tareas donde la explicabilidad sea menos crítica. O también se busca intentar explicar los algoritmos de caja negra con otros métodos que ayuden a entenderlos.

12.6. Referencias bibliográficas

Ley Orgánica 15/1999, de 13 de diciembre, de Protección de Datos de Carácter Personal. *Boletín Oficial del Estado*, 298, de 14 de diciembre de 1999. Recuperado de <https://www.boe.es/buscar/doc.php?id=BOE-A-1999-23750>

Turing, A. M. (1950). Computing machinery and intelligence. *Mind*, 59(236), 433-460.

Orientaciones y garantías en los procedimientos de anonimización de datos personales

Agencia Española de Protección de Datos. (2016). Orientaciones y garantías en los procedimientos de anonimización de datos personales. *aepd.es*. Recuperado de: <https://www.aepd.es/sites/default/files/2019-09/guia-orientaciones-procedimientos-anonimizacion.pdf>

En el siguiente enlace podemos consultar las orientaciones y garantías en los procedimientos de anonimización de datos personales en la Agencia Española de Protección de Datos.

Código de buenas prácticas en protección de datos para proyectos Big Data

Sáiz, A. (coord.). (2017). Código de buenas prácticas en protección de datos para proyectos Big Data. *aepd.es*. Recuperado de <https://www.aepd.es/sites/default/files/2019-09/guia-codigo-de-buenas-practicas-proyectos-de-big-data.pdf>

En el siguiente enlace podemos consultar el código de buenas prácticas en protección de datos para proyectos *big data*.

Adversarial Examples

Molnar, C. (2020.). Adversarial Examples. En *Interpretable Machine Learning. A Guide for Making Black Box Models Explainable (capítulo 6)*. Recuperado de <https://christophm.github.io/interpretable-ml-book/adversarial.html>

Este autor nos explica lo que son los adversarial examples.

1. La Agencia Española de Protección de Datos:
 - A. Se limita a aconsejar al Gobierno sobre cómo debería legislarse en materia de protección de datos.
 - B. Tiene encargada la misión de velar por el cumplimiento de la normativa de protección de la información personal.
 - C. Dependiendo del Ministerio de Interior vela porque los datos de las Administraciones públicas se gestionen correctamente.
 - D. Depende directamente de la Unión Europea.

2. El Reglamento General de Protección de Datos:
 - A. Es de obligado cumplimiento desde el año 2016.
 - B. Se convierte en normativa de obligado cumplimiento en el año 2019.
 - C. Se convierte en normativa de obligado cumplimiento en el año 2018.
 - D. Se convierte en normativa de obligado cumplimiento en el año 2020.

3. En un contexto de anonimización y privacidad de la información, la triada hace referencia a:
 - A. Seguridad, consistencia y persistencia: elementos básicos de un repositorio que cumpla con la normativa oficial.
 - B. La combinación de los atributos edad, género y código postal y que, ocasionalmente, podrían permitir la identificación unívoca de una persona.
 - C. Las tres instituciones encargadas de velar por la privacidad de los usuarios, la AEPD, el Ministerio de Justicia y el Ministerio de Interior.
 - D. Ninguna de las anteriores.

4. A la hora de gestionar la relación con los usuarios o clientes:
- A. Es preciso generar un entorno de confianza.
 - B. Los clientes deben percibir que reciben un beneficio por conceder permiso para trabajar con sus datos.
 - C. Se debe informar a los clientes de cuál es el objetivo que persigue el tratamiento de sus datos personales.
 - D. Todas las anteriores.
5. La anonimización de los datos personales:
- A. Implica eliminar o reducir al mínimo los riesgos de identificación de los datos anonimizados.
 - B. Implica mantener la veracidad de los resultados tras el tratamiento de los datos.
 - C. Implica eliminar la referencia a la entidad.
 - D. Todas las anteriores.

6. Según la AEPD, el proceso de anonimización debe atender a los siguientes principios:

- A. Principio proactivo, principio de veracidad, principio de privacidad objetiva, principio de plena funcionalidad y principio de privacidad.
- B. Principio proactivo, principio de veracidad, principio de privacidad objetiva, principio de plena funcionalidad, principio de privacidad y principio de información y formación.
- C. Principio activo, principio de veracidad, principio de privacidad objetiva, principio de plena funcionalidad, principio de privacidad y principio de información y formación.
- D. Principio reactivo, principio de veracidad, principio de privacidad objetiva, principio de plena funcionalidad, principio de privacidad y principio de información y formación.

7. Una diferencia fundamental entre *tokenizar* y aplicar una función *hash* es:

- A. No existe esa diferencia, son la misma cosa.
- B. El proceso de *tokenización* es irreversible, lo contrario que si aplicamos una función *hash*.
- C. La anonimización mediante función *hash* es irreversible y la *tokenización* no.
- D. La *tokenización* tarda mucho más tiempo que aplicar una función *hash*.

8. ¿Qué podemos decir de las implicaciones de la inteligencia artificial?
- A. Es posible determinar de antemano casi la totalidad de estas implicaciones, tanto para lo bueno como para lo malo.
 - B. El panorama es muy esperanzador puesto que solo se perciben beneficios.
 - C. Los problemas que se perciben a corto, medio y largo plazo superan a los beneficios.
 - D. La educación será esencial para conseguir que la sociedad se adapte a los nuevos puestos laborables.
9. ¿Qué son los *adversal examples*?
- A. Ejemplos atípicos en los datos de entrenamiento.
 - B. Ejemplos manipulados sutilmente que hacen que los algoritmos de IA *fallen*.
 - C. Ejemplos que no son capaces de ser reconocidos por una IA pero que también engañarían a un humano.
 - D. Son los datos de entrenaamiento que se utilizan en las Generative Adversarial Networks.
10. Un algoritmo de caja negra es aquel que:
- A. Permite analizar fácilmente cómo han llegado a obtener una conclusión.
 - B. Es aquel en el que el análisis de cómo ha llegado a obtener una conclusión es muy complejo.
 - C. Son algoritmos que han aprendido sesgos y que pueden hacerlos tomar decisiones poco éticas.
 - D. No se usan ya que se prefiera usar algoritmos de caja blanca.