



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Inteligencia Artificial

Optimización de modelos de lenguaje compactos para la síntesis de programas orientada a la resolución de ARC-AGI-1

Trabajo Fin de Estudios

presentado por: Asier Marin Fernandez

Dirigido por: Fernando Antonio Rufo Jimenez

Ciudad: Valencia

Fecha: 22 de julio de 2026

Índice de Contenidos

Resumen	v
Abstract	vi
1. Introducción	1
1.1. Contexto	1
1.2. Justificación	2
1.3. Objetivos	3
2. Estado del Arte	4
2.1. Definición de la inteligencia	4
2.2. La inteligencia desde un punto de vista filosófico	4
2.3. Nucleos del conocimiento	4
2.4. El Abstract and Reasoning Corpus (ARC-AGI)	4
2.5. Estudio de las limitaciones de los Grandes Modelos de Lenguaje (LLMs) . .	4
2.6. Enfoques de modelos sin Pre-entrenamiento	4
2.7. Optimización en Tiempo de Inferencia	4
3. Especificación de requisitos	5
4. Desarrollo	6
4.1. Datos	6
4.1.1. Técnicas de aumentos de datos	6
4.2. Diseño de arquitectura y entrenamiento	6
5. Resultados	7
6. Planificación	8
7. Estudio económico	9
8. Conclusiones y Trabajo Futuro	10
Referencias	10
A. Apendices	11

Índice de Ilustraciones

8.1. Logo Unir	10
--------------------------	----

Índice de Tablas

8.1. Tabla 1	10
------------------------	----

Resumen

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en español

Abstract

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en inglés

1. Introducción

Actualmente una tendencia ascendente en el campo de inteligencia artificial. El paradigma del aprendizaje profundo ha demostrado ser una herramienta de presente y de futuro. El *software* es un elemento fundamental en la sociedad actual, y con la evolución del propio *software* también evolucionan los distintos campos tecnológicos, entre ellos el de la inteligencia artificial.

La inteligencia artificial es un campo de estudio que se centra en la creación de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, el razonamiento, la resolución de problemas, la comprensión del lenguaje natural y la percepción visual. En los últimos años, ha habido un aumento significativo en el interés y el desarrollo de la inteligencia artificial, lo que ha llevado a avances notables en áreas como el aprendizaje automático, el procesamiento del lenguaje natural y la visión por computadora.

Cada vez se le da más importancia a las herramientas basadas en inteligencia artificial y cada vez llega a un público más amplio. En este contexto, los mecanismos para que esta tecnología pueda ser consumida por el público general se vuelven cada vez más importantes. En este sentido, la eficiencia en el consumo de estos recursos tecnológicos cada vez es más relevante. Con la llegada de más modelos de lenguaje, la necesidad de encontrar formas de medir la capacidad de generalización de estos modelos se vuelve cada vez más importante también.

Es aquí donde entra en juego el *Abstraction and Reasoning Corpus (ARC-AGI)*, un *benchmark* diseñado específicamente para evaluar la inteligencia de los sistemas y su capacidad para adquirir nuevas habilidades de forma eficiente a partir de unos pocos ejemplos, basándose en los principios del conocimiento central innato humano. El estándar ARC-AGI es una respuesta a la necesidad de medir la inteligencia, permitiendo la comparación entre sistemas y humanos.

1.1. Contexto

A pesar de los avances recientes, los Grandes Modelos de Lenguaje (LLMs) siguen teniendo dificultades para resolver este tipo de tareas, ya que sus capacidades se derivan principalmente de volúmenes masivos de datos de pre-entrenamiento y memorización

probabilística. Esto evidencia que, la hipótesis de escalar los modelos sin límites insospechados, no es suficiente para alcanzar el razonamiento abstracto. Aumentar ciegamente la cantidad de parámetros no dota automáticamente al sistema la capacidad de resolver tareas que requieren un razonamiento abstracto más novedoso.

ARC-AGI representa el indicador estándar por excelencia de la industria para medir el progreso real hacia la inteligencia general artificial (AGI) a través de la generalización amplia y síntesis de programas.

1.2. Justificación

Abordar el problema de ARC-AGI desde la perspectiva de los Modelos de Lenguaje Pequeños (SLMs) y la optimización en tiempo de inferencia supone un cambio de paradigma necesario: pasar del escalado por fuerza bruta a la optimización inteligente de los parámetros. Limitar deliberadamente la capacidad del modelo evita la sobre-generalización y fuerza al sistema a concentrarse exclusivamente en descubrir transformaciones algorítmicas robustas y reglas recursivas, en lugar de memorizar estadísticas superficiales.

La viabilidad de este enfoque está respaldada por investigaciones muy recientes. Arquitecturas como el *Hierarchical Reasoning Model (HRM)* y el *Tiny Recursive Model (TRM)* han logrado superar el rendimiento de modelos masivos (como o3-mini o Claude 3.7) en ARC-AGI utilizando redes minúsculas de apenas 7 a 27 millones de parámetros, gracias a la aplicación de pasos de computación recursiva en un espacio latente. Asimismo, enfoques revolucionarios como CompressARC han demostrado que es posible resolver un alto porcentaje de puzzles sin absolutamente ningún pre-entrenamiento, utilizando apenas 76.000 parámetros y minimizando la longitud de descripción puramente en el tiempo de inferencia (*Test-Time Training*).

Dadas las restricciones de capacidad de cómputo disponibles para este proyecto, apostar por estos paradigmas (bucles de refinamiento, síntesis de programas y entrenamiento en tiempo de prueba) no solo es una necesidad técnica, sino la estrategia científica más prometedora y eficiente para abordar el razonamiento complejo sin la saturación de recursos inherente a los LLMs tradicionales.

1.3. Objetivos

Objetivo principal El objetivo principal es diseñar y desarrollar un modelo compacto (SLM) que maximice la puntuación en la resolución del benchmark ARC-AGI-1, priorizando estrictamente la eficiencia computacional y el rendimiento por parámetro frente a los modelos de lenguaje a gran escala.

En cuanto a objetivos particulares se enumeran los siguientes:

- Desarrollar e implementar bucles de refinamiento recursivo que permitan al modelo actualizar iterativamente sus estados latentes y mejorar progresivamente sus predicciones, simulando la síntesis de programas.
- Explorar y aplicar técnicas de adaptación en tiempo de prueba *Test-Time Training* y *Test-Time Compute* para que el modelo aprenda y descubra abstracciones algorítmicas directamente sobre las tareas objetivo, reduciendo la dependencia del pre-entrenamiento.
- Integrar mecanismos de tiempo de cálculo adaptativo o *early-stopping* que permitan al sistema abortar el bucle de razonamiento iterativo una vez haya alcanzado una solución convergente, optimizando drásticamente el consumo de memoria y tiempo de ejecución.
- Implementar estrategias de consistencia y ensamblado *top-k* que operen sobre diversas variantes o aumentos de los datos de entrada para seleccionar las predicciones más robustas.
- Realizar una comparativa exhaustiva de eficiencia que evalúe cuantitativamente la relación entre la precisión lograda en el benchmark y el coste computacional empleado, como el uso de VRAM, y precisión en FLOPs, validando la viabilidad de la inteligencia algorítmica en entornos de recursos restringidos.

2. Estado del Arte

2.1. Definición de la inteligencia

[RTRTHRTHRTHRTHRTHRTH]

2.2. La inteligencia desde un punto de vista filosófico

[RTRTHRTHRTHRTHRTHRTH]

2.3. Nucleos del conocimiento

[RTRTHRTHRTHRTHRTHRTH]

2.4. El Abstract and Reasoning Corpus (ARC-AGI)

[RTRTHRTHRTHRTHRTHRTH]

2.5. Estudio de las limitaciones de los Grandes Modelos de Lenguaje (LLMs)

[RTRTHRTHRTHRTHRTHRTH]

2.6. Enfoques de modelos sin Pre-entrenamiento

[RTRTHRTHRTHRTHRTHRTH]

2.7. Optimización en Tiempo de Inferencia

[RTRTHRTHRTHRTHRTHRTH]

3. Especificación de requisitos

[RTRTHRTHRTHRTHRTHRTH]

4. Desarrollo

[RTRTHRTHRTHRTHRTHRTH]

4.1. Datos

[RTRTHRTHRTHRTHRTHRTH]

4.1.1. Técnicas de aumentos de datos

[RTRTHRTHRTHRTHRTHRTH]

4.2. Diseño de arquitectura y entrenamiento

[RTRTHRTHRTHRTHRTHRTH]

5. Resultados

6. Planificación

7. Estudio económico

8. Conclusiones y Trabajo Futuro

En la Ecuación (8.1)

$$M = \begin{pmatrix} m_{11} & m_{12} \\ m_{21} & m_{22} \end{pmatrix} \quad (8.1)$$

En la siguiente Tabla 8.1

1	2
22	11

Tabla 8.1: Tabla 1

En la siguiente Figura 8.1



Figura 8.1: Logo Unir

(Pimentel y Teixeira, 2016) (da S. Bessa, da Silva, Frederico, y Ricarte, 2023)

Referencias

- da S. Bessa, J., da Silva, J. V., Frederico, M. N., y Ricarte, G. C. (2023, sep). Sharp hessian estimates for fully nonlinear elliptic equations under relaxed convexity assumptions, oblique boundary conditions and applications. *Journal of Differential Equations*, 367, 451–493. Descargado de <https://doi.org/10.1016/j.jde.2023.05.006> doi: 10.1016/j.jde.2023.05.006
- Pimentel, E. A., y Teixeira, E. V. (2016). Sharp hessian integrability estimates for nonlinear elliptic equations: An asymptotic approach. *Journal de Mathématiques Pures et Appliquées*, 106(4), 744–767. Descargado de <https://www.sciencedirect.com/science/article/pii/S0021782416300101> doi: <https://doi.org/10.1016/j.matpur.2016.03.010>

A. Apendices