



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Inteligencia Artificial

Optimización de modelos de lenguaje compactos para la síntesis de programas orientada a la resolución de ARC-AGI-1

Trabajo Fin de Estudios

presentado por: Asier Marin Fernandez

Dirigido por: Fernando Antonio Rufo Jimenez

Ciudad: Valencia

Fecha: 22 de julio de 2026

Índice de Contenidos

Resumen	VI
Abstract	VII
1. Introducción	1
1.1. Contexto	1
1.2. Justificación	2
1.3. Objetivos	2
2. Estado del Arte	4
2.1. Definición de la inteligencia	4
2.2. La inteligencia desde un punto de vista filosófico	4
2.3. Nucleos del conocimiento	5
2.4. El Abstract and Reasoning Corpus	6
2.4.1. Espectro de la generalización	7
2.4.2. La inteligencia desde la perspectiva de la adquisición de habilidades	9
2.4.3. ARC-AGI-1	9
2.5. Grandes Modelos de Lenguaje en ARC-AGI-1	9
2.6. Enfoques de modelos sin Pre-entrenamiento	9
2.7. Optimización en Tiempo de Inferencia	10
3. Metodología, infraestructura y herramientas	12
4. Desarrollo	13
4.1. Datos	13
4.1.1. Técnicas de aumentos de datos	13
4.2. Arquitectura y entrenamiento	13
5. Resultados	14
6. Planificación	15
7. Estudio económico	16

8. Conclusiones y Trabajo Futuro	17
Referencias	17
A. Apendices	18

Índice de Ilustraciones

2.1. Modelo jerárquico de habilidades cognitivas y su mapeo del espectro de generalización	8
2.2.	9
2.3.	9
2.4.	10
2.5.	10
2.6.	11
2.7.	11

Índice de Tablas

Resumen

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en español

Abstract

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en inglés

1. Introducción

Actualmente una tendencia ascendente en el campo de inteligencia artificial. El paradigma del aprendizaje profundo ha demostrado ser una herramienta de presente y de futuro. El *software* es un elemento fundamental en la sociedad actual, y con la evolución del propio *software* también evolucionan los distintos campos tecnológicos, entre ellos el de la inteligencia artificial.

La inteligencia artificial es un campo de estudio que se centra en la creación de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, el razonamiento, la resolución de problemas, la comprensión del lenguaje natural y la percepción visual. En los últimos años, ha habido un aumento significativo en el interés y el desarrollo de la inteligencia artificial, lo que ha llevado a avances notables en áreas como el aprendizaje automático, el procesamiento del lenguaje natural y la visión por computadora.

Cada vez se le da más importancia a las herramientas basadas en inteligencia artificial y cada vez llega a un público más amplio. En este contexto, los mecanismos para que esta tecnología pueda ser consumida por el público general se vuelven cada vez más importantes. En este sentido, la eficiencia en el consumo de estos recursos tecnológicos cada vez es más relevante. Con la llegada de más modelos de lenguaje, la necesidad de encontrar formas de medir la capacidad de generalización de estos modelos se vuelve cada vez más importante también.

Es aquí donde entra en juego el *Abstraction and Reasoning Corpus (ARC-AGI)*, un *benchmark* diseñado específicamente para evaluar la inteligencia de los sistemas y su capacidad para adquirir nuevas habilidades de forma eficiente a partir de unos pocos ejemplos, basándose en los principios del conocimiento central innato humano. El estándar ARC-AGI es una respuesta a la necesidad de medir la inteligencia, permitiendo la comparación entre sistemas y humanos.

1.1. Contexto

A pesar de los avances recientes, los Grandes Modelos de Lenguaje siguen teniendo dificultades para resolver este tipo de tareas, ya que sus capacidades se derivan principalmente de volúmenes masivos de datos de pre-entrenamiento y memorización probabilística.

Esto evidencia que, la hipótesis de escalar los modelos sin límites insospechados, no es suficiente para alcanzar el razonamiento abstracto. Aumentar ciegamente la cantidad de parámetros no dota automáticamente al sistema la capacidad de resolver tareas que requieren un razonamiento abstracto más novedoso.

ARC-AGI representa el indicador estándar por excelencia de la industria para medir el progreso real hacia la inteligencia general artificial a través de la generalización amplia y síntesis de programas.

1.2. Justificación

Abordar el problema de ARC-AGI desde la perspectiva de los Modelos de Lenguaje Pequeños o SMLs y la optimización en tiempo de inferencia supone un cambio de paradigma necesario: pasar del escalado por fuerza bruta a la optimización inteligente de los parámetros. Limitar deliberadamente la capacidad del modelo evita la sobre-generalización y fuerza al sistema a concentrarse exclusivamente en descubrir transformaciones algorítmicas robustas y reglas recursivas, en lugar de memorizar estadísticas superficiales.

La viabilidad de este enfoque está respaldada por investigaciones muy recientes. Arquitecturas como el *Hierarchical Reasoning Model* y el *Tiny Recursive Model* han logrado superar el rendimiento de modelos masivos en ARC-AGI utilizando redes minúsculas de apenas 7 a 27 millones de parámetros, gracias a la aplicación de pasos de computación recursiva en un espacio latente. Asimismo, enfoques revolucionarios como CompressARC han demostrado que es posible resolver un alto porcentaje de puzles sin absolutamente ningún pre-entrenamiento, utilizando apenas 76.000 parámetros y minimizando la longitud de descripción puramente en el tiempo de inferencia (*Test-Time Training*).

Dadas las restricciones de capacidad de cómputo disponibles para este proyecto, apostar por estos paradigmas (bucles de refinamiento, síntesis de programas y entrenamiento en tiempo de prueba) no solo es una necesidad técnica, sino la estrategia científica más prometedora y eficiente para abordar el razonamiento complejo sin la saturación de recursos inherente a los modelos de lenguaje a gran escala.

1.3. Objetivos

Objetivo principal El objetivo principal es diseñar y desarrollar un modelo compacto (SLM) que maximice la puntuación en la resolución del benchmark ARC-AGI-1, priori-

zando estrictamente la eficiencia computacional y el rendimiento por parámetro frente a los modelos de lenguaje a gran escala.

En cuanto a objetivos particulares se enumeran los siguientes:

- Desarrollar e implementar bucles de refinamiento recursivo que permitan al modelo actualizar iterativamente sus estados latentes y mejorar progresivamente sus predicciones, simulando la síntesis de programas.
- Explorar y aplicar técnicas de adaptación en tiempo de prueba *Test-Time Training* y *Test-Time Compute* para que el modelo aprenda y descubra abstracciones algorítmicas directamente sobre las tareas objetivo, reduciendo la dependencia del pre-entrenamiento.
- Integrar mecanismos de tiempo de cálculo adaptativo o *early-stopping* que permitan al sistema abortar el bucle de razonamiento iterativo una vez haya alcanzado una solución convergente, optimizando drásticamente el consumo de memoria y tiempo de ejecución.
- Implementar estrategias de consistencia y ensamblado *top-k* que operen sobre diversas variantes o aumentos de los datos de entrada para seleccionar las predicciones más robustas.
- Realizar una comparativa exhaustiva de eficiencia que evalúe cuantitativamente la relación entre la precisión lograda en el benchmark y el coste computacional empleado, como el uso de VRAM, y precisión en FLOPs, validando la viabilidad de la inteligencia algorítmica en entornos de recursos restringidos.

2. Estado del Arte

2.1. Definición de la inteligencia

La definición de inteligencia no es una tarea sencilla. A lo largo de la historia, filósofos, científicos y expertos en diversas disciplinas han propuesto diferentes definiciones de inteligencia, cada una con su propia perspectiva y enfoque. A pesar de muchos intentos, no existe una definición estándar de inteligencia.

La inteligencia se ha descrito de manera aproximada pero no se ha llegado a una definición concreta. Según la real academia española, la inteligencia es la “capacidad de entender o comprender”, “capacidad de resolver problemas” y “conocimiento, comprensión, acto de entender”. Sin embargo, esta definición es bastante amplia y no captura completamente la complejidad de lo que implica la inteligencia.

Para crear una definición única se debe tener en cuenta varios factores. La inteligencia es una propiedad que tiene en consideración la interacción con uno o diversos entornos. La inteligencia también se relaciona con la capacidad del agente para tener éxito u obtener ganancias al respecto de alguna meta. De la misma forma, también dependen de cómo el agente está capacitado en diferentes objetivos y entornos. En base a referencias de diversos autores, en este trabajo se adoptará el estándar de definición más utilizada a día de hoy.

“Intelligence measures an agent’s ability to achieve goals in a wide range of environments.”

(Legg, Hutter, y cols., 2007, p. 9, párr. 6)

2.2. La inteligencia desde un punto de vista filosófico

Autores como Descartes, Kant o Hume han reflexionado sobre la naturaleza de la inteligencia y la mente humana. Descartes, por ejemplo, propuso la idea de que la mente y el cuerpo son entidades separadas, lo que se conoce como dualismo (González, 2011). Kant, por su parte, argumentó que la inteligencia es una facultad innata que nos permite organizar y comprender el mundo a través de categorías y conceptos (Waxman, 2014). Hume, en cambio, se centró en la experiencia y la percepción como base de la inteligencia humana.

Aristóteles también realiza varias reflexiones sobre lo que hoy se entiende por inteligencia. En concreto, sus reflexiones se desarrollan fundamentalmente a través de la naturaleza del intelecto, la facultad de inteligir y el pensamiento.

“El intelecto -siendo impasible- ha de ser capaz de recibir la forma, es decir, ha de ser en potencia tal como la forma pero sin ser ella misma y será respecto de lo inteligible algo análogo a lo que es la facultad sensitiva respecto de lo sensible.”

(Aristotle y Boeri, 2010, p. 230, párr. 1)

2.3. Nucleos del conocimiento

En la teoría se ha considerado que el conocimiento humano se basa en un único sistema de aprendizaje de propósito general. Investigaciones recientes del departamento de Psicología de la Universidad de Harvard ha propuesto una teoría alternativa, que sugiere el conocimiento humano se basa en una serie de núcleos o módulos innatos de conocimiento innatos, cada uno especializado en un dominio específico, como el espacio, los objetos, las personas, los números y el lenguaje (Spelke y Kinzler, 2007).

Cada sistema se define por un conjunto de principios y un conjunto de fronteras cognitivas. Estas fronteras actúan como un sello de identidad que ayuda a diversos investigadores demostrar que existe un sistema cognitivo único (Spelke y Kinzler, 2007). Por ejemplo, el sistema numérico central, se evidencia con representaciones numéricas poco imprecisas, esta imprecisión crece de forma lineal a medida que aumenta el número representado.

1. **Sistema de representación de objetos inanimados:** Es la capacidad de percibir límites de objetos, la forma completa o parcial de objetos ocultos y percibir cuándo y hacia donde se moverán los objetos.
2. **Sistema de representación de agentes y sus acciones:** Es la capacidad de percibir agentes animados, sus acciones y sus intenciones, incluso sin lenguaje.
3. **Sistema de representación numérica:** Es la capacidad de representar cantidades numéricas, incluso sin lenguaje, y de realizar operaciones aritméticas básicas.
4. **Sistema de representación geométrica del espacio:** Es la capacidad de representar el espacio y las relaciones espaciales entre objetos.

5. **Sistema de representación del lenguaje y social:** Es la capacidad de comprender y utilizar el lenguaje, así como de interactuar socialmente con otros individuos.

2.4. El Abstract and Reasoning Corpus

Los sistemas de evaluación de la inteligencia artificial han ido evolucionando a lo largo del tiempo. La investigación de esta área se ha centrado históricamente en comprobar si las máquinas realizan bien tareas específicas, siendo una evaluación orientada a tareas y no una evaluación de la inteligencia intrínseca.

“[AI is] the science of making machines capable of performing tasks that would require intelligence if done by [humans].”

(Minsky, 1968)

Tras los métodos tradicionales de evaluar algoritmos, la IA ha pasado a una evaluación de “caja negra” basada en el comportamiento que involucra la discriminación humana (comparación directa por o contra humanos) y pruebas de rendimiento de problemas. Se iniciaron evaluaciones metodológicas de dudosa validez, donde los investigadores a menudo seleccionaban los conjuntos de datos que mejor les convenían y ajustaban parámetros en exceso provocando sobreajustes. Esto llevó a situaciones donde muchos resultados publicados eran reproducibles pero difícilmente replicables (Hernández-Orallo, 2017). En consecuencia, la aparente mejora del modelo desaparecía en cuanto cambiaba ligeramente el dominio de los datos, además de una fuerte dispersión de los métodos en las diferentes disciplinas.

Para sistemas de inteligencia artificial de propósito general era necesario un nuevo enfoque orientado a habilidades. Este enfoque se basa en la evaluación de capacidades cognitivas en lugar de tareas en las que fue diseñado originalmente (Hernández-Orallo, 2017). Para garantizar la validez de este enfoque, las pruebas de evaluación requieren directrices estrictas, como definir con antelación los conjuntos de datos para entrenamiento y evaluación, y evitar el sobreajuste a conjuntos de datos específicos.

“The field of artificial intelligence has been very successful in developing artificial systems that perform these tasks without featuring intelligence.”

(Hernández-Orallo, 2017)

Para avanzar hacia sistemas de inteligencia artificial más inteligentes y humanos es necesario un método de evaluación de la inteligencia que compare dos o más sistemas y humanos. Es aquí donde entra en juego el Abstract and Reasoning Corpus (ARC-AGI), un *benchmark* diseñado para respetar todas las directrices necesarias. ARC-AGI está construido con un conjunto de prioridades para ser lo más parecido posible a la capacidad de razonamiento innata del ser humano (Chollet, 2019).

Los modelos que existen en la actualidad funcionan correctamente en tareas específicas, todavía están ciertamente limitados y hambrientos de datos. En situaciones en las que se desvían ligeramente de sus datos de entrenamiento, son incapaces de afrontar tareas que requieren un razonamiento novedoso. ARC-AGI también está pensado para medir el progreso de manera precisa y cuantitativa de la inteligencia. En este sentido, las definiciones que se han dado en este trabajo en secciones anteriores pueden ayudar a intuir la estructura de las pruebas de evaluación de ARC-AGI. Las tareas de evaluación no deben ser necesariamente conocidas de antemano, para conseguir la generalización el agente debe ser capaz de aprender y gestionar nuevas tareas (Chollet, 2019).

“We have been conceptualizing and evaluating intelligence in the context of AI research: crystallized skill on one hand, skill-acquisition ability on the other.”

(Chollet, 2019)

2.4.1. Espectro de la generalización

La generalización es un concepto que ha llegado de la mano del aprendizaje automático desarrollado originalmente para caracterizar el buen rendimiento de un modelo estadístico en datos de entrada que no forman parte de su conjunto de datos de entrenamiento. Este concepto ha seguido siendo parte de la conversación y se puede definir como la “habilidad” de un modelo para gestionar una situación o varias situaciones (o tareas) que no se ha encontrado previamente. Nótese que el concepto de la frase “situación que no se ha encontrado previamente” puede ser tremendamente ambigua y el autor (Chollet, 2019) propone un espectro de generalización para aclarar esta ambigüedad. En este espectro, se pueden encontrar diferentes tipos de generalización, como la generalización sistémica (centrada en el sistema) o generalización consciente-desarrollada (capacidad de manejar situaciones que ni el sistema ni su creador humano habían encontrado antes) que no se va a profundizar en este artículo. Al contrario, se va a profundizar en la generalización de

habilidades, que es más útil para cuantificar los grados de generalización.

- **Ausencia de generalización:** Sistemas donde no existe incertidumbre ni novedad. Entorno cerrado como un algoritmo que juega al “tres en raya”, iterando exhaustivamente sobre todas las jugadas posibles. No hay adaptación posible.
- **Generalización local o robustez:** Es la capacidad de un sistema para manejar nuevos ejemplos dentro de una distribución de datos conocida para una sola tarea o un conjunto bien definido de ellas. Este es el nivel en el que ha operado históricamente el aprendizaje profundo moderno. El autor (Chollet, 2019) hace referencia a un ejemplo de clasificador de gatos que, se clasifican gatos donde el modelo no había visto antes.
- **Generalización amplia o flexibilidad:** Es la capacidad de manejar una categoría amplia de tareas y entornos relacionados sin intervención humana adicional, incluyendo situaciones imprevistas por los creadores (Chollet, 2019). Un ejemplo de esto puede ser el coche autónomo de nivel 5.
- **Generalización extrema o generalidad:** Sistemas abiertos capaces de manejar tareas enteramente nuevas que solo comparten características abstractas con las ya conocidas, aplicable a cualquier dominio. También se puede denominar como inteligencia general.




Figura 2.1: Modelo jerárquico de habilidades cognitivas y su mapeo del espectro de generalización.

Fuente: Adaptado de “On the Measure of Intelligence” (Chollet, 2019)

2.4.2. La inteligencia desde la perspectiva de la adquisición de habilidades




Figura 2.2:

2.4.3. ARC-AGI-1




Figura 2.3:

2.5. Grandes Modelos de Lenguaje en ARC-AGI-1

[RTRTHRTHRTHRTHRTHRTH]

2.6. Enfoques de modelos sin Pre-entrenamiento

[RTRTHRTHRTHRTHRTHRTH]




Figura 2.4:




Figura 2.5:

2.7. Optimización en Tiempo de Inferencia

[RTRTHRTHRTHRTHRTH]




Figura 2.6:




Figura 2.7:

3. Metodología, infraestructura y herramientas

[RTRTHRTHRTHRTHRTHRTH]

4. Desarrollo

[RTRTHRTHRTHRTHRTHRTH]

4.1. Datos

[RTRTHRTHRTHRTHRTHRTH]

4.1.1. Técnicas de aumentos de datos

[RTRTHRTHRTHRTHRTHRTH]

4.2. Arquitectura y entrenamiento

[RTRTHRTHRTHRTHRTHRTH]

5. Resultados

6. Planificación

7. Estudio económico

8. Conclusiones y Trabajo Futuro

Referencias

- Aristotle, y Boeri, M. D. (2010). *Acerca del alma*. Colihue Buenos Aires.
- Chollet, F. (2019). On the measure of intelligence. *arXiv preprint arXiv:1911.01547*.
- González, R. (2011). Descartes: las intuiciones modales y la inteligencia artificial clásica. *Alpha (Osorno)*(32), 181–198.
- Hernández-Orallo, J. (2017). Evaluation in artificial intelligence: from task-oriented to ability-oriented measurement. *Artificial Intelligence Review*, 48(3), 397–447.
- Legg, S., Hutter, M., y cols. (2007). A collection of definitions of intelligence. *Frontiers in Artificial Intelligence and applications*, 157, 17.
- Minsky, M. (1968). *Matter, mind, and models in: Ml minsky (ed.): Semantic information processing*. MIT Press.
- Spelke, E. S., y Kinzler, K. D. (2007). Core knowledge. *Developmental science*, 10(1), 89–96.
- Waxman, W. (2014). *Kant's anatomy of the intelligent mind*. OUP USA.

A. Apendices